Um Framework de Apoio à Limpeza de Dados em Estatísticas Públicas

Gustavo de Oliveira Camargo

Relatório apresentado ao
Instituto de Matemática e Estatística
da Universidade de São Paulo
para exame de qualificação de
Mestrado em Ciências

Programa: Ciência da Computação
Orientador: Prof. Dr. Pedro Henrique Dias Valle
Coorientadora: Prof.ª Dr.ª Kelly Rosa Braghetto

São Paulo
Abril de 2026

Um Framework de Apoio à Limpeza de Dados em Estatísticas Públicas

Gustavo de Oliveira Camargo

Esta é a versão original do texto de
qualificação elaborado pelo candidato
Gustavo de Oliveira Camargo, tal
como submetido à Comissão Julgadora.

O conteúdo deste trabalho é publicado sob a licença CC BY 4.0
(Creative Commons Attribution 4.0 International License)

Resumo

Gustavo de Oliveira Camargo. **Um Framework de Apoio à Limpeza de Dados em Estatísticas Públicas**. Exame de Qualificação (Mestrado). Instituto de Matemática e Estatística, Universidade de São Paulo, São Paulo, 2026.

A produção de estatísticas oficiais tem enfrentado um cenário de volume e heterogeneidade crescentes de dados, o que coloca desafios relevantes à qualidade, à reprodutibilidade e à rastreabilidade dos processos de geração de indicadores. Ao mesmo tempo, o surgimento de Large Language Models (LLMs) abriu novas possibilidades para automatizar e aprimorar tarefas de limpeza de dados. Este trabalho tem por objetivo projetar e validar um *framework* baseado em LLMs para a limpeza de dados, aplicável a institutos produtores de estatísticas oficiais, com ênfase nos requisitos institucionais de reprodutibilidade, auditabilidade e integração a arquiteturas modernas de dados, como o modelo *Data Mesh*. A metodologia combina um mapeamento sistemático da literatura (MSL), o desenho do *framework* com base nos padrões identificados e a implementação e avaliação empírica de um protótipo funcional. O MSL, já concluído, analisou 51 estudos primários publicados entre 2023 e 2026 e identificou oito estratégias predominantes de uso de LLMs, com destaque para a geração de código e de regras executáveis como o padrão mais adequado aos requisitos institucionais. Adicionalmente, o MSL evidenciou a ausência de estudos voltados ao contexto das estatísticas públicas. O *framework* proposto articula agentes LLM para a geração de *prompts* e de código, processos determinísticos para execução, auditoria e documentação, supervisão humana em pontos de decisão e persistência de metadados para o reuso de modelos aprovados. A validação ocorrerá em *benchmarks* clássicos da literatura e em um estudo de caso conduzido em colaboração com o Centro de Ciências de Dados da Fundação SEADE. Espera-se que a pesquisa contribua com um padrão arquitetural integrativo, um protótipo de código aberto aplicável a institutos de estatística e evidências empíricas sobre o desempenho do *framework* em *benchmarks* da literatura e em um conjunto de dados real da Fundação SEADE, com comparação a abordagens clássicas e a técnicas recentes baseadas em LLMs.

Palavras-chave: Limpeza de dados. Large Language Models. Estatísticas públicas. Framework. Data Mesh.

Abstract

Gustavo de Oliveira Camargo. **Data Cleaning for Official Statistics: From Methodologies to a Practical Framework**. Qualifying Exam (Master's). Institute of Mathematics and Statistics, University of São Paulo, São Paulo, 2026.

The production of official statistics faces growing data volume and heterogeneity, which poses significant challenges to the quality, reproducibility, and traceability of indicator generation processes. At the same time, the emergence of Large Language Models (LLMs) has opened new possibilities for automating and improving data cleaning tasks. This work aims to design and validate an LLM-based framework for data cleaning, applicable to institutes that produce official statistics, with emphasis on the institutional requirements of reproducibility, auditability, and integration with modern data architectures, such as the Data Mesh model. The methodology combines a systematic literature mapping (SLM), the design of the framework based on the identified patterns, and the implementation and empirical evaluation of a functional prototype. The SLM, already completed, analyzed 51 primary studies published between 2023 and 2026 and identified eight predominant LLM usage strategies, highlighting code and executable rule generation as the pattern best aligned with institutional requirements. Additionally, the SLM evidenced the absence of studies focused on the public statistics context. The proposed framework articulates LLM agents for prompt and code generation, deterministic processes for execution, auditing, and documentation, human supervision at decision points, and metadata persistence for the reuse of approved models. Validation will be carried out on classical literature benchmarks and in a case study conducted in collaboration with the Data Science Center of Fundação SEADE. The research is expected to contribute with an integrative architectural pattern, an open-source prototype applicable to statistical institutes, and empirical evidence on the framework's performance across literature benchmarks and a real-world Fundação SEADE dataset, including comparisons with classical approaches and recent LLM-based techniques.

Keywords: Data cleaning. Large Language Models. Public statistics. Framework. Data Mesh.

Lista de figuras

2.1 Camadas e papéis na arquitetura *Data Mesh* (Goedegebuure *et al.*, 2025) 11
2.2 Processo de Data Cleaning (Hosseinzadeh *et al.*, 2023) 12
2.3 Atividades de Data Cleaning e Possíveis Abordagens (Côté *et al.*, 2024) . 13

3.1 Fluxograma PRISMA 2020 do processo de seleção de estudos. 24
3.2 Distribuição dos 573 registros identificados após a execução da string de busca nas bases de dados. 25
3.3 Distribuição temporal dos 51 estudos primários incluídos no mapeamento. 28
3.4 Frequência das estratégias de uso das LLMs nos 51 estudos primários. Um mesmo estudo pode combinar múltiplas estratégias, por isso o somatório ultrapassa o total de estudos. 29
3.5 Distribuição dos 51 estudos primários por domínio de aplicação. 31
3.6 Distribuição dos 51 estudos primários por tipo de dado tratado. 33
3.7 Frequência das atividades centrais de limpeza de dados nos 51 estudos primários. Um mesmo estudo pode endereçar múltiplas atividades, por isso o somatório ultrapassa o total de estudos. 35
3.8 Frequência das atividades correlatas de preparação de dados nos 51 estudos primários, realizadas em conjunto com as atividades centrais de limpeza. 36

4.1 Fluxograma do framework proposto. 45

B.1 Exemplo de Curva ROC Géron, 2019. 63

Lista de tabelas

2.1 Descrição das metodologias aplicáveis às atividades de Data Cleaning. . . 14

3.1 Formulário de Extração de Dados 22
3.2 Estudos primários incluídos no MSL. 25

4.1 Cronograma previsto para a pesquisa após a qualificação. 49

A.1 Catálogo de ferramentas e bibliotecas de Data Cleaning 53
A.2 Ferramentas de Data Cleaning citadas no artigo Abedjan *et al.*, 2016 . . 57
A.3 Métricas de Validação utilizadas nas soluções de Data Cleaning 57

Sumário

1 Introdução **1**

2 Referencial Teórico **5**

2.1 Estatísticas Públicas 5
2.2 Arquitetura Data Mesh 9
2.3 Limpeza de Dados 12
2.4 Considerações Finais 17

3 Mapeamento Sistemático da Literatura **19**

3.1 Objetivo 19
3.2 Questões de Pesquisa (QP) 19
3.3 Construção da *String* de Busca 20
3.4 Bases de Dados 20
3.4.1 Critérios de Seleção de Estudos 21
3.4.2 Avaliação de Qualidade de Estudos 22
3.5 Formulário de Extração 22
3.6 Seleção de Estudos 23
3.7 Resultados e Discussão 28
3.7.1 QP1: Quais metodologias, técnicas, ferramentas e abordagens baseadas em LLMs são utilizadas na literatura para limpeza de dados? 28
3.7.2 QP2: Em quais domínios ou contextos de aplicação as abordagens de limpeza de dados têm sido utilizadas? 31
3.7.3 QP3: Quais tipos de dados são abordados pelas técnicas de limpeza de dados descritas na literatura? 32
3.7.4 QP4: Como LLMs têm sido utilizados no processo de limpeza de dados (por exemplo, detecção de erros, imputação, normalização, deduplicação ou geração de regras)? 34

3.7.5 QP5: Quais evidências são apresentadas sobre o impacto dessas técnicas na qualidade, confiabilidade, transparência e rastreabilidade dos dados? . . . 37
3.8 Desafios e Limitações . . . 38
3.9 Ameaças à Validade do MSL . . . 40
3.10 Considerações Finais . . . 41

4 Proposta de Mestrado **43**
4.1 Considerações Iniciais . . . 43
4.2 Questão de Pesquisa . . . 43
4.3 Descrição do Framework . . . 44
4.3.1 Visão Geral . . . 44
4.3.2 Componentes . . . 46
4.3.3 Princípios do Framework . . . 47
4.4 Metodologia . . . 48
4.5 Cronograma . . . 49
4.6 Avaliação dos Resultados . . . 49
4.7 Contribuições Esperadas . . . 50

A Catálogo de Ferramentas Clássicas de Limpeza de Dados **53**
A.1 Catálogo de Ferramentas e Bibliotecas . . . 53
A.2 Ferramentas Complementares de Abedjan *et al.* (2016) . . . 56
A.3 Métricas de Validação por Solução . . . 57

B Métricas de Avaliação **61**
B.1 Accuracy . . . 61
B.2 Precision, Recall e F1-Score . . . 61
B.3 Curva ROC e AUROC . . . 62
B.4 PRAUC . . . 63

Referências **65**

Capítulo 1

Introdução

Nas últimas décadas, a ampla digitalização das informações, impulsionada pelo crescimento de tecnologias como redes sociais, Internet das Coisas (IoT), inteligência artificial e computação em nuvem, resultou em um aumento expressivo do volume de dados disponíveis. Segundo a projeção da Statista (Statista, 2022), a produção de dados em 2025 ultrapassa 173 zettabytes, valor que supera em mais de 12 vezes o produzido em 2015 (15,5 ZB), e essa quantidade ultrapassará 500 zettabytes em 2029. Esse crescimento é sustentado por fontes como transações de comércio eletrônico, dispositivos móveis, sensores urbanos, plataformas de mídia social e registros administrativos digitalizados. A combinação dessas fontes cria um potencial inédito para a produção de estatísticas oficiais e para o desenho de novas políticas públicas baseadas nelas (Kitchin, 2015; Daas *et al.*, 2015).

Institutos de estatística em diferentes países já vêm adotando essas novas fontes na produção de indicadores oficiais. A Eurostat, o *Office for National Statistics* (ONS) britânico e o *Statistics Netherlands*, por exemplo, utilizam *scanner data* de varejo no cálculo do índice de preços ao consumidor, o que amplia a cobertura de produtos e reduz o custo de coleta em relação aos levantamentos tradicionais (Chessa e Griffioen, 2019). Imagens de satélite e dados de sensoriamento remoto também complementam levantamentos agrícolas e indicadores ambientais em diversos institutos nacionais (MacFeely, 2020). Esse movimento demonstra uma tendência de modernização na produção de estatísticas oficiais.

Nesse contexto, há mais de 40 anos, a Fundação SEADE (Sistema Estadual de Análise de Dados), do Estado de São Paulo, produz estatísticas oficiais que, tradicionalmente, baseiam-se em registros administrativos ou na coleta primária de dados por meio de *surveys*, pesquisas amostrais domiciliares, estimativas e projeções populacionais e levantamentos setoriais para a construção de indicadores econômicos, sociais e demográficos (Fundação Seade, 2026a; Fundação Seade, 2026b). Para isso, a Fundação SEADE conta com uma equipe diversa, metodologias consolidadas e acordos de cooperação técnica para a realização de pesquisas primárias e para o acesso a dados secundários. Apesar disso, o contexto da era digital representa um novo paradigma para a atuação de agências de estatísticas e demanda pesquisa e inovação para adotar novos métodos e tecnologias, como as técnicas de Inteligência Artificial, para coletar, armazenar, organizar e processar dados, visando à produção de estatísticas públicas (Struijs *et al.*, 2014; Riza e Suhardi, 2022).

Em particular, em outubro de 2024, a Fundação SEADE lançou o Centro de Ciência de Dados para Estatísticas Públicas (CCDEP),[1] uma iniciativa em parceria com instituições de pesquisa do Estado de São Paulo e financiada pela FAPESP, voltada ao desenvolvimento de tecnologias e metodologias inovadoras e à exploração de novas fontes de dados para aprimorar a produção de indicadores. O centro busca fortalecer a capacidade científica e técnica, gerar impacto social por meio da melhoria das políticas públicas e modernizar a coleta, o tratamento e a análise de registros digitais por meio do uso de ciência de dados. Além disso, promove a colaboração entre equipes da Fundação SEADE e pesquisadores externos e dissemina o conhecimento e as soluções desenvolvidas para apoiar a administração pública paulista e outras esferas de governo.

A produção de estatísticas oficiais envolve fluxos complexos de coleta, integração e transformação de dados provenientes de múltiplas fontes, historicamente executados com forte apoio de processos manuais e ferramentas planilhadoras. Com o crescimento no volume e na heterogeneidade das fontes disponíveis, institutos nacionais de estatística têm enfrentado desafios crescentes para manter a qualidade, a escalabilidade e a confiabilidade dos processos de produção de indicadores (Struijs *et al.*, 2014). Esses desafios ganham especial relevância diante de requisitos como reprodutibilidade, auditabilidade e rastreabilidade, considerados dimensões fundamentais de qualidade em estatísticas oficiais, para os quais os *frameworks* tradicionais demandam adaptação quando novos métodos de coleta, tratamento e análise passam a integrar a produção (Saidani e Dumpert, 2025).

No caso da Fundação SEADE, esses desafios se manifestam em indicadores cuja produção depende da integração de grandes volumes de dados provenientes de múltiplas entidades estaduais e federais. Um exemplo é o cálculo do PIB (Produto Interno Bruto) estadual, que envolve um conjunto amplo de fontes e etapas de processamento, ilustrando a complexidade característica da produção de estatísticas oficiais.

Em um cenário marcado pelo crescimento contínuo e pela diversificação das fontes de dados, o atendimento sustentado a princípios fundamentais de qualidade, como reprodutibilidade, auditabilidade e rastreabilidade, demanda a sistematização e a evolução dos processos associados à produção desses indicadores. Nesse sentido, a adoção de técnicas de Ciência de Dados e de Engenharia de Software pode otimizar esses fluxos de trabalho e aumentar a eficiência da produção de estatísticas oficiais. Foi com esse propósito que o grupo de trabalho conduzido por professores e alunos do IME (Instituto de Matemática, Estatística e Ciência da Computação) da USP propôs o desenvolvimento de um ambiente de processamento e análise de dados baseado no paradigma de *Data Mesh*, capaz de lidar com o crescimento do volume de dados e a complexidade das tarefas analíticas.

No contexto da construção do *Data Mesh*, assegurar a qualidade dos dados consumidos pelo SEADE é essencial, pois a confiabilidade de qualquer indicador, estudo ou pesquisa conduzidos pelo centro depende diretamente da integridade e da precisão das informações utilizadas. Como um dos objetivos do CCDEP é ampliar as fontes de informação e lidar com grandes volumes de dados por meio de *big data*, torna-se crucial implementar técnicas eficazes de validação, tratamento e limpeza de dados na arquitetura em desenvolvimento.

Apesar da existência de diversas metodologias e ferramentas para a qualidade de

[1] Mais informações em: https://ccd.fapesp.br/ccdep

dados na literatura científica sobre ciência de dados, ainda há uma lacuna quanto à sua sistematização e adaptação ao contexto específico da produção de estatísticas públicas, especialmente em arquiteturas modernas como a *Data Mesh*. Em paralelo, o avanço recente dos *Large Language Models* (LLMs) tem aberto novas possibilidades para automatizar e aprimorar tarefas de limpeza de dados, com estratégias que variam da inferência direta de correções à geração de código executável. A aplicabilidade dessas abordagens ao contexto institucional das estatísticas públicas, no entanto, ainda é pouco explorada na literatura, em especial sob a ótica dos requisitos de reprodutibilidade, rastreabilidade e auditabilidade característicos desse domínio.

Portanto, nesse contexto, o objetivo deste projeto de mestrado é projetar e validar um *framework* baseado em LLMs para apoiar a limpeza de dados em institutos produtores de estatísticas públicas, com ênfase nos requisitos de reprodutibilidade, rastreabilidade e auditabilidade, e alinhado a arquiteturas modernas de dados, como o paradigma *Data Mesh* em desenvolvimento no CCDEP.

Para isso, os seguintes objetivos específicos deverão ser realizados:

- Mapear sistematicamente a literatura sobre o uso de LLMs em tarefas de limpeza de dados, identificando estratégias, padrões arquiteturais, atividades suportadas e lacunas existentes;
- Projetar um *framework* baseado em LLMs que articule geração de código, supervisão humana e persistência de metadados, alinhado aos princípios da arquitetura *Data Mesh* e aos requisitos institucionais da produção de estatísticas públicas;
- Implementar um protótipo funcional do *framework* utilizando ferramentas de código aberto;
- Avaliar o *framework* em *benchmarks* clássicos da literatura e em um estudo de caso conduzido em colaboração com o Centro de Ciências de Dados para Estatísticas Públicas (CCDEP) da Fundação SEADE.

Este documento está organizado da seguinte forma: o Capítulo 2 apresenta o referencial teórico, abordando os conceitos fundamentais para a compreensão da proposta de pesquisa, incluindo Estatísticas Públicas, *Data Mesh* e Limpeza de Dados. O Capítulo 3 descreve o mapeamento sistemático da literatura conduzido para identificar técnicas de limpeza de dados. Por fim, o Capítulo 4 apresenta a proposta do projeto de mestrado, abrangendo a descrição do *framework* proposto, a metodologia definida e o cronograma previsto para a execução das atividades e a conclusão da dissertação.

Capítulo 2

Referencial Teórico

Neste capítulo são apresentados os conceitos fundamentais para a compreensão da proposta de pesquisa do mestrado, a saber: estatísticas públicas, arquitetura *Data Mesh* e limpeza de dados. O capítulo está organizado nas seguintes seções: a Seção 2.1 apresenta o conceito de estatísticas públicas, sua relevância, os principais tipos e os desafios associados. Na Seção 2.2 são discutidos os fundamentos da arquitetura *Data Mesh*, os aspectos que a tornam pertinente ao contexto do CCDEP e os desafios relacionados à sua adoção. Enquanto a Seção 2.3 aborda os conceitos de limpeza de dados, sua importância, as principais técnicas e os desafios. Por fim, a Seção 2.4 sintetiza os principais pontos discutidos ao longo do capítulo.

2.1 Estatísticas Públicas

As estatísticas públicas constituem um elemento fundamental para o funcionamento de sociedades modernas, pois atendem às necessidades de informação de governos, cidadãos e setores produtivos em diferentes áreas, como a economia, a demografia, os aspectos sociais e o meio ambiente (MacFeely, 2020). Sua produção depende não apenas de metodologias técnicas rigorosas, mas também da cooperação efetiva entre indivíduos e organizações na coleta de dados. Para que as informações oficiais sejam confiáveis e amplamente utilizadas, as agências estatísticas precisam operar com princípios sólidos, incluindo independência institucional, relevância dos dados e credibilidade junto ao público, de modo a fortalecer a confiança na informação estatística produzida (United Nations, 2003).

As Estatísticas Públicas abrangem diversas áreas da sociedade, como saúde, educação, trabalho, mobilidade e renda, entre outras, e exigem uma organização clara para facilitar o acesso e a compreensão dos dados por usuários diversos (United Nations, 2003). Nesse contexto, o IBGE (Instituto Brasileiro de Geografia e Estatística) desenvolveu a Classificação de Informações Estatísticas (CIE), um sistema que representa os temas mensurados ou demandados no âmbito do Sistema Estatístico Nacional, inspirado na *Classification of Statistical Activities* (CSA), versão de 2009, elaborada pela Comissão Econômica das Nações Unidas para a Europa (*United Nations Economic Commission for Europe* - UN/ECE). A CIE organiza as informações estatísticas em 5 domínios, detalhados abaixo (IBGE, Coordenação de Cadastros e Classificações, 2024):

1. **Estatísticas sociais e de população**: Compreende informações que fornecem um amplo perfil sociodemográfico do País, abrangendo estatísticas de população e suas múltiplas dimensões de análise, como: trabalho (taxa de ocupação e desemprego), educação (taxa de escolarização, anos médios de estudo), saúde (expectativa de vida, mortalidade infantil), rendimento, despesa e consumo das famílias, proteção social, assentamentos humanos e moradia (déficit habitacional), uso do tempo, entre outros aspectos;

2. **Econômicas**: Compreende informações que fornecem um amplo perfil da realidade econômica do País, em suas múltiplas dimensões de análise, abrangendo estatísticas e contas macroeconômicas (PIB, contas nacionais), estatísticas de empresas (número de estabelecimentos, pessoal ocupado), estatísticas econômicas setoriais (produção industrial, agropecuária, serviços), comércio internacional (exportações e importações), preços e custos (IPCA, INPC), entre outros aspectos;

3. **Ambientais**: Compreende informações sobre o estado vigente e as mudanças das condições ambientais, bem como sobre a qualidade e a disponibilidade dos recursos naturais e os impactos das atividades humanas e de eventos naturais, incluindo estatísticas sobre cobertura e uso da terra, desmatamento, recursos hídricos, qualidade da água, emissões de gases de efeito estufa, biodiversidade e eventos climáticos extremos;

4. **Governança**: Compreende informações que fornecem um amplo perfil da realidade da governança do País, em suas múltiplas dimensões de análise, abrangendo estatísticas sobre não discriminação e igualdade, participação política (comparecimento eleitoral), acesso à informação e transparência na gestão pública, acesso à justiça e qualidade da justiça, capacidade de resposta do Estado, percepção de corrupção, confiança nas instituições, segurança pública (taxas de homicídio) e sensação de segurança, entre outros aspectos;

5. **Transversais**: Compreende informações sobre questões conceituais ou abordagens temáticas que exigem a articulação de dados de diferentes domínios para subsidiar agendas públicas. Inclui temas como desenvolvimento sustentável (ODS), desigualdades sociais, gênero, raça, território, mudanças climáticas, juventude e envelhecimento populacional, além de outros temas que integram dois ou mais domínios.

O CIE contribui para a transparência, a governança e a navegabilidade dos dados disponíveis no portal do IBGE e apoia tanto a produção quanto a utilização de estatísticas para a análise e a formulação de políticas públicas (IBGE, Coordenação de Cadastros e Classificações, 2024).

A Fundação SEADE, vinculada à Secretaria da Fazenda e Planejamento do Estado de São Paulo, é um centro de referência na produção e disseminação de estatísticas socioeconômicas e demográficas (Fundação Seade, 2026a). A instituição realiza pesquisas próprias e organiza dados de diversas fontes, formando um amplo acervo sobre o estado de São Paulo e seus 645 municípios, disponibilizado gratuitamente, principalmente na internet. Ao longo de mais de 40 anos de atuação, a Fundação SEADE tornou-se uma fonte confiável de informações para apoiar a análise da realidade socioeconômica e o planejamento de políticas públicas. Seus produtos e serviços atendem cidadãos, gestores públicos, empresas

e imprensa. A instituição também adota diretrizes voltadas à transparência e à qualidade dos dados, como a oferta de microdados, a disponibilização de metadados e o investimento contínuo em metodologias, sistemas e ferramentas, além do compartilhamento de soluções com instituições parceiras (Fundação Seade, 2026a).

A Fundação SEADE organiza seus produtos estatísticos em três grandes temas: **Demografia**, **Economia** e **Social** (Fundação Seade, 2026b). No tema de Demografia, encontram-se produtos que oferecem dados sobre a distribuição espacial e a dinâmica da população, como estimativas e projeções populacionais, taxas de mortalidade e mortalidade infantil, índices de envelhecimento e evolução da população por município, permitindo acompanhar transformações demográficas ao longo do tempo (por exemplo, estimativas de população e taxas de mortalidade por município). No tema de Economia, o SEADE publica estatísticas sobre o desempenho econômico do estado, incluindo séries mensais e trimestrais do Produto Interno Bruto (PIB), dados de investimentos anunciados, indicadores setoriais de indústria e serviços e bases de dados sobre empresas, que são importantes para entender o comportamento econômico e estruturar análises de atividades produtivas locais. Já no tema Social, estão disponíveis produtos que abordam aspectos como emprego e trabalho, características dos municípios em termos de educação e saúde, e indicadores de vulnerabilidade social, que trazem dados sobre as condições sociais das populações e auxiliam na formulação e avaliação de políticas públicas voltadas ao bem-estar social.

Tradicionalmente, dados para estatísticas públicas são obtidos por meio de censos e pesquisas periódicas, realizados em diferentes intervalos de tempo, como semanal, mensal, anual ou em ciclos mais longos, como os censos (United Nations, 2003). Após a coleta, as informações passam por etapas de tratamento e processamento até se tornarem insumos para análise. No entanto, esse modelo convencional apresenta limitações relacionadas a custos, tempo e complexidade operacional, o que tem incentivado o uso de fontes alternativas de dados (Daas *et al.*, 2015). Entre essas fontes, destacam-se os dados administrativos provenientes de registros e relatórios institucionais, bem como os dados oriundos da internet e de sistemas de observação em larga escala. Esses conjuntos podem ser analisados por meio de técnicas de aprendizado de máquina e de aprendizado profundo, permitindo a extração de padrões e informações relevantes a partir de diferentes formatos, como textos, imagens, vídeos e áudios (Riza e Suhardi, 2022).

Além dos aspectos relacionados à coleta e ao processamento de dados, a incorporação de fontes de *big data* na produção de estatísticas públicas também envolve um amplo conjunto de oportunidades, desafios e riscos institucionais, técnicos e metodológicos (Struijs *et al.*, 2014). A literatura científica aponta que essas novas fontes podem complementar e, em alguns casos, substituir bases tradicionais, permitindo a geração de indicadores mais tempestivos, a ampliação das análises em nível micro e territorial, bem como a redução de custos operacionais (Daas *et al.*, 2015). Ao mesmo tempo, seu uso exige mudanças organizacionais, o fortalecimento de capacidades analíticas e maior integração com áreas como a ciência de dados e as ciências sociais computacionais (MacFeely, 2020). No entanto, a adoção de *big data* também impõe riscos relevantes, relacionados à qualidade, à governança, às questões legais e à confiabilidade das inferências produzidas, o que demanda estruturas robustas de validação, transparência e controle institucional(Kitchin, 2015).

A incorporação de novas fontes de dados, especialmente as associadas ao *big data*,

apresenta um amplo conjunto de oportunidades para aprimorar a produção estatística e a geração de conhecimento (Kitchin, 2015). Entre essas oportunidades, destaca-se a possibilidade de complementar, substituir, aprimorar e ampliar conjuntos de dados já existentes, tornando as análises mais robustas e abrangentes (Daas *et al.*, 2015). Além disso, tais fontes permitem a obtenção de resultados mais tempestivos, contribuindo para processos decisórios mais ágeis. Também podem mitigar a fadiga dos respondentes em pesquisas tradicionais ao reduzir a necessidade de coleta direta de informações (Daas *et al.*, 2015). Outro benefício relevante é a possibilidade de complementar e estender análises em nível micro e em pequenas áreas geográficas, ampliando o detalhamento das estatísticas. A utilização dessas bases pode ainda melhorar a qualidade dos dados por meio de processos de validação e *ground-truthing*, além de refinar a composição estatística existente e facilitar comparações entre diferentes jurisdições. A melhor integração com outras bases de dados favorece análises integradas, possibilitando novos *insights* e interpretações mais sofisticadas (Struijs *et al.*, 2014). Do ponto de vista organizacional, observa-se potencial para redução de custos, otimização das práticas de trabalho, ganhos de eficiência e redirecionamento de equipes para atividades de maior valor agregado. Soma-se a isso o fortalecimento da colaboração com a ciência de dados e a indústria de dados, o aumento da visibilidade e do uso das estatísticas oficiais e a formação de alianças estratégicas com produtores de *big data* (MacFeely, 2020).

Entretanto, a adoção dessas novas fontes também impõe desafios significativos. Um dos principais é a obtenção de acesso aos dados, incluindo questões relacionadas à aquisição e ao licenciamento. Muitas vezes, há limitações de acesso à metodologia associada e aos metadados, o que dificulta a compreensão adequada das bases (Kitchin, 2015). Estabelecer a proveniência e a linhagem dos conjuntos de dados torna-se essencial para garantir transparência e rastreabilidade. Além disso, surgem questões legais e regulatórias, incluindo aspectos de propriedade intelectual (Struijs *et al.*, 2014). É igualmente necessário determinar a adequação dos dados ao propósito estatístico pretendido, bem como avaliar sua qualidade quanto à veracidade, incerteza, erro, viés e confiabilidade (Saidani e Dumpert, 2025). A viabilidade tecnológica e metodológica precisa ser cuidadosamente analisada, especialmente quando se trata de experimentos e testes com análises em larga escala. Soma-se a isso a necessidade de gestão de mudanças institucionais e de assegurar a colaboração interjurisdicional, por meio de padrões comuns que promovam interoperabilidade e consistência (Struijs *et al.*, 2014).

Por fim, existem riscos a serem considerados. Há o risco de desvio da missão institucional, caso o foco em novas fontes de dados comprometa os objetivos centrais (Kitchin, 2015). Danos à reputação e perda de confiança pública podem ocorrer, especialmente diante de falhas na qualidade dos dados ou na transparência dos processos. Violações de privacidade e segurança representam riscos críticos, exigindo mecanismos rigorosos de governança e de proteção. O acesso inconsistente às fontes e a eventual descontinuidade dos dados também podem comprometer séries históricas e análises comparativas (Struijs *et al.*, 2014). Pode haver resistência tanto por parte dos provedores de *big data* quanto da própria população, além do risco de fragmentação de abordagens entre diferentes jurisdições. Restrições de recursos e cortes orçamentários podem limitar a sustentabilidade das iniciativas, e a privatização ou a competição por fontes de dados pode dificultar o acesso equitativo e a manutenção do caráter público das estatísticas (Kitchin, 2015).

Em síntese, as estatísticas públicas constituem um elemento central para o planejamento, o monitoramento e a avaliação de políticas públicas, além de contribuir para o fortalecimento da transparência e do controle social (United Nations, 2003). A incorporação de novas fontes de dados e de técnicas avançadas de análise, especialmente no contexto do *big data*, amplia o potencial informativo dessas estatísticas e possibilita a produção de indicadores mais detalhados e tempestivos (Daas *et al.*, 2015). Entretanto, esse processo também impõe desafios relacionados à governança, à qualidade, à integração e à sustentabilidade institucional, evidenciando a necessidade de estruturas organizacionais, arquiteturas de dados e metodologias capazes de organizar, integrar e disponibilizar dados de forma descentralizada, confiável e escalável. Nesse contexto, a próxima seção apresenta a arquitetura de *Data Mesh*, discutindo seus princípios, características e seu potencial de aplicação na produção de estatísticas públicas (Machado *et al.*, 2022).

2.2 Arquitetura Data Mesh

Atualmente, para incorporar *big data* às suas estruturas, as organizações têm utilizado, como padrão, as arquiteturas de *Data Warehouse* e *Data Lake* (Souibgui *et al.*, 2019). Os *Data Warehouses* são repositórios voltados à consolidação de dados operacionais para apoio à tomada de decisão, compostos por quatro componentes principais: transações de origem, sistema de Extração, Transformação e Carga (ETL), área de apresentação de dados e aplicações de *Business Intelligence* (BI). Já os *Data Lakes* são repositórios altamente escaláveis, nos quais os dados são armazenados em seu formato original (*as-is*), permanecendo nesse estado até que surja a necessidade de processamento. Embora ambas as arquiteturas atuem como repositórios de dados, elas se diferenciam quanto à sua estrutura e forma de implementação, especialmente em relação aos tipos de dados tratados e ao nível de processamento aplicado (Machado *et al.*, 2022).

No entanto, com o aumento do uso de *big data* e de técnicas de Inteligência Artificial, tem-se observado a formação de gargalos operacionais nas organizações (Machado *et al.*, 2022). As equipes de dados vêm sendo cada vez mais sobrecarregadas, assumindo atividades que vão desde análises exploratórias pontuais até o gerenciamento centralizado de pipelines de ETL. Como consequência, cresce também o descontentamento das empresas quanto à capacidade dessas arquiteturas tradicionais de entregar valor analítico de forma ágil. Além disso, a centralização das responsabilidades dificulta a adaptação às novas demandas e limita a escalabilidade organizacional.

Diante desse cenário, o *Data Mesh* surge como uma proposta arquitetural baseada na descentralização da gestão de dados (Machado *et al.*, 2022). Essa abordagem organiza os dados conforme os domínios de negócio da organização, atribuindo às equipes responsáveis a propriedade e a manutenção de seus respectivos produtos de dados. Nesse modelo, os dados passam a ser tratados como produtos, com requisitos claros de qualidade, confiabilidade e usabilidade. Para viabilizar essa dinâmica, utiliza-se uma plataforma autoatendida que fornece ferramentas padronizadas para o desenvolvimento e a operação de produtos de dados, aliada a um modelo de governança federada que garante interoperabilidade e segurança (Goedegebuure *et al.*, 2025). Dessa forma, o *Data Mesh* busca alinhar a arquitetura de dados à estrutura organizacional, promovendo maior escalabilidade e democratização do acesso à informação (Machado *et al.*, 2022).

O conceito de Data Mesh é definido com base em quatro princípios fundamentais (Goedegebuure *et al.*, 2025):

1. ***Data as a Product* (Dado como Produto):** No contexto do *Data Mesh*, o dado é tratado como um produto e, portanto, deve possuir características semelhantes às de um produto tradicional. Um produto de dados deve conter dados e metadados, código de ETL e de governança, além de infraestrutura para a construção, implantação, execução e armazenamento dos processos responsáveis pela geração dessas informações. Além disso, os metadados devem incluir informações como os responsáveis pelo produto (*product owners*), os *endpoints* de acesso, o modelo de dados, as políticas de acesso, as métricas de qualidade e o ciclo de vida dos dados.

2. ***Domain Ownership of Data* (Responsabilidade dos Dados por Domínio):** Diferentemente das arquiteturas tradicionais, nas quais um time centralizado é responsável pela gestão dos dados analíticos, no *Data Mesh* essa responsabilidade é distribuída entre equipes ou indivíduos que têm maior conhecimento e proximidade com os dados. As organizações já estruturam seus negócios em domínios, como vendas, finanças e produtos. Nesse modelo, os produtos de dados são construídos e governados com base nesses domínios existentes. As equipes são responsáveis pelo desenvolvimento, manutenção e governança dos produtos de dados associados ao seu domínio, garantindo a qualidade, a confiabilidade e a conformidade com as diretrizes organizacionais.

3. **Governança Computacional Federada:** Na arquitetura *Data Mesh*, a governança é descentralizada, de modo que cada equipe é responsável por assegurar a qualidade e a conformidade de seus produtos de dados. No entanto, é necessária a existência de um grupo de governança federada, composto por representantes dos domínios, especialistas em governança e, quando necessário, por membros da equipe jurídica. Esse grupo tem como objetivo definir regras de conformidade regulatória, normas de padronização e políticas que garantam a interoperabilidade entre os produtos de dados.

4. ***Self-Serve Data Platform* (Plataforma de Dados de Autoatendimento):** A arquitetura *Data Mesh* pressupõe a existência de uma plataforma que permita que diferentes usuários criem, implantem, gerenciem e consumam produtos de dados de forma autônoma. Essa plataforma tem como objetivo padronizar a estrutura dos produtos, garantir a interoperabilidade, reduzir o nível de especialização técnica exigido dos desenvolvedores e otimizar a experiência dos *stakeholders* no desenvolvimento, no consumo e na governança dos dados.

A organização das camadas, responsabilidades e papéis no contexto do *Data Mesh* pode ser observada na Figura 2.1, que apresenta a estrutura da arquitetura, evidenciando a separação entre a plataforma, os produtos de dados, a governança e os domínios de negócio (Goedegebuure *et al.*, 2025).

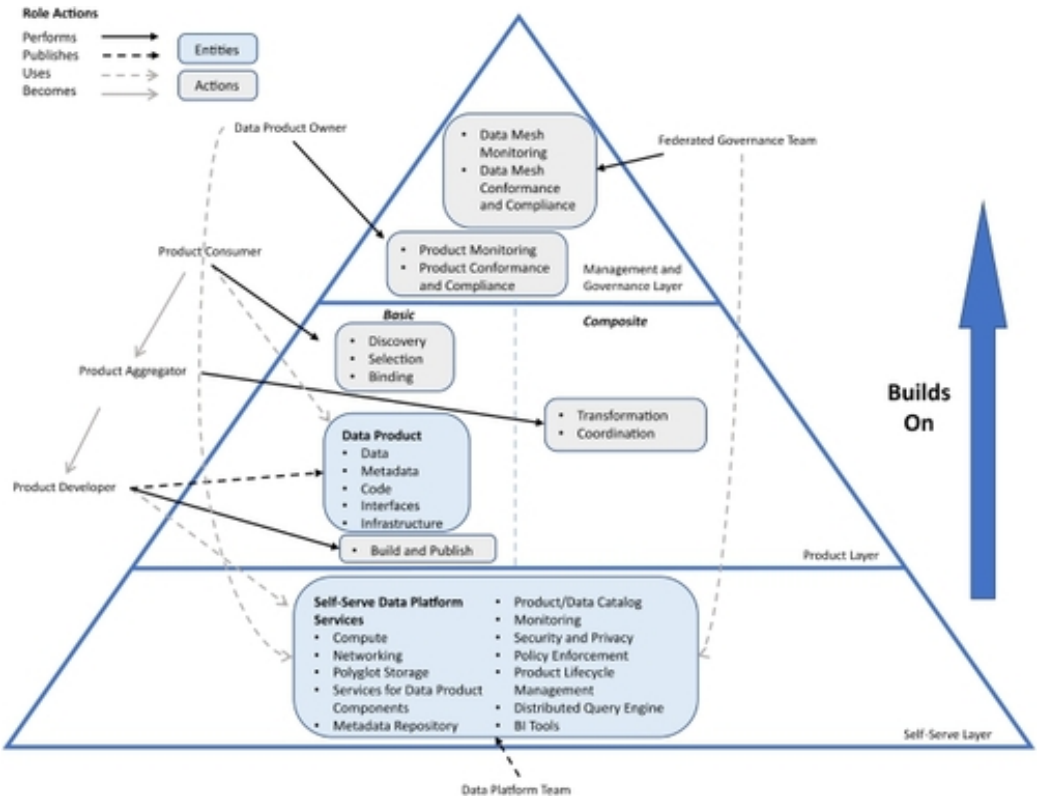


Figura 2.1: *Camadas e papéis na arquitetura Data Mesh (Goedegebuure et al., 2025)*

A arquitetura *Data Mesh* apresenta-se como uma abordagem promissora para o contexto do CCDEP e, de modo mais amplo, para a produção de Estatísticas Públicas, uma vez que cada indicador pode ser compreendido como um produto de dados, enquanto cada tema ou subtema pode ser interpretado como um domínio dentro de um instituto de pesquisa. Nesse modelo, quanto maior for a qualidade desses produtos de dados e mais elevada for a interoperabilidade entre eles, maior será o potencial para o desenvolvimento de estudos analíticos baseados em estatísticas oficiais, contribuindo para a formulação de políticas públicas mais consistentes.

Entretanto, sua aplicação ainda apresenta desafios relevantes, especialmente devido à limitada consolidação na literatura científica quanto à padronização do *Data Mesh*. Persistem lacunas relacionadas à definição dos produtos de dados, à sua composição e às suas interfaces, bem como aos critérios de publicação e aos artefatos produzidos e utilizados por esses produtos. Além disso, não há consenso quanto à estrutura e à interface das plataformas de autoatendimento. De modo geral, a literatura apresenta princípios orientadores para a implementação do *Data Mesh*, porém, ainda são escassas as ferramentas e metodologias detalhadas que operacionalizem esses princípios na construção e na manutenção dessas arquiteturas (Goedegebuure *et al.*, 2025).

Nesse contexto, destaca-se como aspecto central a compreensão de como o *Data Mesh* pode incorporar, de forma orgânica, os processos de limpeza de dados à sua estrutura. Essa questão constitui o foco deste projeto de pesquisa. Para tanto, é necessário esclarecer o conceito de limpeza de dados, que será abordado na seção seguinte.

2.3 Limpeza de Dados

O processo de software responsável por facilitar a população de *Data Warehouses* é denominado ETL (*Extraction, Transformation and Loading*). Nesse processo, inicialmente os dados são extraídos de suas fontes de origem; em seguida, ocorre a etapa de transformação, na qual os dados são convertidos para o formato ou a estrutura apropriados para fins de consulta e análise, por meio de atividades como limpeza de dados, reformatação, correspondência e agregação. Por fim, é realizada a etapa de carga, na qual os dados já transformados são armazenados no sistema de destino, tipicamente o *Data Warehouse*(Souibgui *et al.*, 2019).

Dentro da etapa de transformação de dados, a limpeza de dados é um processo fundamental para garantir a qualidade das análises, sobretudo em cenários caracterizados por grandes volumes e diversidade de fontes de dados (Côté *et al.*, 2024). À medida que a quantidade de dados cresce, aumenta também a probabilidade de ocorrência de problemas como registros incompletos, duplicados ou inconsistências de formato, o que torna necessária a adoção de procedimentos sistemáticos de tratamento. De modo geral, a limpeza de dados é conduzida de forma iterativa e envolve múltiplas etapas, como demonstrado na Figura 2.2. Inicialmente, os dados são analisados para identificar anomalias que possam comprometer sua qualidade. Em seguida, são definidas e aplicadas técnicas apropriadas para detectar e corrigir esses problemas, compondo um fluxo de tratamento que deve ser previamente avaliado quanto à sua eficácia e consistência. Após essa validação, o processo é executado sobre os dados, e os resultados obtidos passam por novas verificações para assegurar que as correções realizadas atendem aos objetivos propostos. Por fim, realiza-se o monitoramento dos resultados, incluindo o tratamento de exceções para os casos que não foram adequadamente resolvidos nas etapas anteriores (Hosseinzadeh *et al.*, 2023).

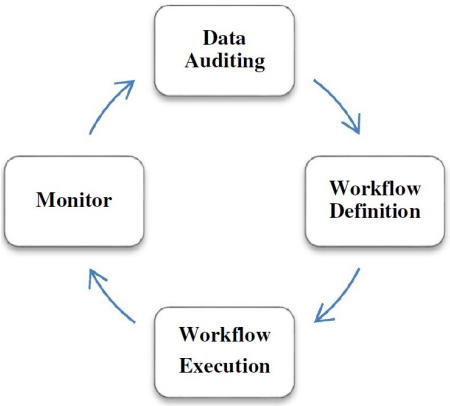


Figura 2.2: *Processo de Data Cleaning (Hosseinzadeh et al., 2023)*

De forma geral, a limpeza de dados (*data cleaning*) consiste em um conjunto de processos e técnicas voltados à identificação, correção e mitigação de erros, inconsistências, ruídos e incompletudes presentes em conjuntos de dados (Côté *et al.*, 2024). Trata-se de uma etapa fundamental nos processos analíticos, uma vez que a qualidade dos dados impacta diretamente a confiabilidade dos modelos, indicadores e análises produzidos.

Nesse contexto, a literatura tem se dedicado a investigar diferentes estratégias para lidar com problemas como valores incorretos, registros duplicados, dados ausentes e rótulos inconsistentes (Hosseinzadeh *et al.*, 2023).

Para consolidar o estado da arte sobre o tema, este trabalho se apoia em dois mapeamentos sistemáticos recentes, cada um com um recorte complementar. O primeiro, de Côté *et al.* (2024), analisa 101 estudos com foco em *data cleaning* aplicado a *machine learning* e apresenta a taxonomia mais detalhada sobre atividades e metodologias da área. O segundo, de Hosseinzadeh *et al.* (2023), concentra-se em 27 estudos voltados a ambientes de *big data* e organiza as técnicas pelas respectivas estratégias de implementação.

No trabalho conduzido por Côté *et al.* (2024), os autores analisaram 101 estudos e propuseram uma categorização das principais atividades de limpeza de dados, bem como das metodologias associadas a cada uma delas. A Figura 2.3 sintetiza essa classificação, relacionando os tipos de erro às possíveis abordagens de correção.

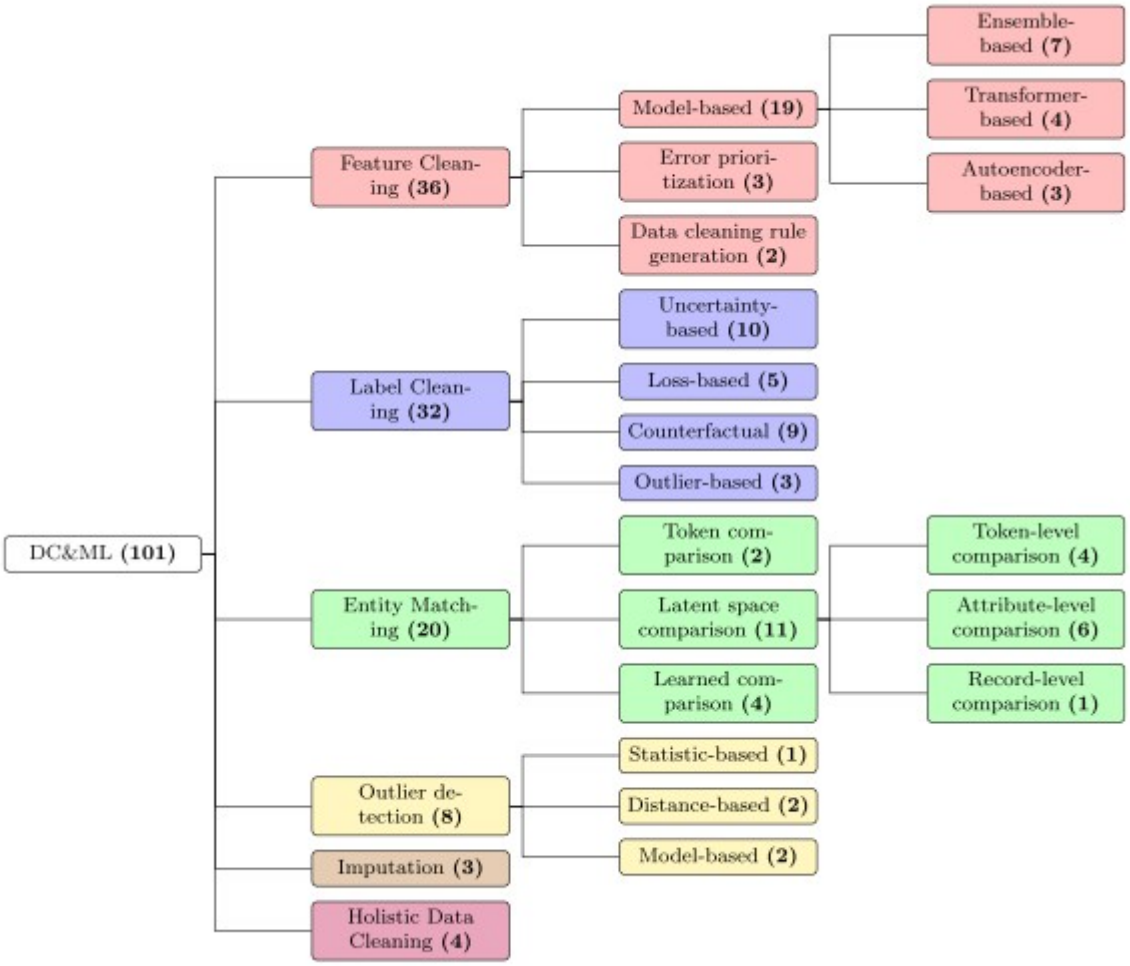


Figura 2.3: *Atividades de Data Cleaning e Possíveis Abordagens (Côté et al., 2024)*

De acordo com essa revisão, as principais atividades de limpeza de dados podem ser organizadas em seis categorias: *feature cleaning*, *label cleaning*, *entity matching*, *outlier*

detection, *imputation* e *holistic data cleaning*. Cada atividade de data cleaning apresentada tem por objetivo corrigir um tipo de erro específico em um dataset, como detalhado a seguir:

- ***Feature Cleaning***
  - **Tipo de erro tratado:** Valores incorretos nos atributos.
  - **Descrição:** Detecta ou corrige erros nos atributos de um registro.
- ***Label Cleaning***
  - **Tipo de erro tratado:** Rótulos incorretos.
  - **Descrição:** Identifica e corrige erros nos rótulos dos dados.
- ***Entity Matching***
  - **Tipo de erro tratado:** Registros duplicados.
  - **Descrição:** Identifica diferentes tuplas que se referem à mesma entidade no mundo real, como um registro duplicado.
- ***Outlier Detection***
  - **Tipo de erro tratado:** Dados fora da distribuição esperada.
  - **Descrição:** Detecta registros que estão muito distantes estatisticamente dos demais registros do *dataset*.
- ***Imputation***
  - **Tipo de erro tratado:** Valores ausentes (*missing values*).
  - **Descrição:** Preenche campos vazios em registros que apresentam atributos vazios.
- ***Holistic Data Cleaning***
  - **Tipo de erro tratado:** Múltiplos tipos de erro simultaneamente.
  - **Descrição:** Abordagens que buscam corrigir mais de um tipo de erro de uma só vez.

A partir da análise dos estudos, observa-se que essas atividades são apoiadas por diferentes metodologias, conforme apresentado na Tabela 2.1. De modo geral, destacam-se abordagens baseadas em modelos estatísticos, em aprendizado de máquina e em aprendizado profundo, além de técnicas baseadas em regras e na geração automática de *pipelines*.

Tabela 2.1: *Descrição das metodologias aplicáveis às atividades de Data Cleaning.*

Metodologia	Descrição
Model-based	Usa modelos de aprendizado de máquina supervisionados ou não supervisionados para detectar, imputar ou corrigir erros. O modelo aprende o padrão dos dados corretos e identifica desvios.

Metodologia	**Descrição**
Ensemble-based	Combinação de múltiplos modelos ou técnicas de limpeza (como modelos preditivos, regras e estatísticas) para melhorar a precisão na detecção e correção de erros.
Transformer-based	Uso de modelos baseados em *Transformers* (como BERT e GPT) aplicados a dados tabulados, textuais ou semiestruturados, para tarefas como previsão de valores corretos ou *matching*.
Autoencoder-based	Emprega *autoencoders* (redes neurais de reconstrução) para identificar anomalias; dados mal reconstruídos são considerados suspeitos de erro.
Error Priorization	Técnicas que priorizam os registros mais prováveis de estarem incorretos, otimizando o processo de limpeza quando os recursos (tempo, esforço humano) são limitados.
Data Cleaning Rule Generation	Geração automática ou assistida de regras (restrições, dependências funcionais, validações lógicas) para detectar e corrigir inconsistências nos dados.
Uncertainty-based	Métodos que analisam a incerteza associada às predições de modelos para detectar rótulos possivelmente incorretos.
Loss-based	Detecta rótulos incorretos analisando o impacto desses registros na função de perda durante o treinamento do modelo.
Counterfactual-based	Avalia o comportamento dos dados sob alterações contrafactuais para detectar inconsistências ou erros nos rótulos.
Outlier-based (para *Label Cleaning*)	Usa técnicas tradicionais de detecção de *outliers* (estatísticas, distâncias, etc.) para identificar rótulos que não seguem o padrão esperado.
Token Comparison	Comparação simples baseada em *tokens* ou *substrings* (ex.: nomes, endereços) para verificar a similaridade entre registros no processo de deduplicação.
Latent Space Comparison	Representa registros no espaço latente (por meio de *embeddings*) e compara seus vetores para medir a similaridade, sem depender diretamente de *tokens* ou campos específicos.
Learned Comparison	Usa modelos supervisionados (como classificadores binários) para determinar se dois registros representam a mesma entidade, com base em exemplos rotulados.
Statistic-based (*Outlier*)	Métodos estatísticos tradicionais como z-score, *boxplot*, média ± n desvios padrão, usados para identificar valores atípicos nos dados.
Distance-based (*Outlier*)	Mede a distância (euclidiana, Manhattan, etc.) entre registros ou pontos em um espaço de atributos para identificar aqueles que estão isolados dos demais.
Model-based (*Outlier* e *Imputation*)	Usa modelos preditivos (regressão, árvores, redes neurais) para estimar valores esperados; valores muito divergentes são considerados *outliers* ou imputados como correção.

Metodologia	Descrição
Data Cleaning Pipeline Generation	Criação automatizada de *pipelines* que orquestram várias etapas de *data cleaning* (imputação, deduplicação, detecção de outliers, correção de erros), de forma sequencial ou em paralelo.

Os métodos baseados em aprendizado de máquina são amplamente utilizados em tarefas como detecção de *outliers*, imputação, deduplicação e correção de atributos, permitindo a identificação de padrões e desvios nos dados. Já as abordagens de *deep learning*, especialmente *autoencoders* e modelos baseados em *Transformers*, têm sido empregadas em cenários mais complexos, como em dados textuais, semiestruturados e em processos avançados de correspondência entre entidades. Por sua vez, métodos estatísticos são utilizados principalmente em contextos em que a simplicidade, a interpretabilidade e o baixo custo computacional são prioritários.

O trabalho proposto por Hosseinzadeh *et al.* (2023) concentra-se em estratégias de limpeza aplicáveis a ambientes de *big data*. Os autores focaram em analisar as metodologias por meio de suas respectivas técnicas de implementação. As técnicas foram classificadas em cinco grupos:

- ***Machine Learning-based***
  - Usa modelos para prever e corrigir erros automaticamente. Tem alta escalabilidade, mas apresenta alta complexidade e baixo foco em usabilidade.
- ***Sample-based***
  - Realiza a limpeza em subconjuntos amostrais para reduzir custo e tempo, mantendo uma boa precisão nas consultas ou nos modelos.
- ***Expert-based***
  - Usa validação humana ou *crowdsourcing* para garantir a qualidade dos dados. Oferece alta acurácia, porém apresenta baixa escalabilidade e eficiência.
- ***Rule-based***
  - Baseado na aplicação de regras e restrições (como dependências funcionais, verificação de integridade, etc.). É simples e eficiente, mas pouco adaptável a dados muito grandes ou não estruturados.
- **Framework-based**
  - Integra diferentes técnicas (como aprendizado de máquina e regras) em plataformas otimizadas, geralmente com suporte a ambientes distribuídos (como MapReduce, Spark e outros).

Apesar dos avanços observados na literatura, a limpeza de dados ainda apresenta desafios significativos. Entre os principais, destaca-se a escassez de ferramentas de código aberto disponíveis para a realização dessa tarefa. O estudo realizado por Côté *et al.* (2024) identificou poucos artigos com pacotes disponíveis para replicação e apenas uma biblioteca com código aberto, que não era atualizada há dois anos. O que é um problema, visto que a

limpeza de dados é uma tarefa demorada e tediosa, que pode consumir até 80% do tempo de um cientista de dados (Côté *et al.*, 2024).

Além disso, muitas abordagens são desenvolvidas de forma isolada, focadas em problemas específicos, o que dificulta sua incorporação a arquiteturas mais amplas, como o *Data Mesh*. Côté *et al.*, 2024 evidenciou apenas duas estratégias para realizar *data cleaning* de forma holística. A ausência de metodologias consolidadas que integrem, de forma sistemática, os processos de limpeza aos fluxos de dados representa uma lacuna relevante na literatura.

A partir dos dois mapeamentos sistemáticos discutidos, consolidou-se um catálogo com aproximadamente 45 ferramentas e bibliotecas de código aberto voltadas à limpeza de dados, agrupadas por atividade (*feature cleaning*, *label cleaning*, *entity matching*, *outlier detection* e variações holísticas) e pela metodologia empregada. A análise das métricas de avaliação adotadas por essas soluções indica que a comunidade converge em torno de *Precision*, *Recall* e *F1-Score* nas tarefas de *feature cleaning*, com uso de *Accuracy* em *label cleaning* e, em cenários desbalanceados, de AUROC e PRAUC. Tanto o catálogo completo quanto a tabela de métricas por solução estão reunidos no Anexo A; descrições didáticas dessas métricas estão no Anexo B.

Um aspecto relevante dos dois mapeamentos, no entanto, é que ambos foram publicados entre 2023 e 2024 e concentram sua análise em técnicas clássicas, como aprendizado de máquina supervisionado, *autoencoders*, regras e *Transformers* anteriores a 2023. A emergência dos *Large Language Models* (LLMs) a partir desse mesmo ano introduziu um novo paradigma com capacidades que não estão sistematizadas na literatura de limpeza de dados. Essa lacuna motiva o mapeamento sistemático apresentado no Capítulo 3, dedicado exclusivamente ao uso de LLMs em tarefas de limpeza de dados.

Nesse contexto, torna-se fundamental investigar mecanismos que permitam incorporar a limpeza e a transformação de dados de maneira orgânica às arquiteturas descentralizadas, alinhando qualidade, governança e escalabilidade. Essa problemática constitui o foco central deste projeto de pesquisa, sendo aprofundada nos capítulos subsequentes.

2.4 Considerações Finais

Neste capítulo, apresentaram-se os conceitos fundamentais que norteiam este projeto de mestrado, abrangendo o contexto das Estatísticas Públicas, os princípios da arquitetura *Data Mesh* e os fundamentos da Limpeza de Dados. Com relação ao primeiro conceito, verificou-se que a produção de estatísticas oficiais envolve desafios crescentes relacionados à diversidade de fontes, ao volume de dados, à necessidade de tempestividade e à garantia de qualidade, especialmente diante da incorporação de dados em larga escala obtidos na internet. Nesse cenário, torna-se evidente a necessidade de estruturas organizacionais e tecnológicas capazes de promover a integração, a governança e a confiabilidade dos dados ao longo de todo o seu ciclo de vida.

A arquitetura *Data Mesh* foi discutida como uma alternativa promissora para lidar com tais desafios, ao propor a descentralização da gestão de dados por domínios, o tratamento dos dados como produtos e a adoção de mecanismos de governança federada apoiados por

plataformas de autoatendimento. No contexto das estatísticas públicas, essa abordagem apresenta potencial para alinhar a organização institucional dos institutos de pesquisa à estrutura dos produtos estatísticos, favorecendo a interoperabilidade, a escalabilidade e a autonomia dos domínios. Entretanto, ainda existem lacunas relacionadas à operacionalização prática desses princípios, especialmente no que se refere à padronização dos produtos de dados e à incorporação de processos de qualidade de dados de forma estruturada.

Por fim, a discussão sobre a limpeza de dados evidenciou que, apesar da ampla variedade de técnicas e metodologias existentes na literatura, ainda há limitações significativas quanto à integração dessas abordagens em arquiteturas de dados modernas e à disponibilidade de ferramentas consolidadas que as suportem em larga escala. Evidenciou-se também que os dois mapeamentos sistemáticos mais recentes sobre o tema precedem a emergência dos *Large Language Models* (LLMs) e, portanto, não contemplam o paradigma generativo introduzido por esses modelos, lacuna que motivou a condução do mapeamento sistemático apresentado no Capítulo 3.

Considerando que a qualidade dos dados é um fator crítico para a confiabilidade das estatísticas públicas, torna-se fundamental investigar estratégias que permitam incorporar processos de limpeza a arquiteturas descentralizadas, como o *Data Mesh*, tirando proveito das novas capacidades oferecidas pelas LLMs. Assim, os conceitos apresentados neste capítulo estabelecem a base teórica necessária ao desenvolvimento da proposta desta pesquisa, aprofundada nos capítulos a seguir.

Capítulo 3

Mapeamento Sistemático da Literatura

Este capítulo apresenta o Mapeamento Sistemático da Literatura (MSL) sobre o uso de *Large Language Models* (LLMs) para limpeza de dados realizado para apoiar a condução desta proposta de mestrado. Este MSL complementa os dois MSL discutidos no Capítulo 2, que cobrem trabalhos sobre técnicas clássicas de limpeza publicados até 2023 e tratam apenas de forma limitada os LLMs, cujo uso na área começou a ganhar tração a partir desse mesmo ano. Ao organizar o que há de mais recente nessa nova frente, este capítulo oferece *insights* para a elaboração da proposta de um *framework* de limpeza de dados em estatísticas públicas, apresentada nos capítulos seguintes. O MSL segue diretrizes amplamente adotadas em MSLs nas áreas de Engenharia de Software e Ciência de Dados (Petersen *et al.*, 2015) e está organizado em torno do seu objetivo, das questões de pesquisa, da estratégia de busca, dos critérios de seleção, do processo de extração de dados e da análise dos resultados.

3.1 Objetivo

O objetivo deste MSL é identificar e analisar abordagens que empregam técnicas de limpeza de dados, com especial atenção às que se baseiam em LLMs.

Embora MSLs anteriores já tenham mapeado técnicas tradicionais de limpeza de dados, avanços recentes em LLMs abrem novas possibilidades para automatizar e aprimorar esses processos. Dessa forma, este estudo busca sistematizar as abordagens existentes na literatura, classificando os métodos propostos, seus contextos de aplicação e os tipos de dados tratados. Os resultados do MSL visam fornecer uma visão atualizada das pesquisas na área, identificar lacunas de investigação e apoiar o desenvolvimento de estratégias de qualidade de dados para ambientes de dados complexos, incluindo o contexto da produção de estatísticas públicas.

3.2 Questões de Pesquisa (QP)

Com base no objetivo do estudo, definiram-se as seguintes questões de pesquisa (QP).

- **QP1:** Quais metodologias, técnicas, ferramentas e abordagens baseadas em LLMs são utilizadas na literatura para limpeza de dados?
- **QP2:** Em quais domínios ou contextos de aplicação as abordagens de limpeza de dados têm sido utilizadas?
- **QP3:** Quais tipos de dados são abordados pelas técnicas de limpeza de dados descritas na literatura?
- **QP4:** Como LLMs têm sido utilizados no processo de limpeza de dados (por exemplo, detecção de erros, imputação, normalização, deduplicação ou geração de regras)?
- **QP5:** Quais evidências são apresentadas sobre o impacto dessas técnicas na qualidade, confiabilidade, transparência e rastreabilidade dos dados?

3.3 Construção da *String* de Busca

A construção da *string* de busca foi realizada com base nas principais variações terminológicas utilizadas na literatura para descrever atividades de limpeza de dados. Inicialmente, foram identificadas palavras-chave representativas de cada conceito central do estudo, incluindo termos associados à qualidade dos dados, às tarefas de pré-processamento e limpeza, bem como às abordagens baseadas em LLMs.

Considerando que diferentes autores utilizam terminologias distintas para se referir a processos semelhantes, foram incluídas variações comuns encontradas na literatura científica, como *data cleaning*, *data cleansing*, *data wrangling*, *data scrubbing*, *data harmonization* e *data standardization*. De forma semelhante, para representar abordagens baseadas em modelos de linguagem foram consideradas expressões como *large language model*, *large language models*, *LLM* e *LLMs*.

A combinação desses termos foi realizada com operadores *booleanos* (`AND` e `OR`), de modo a ampliar a cobertura da busca e garantir a recuperação de estudos relevantes nas bases de dados para responder às QP definidas neste MSL.

```
("data cleaning" OR "data cleansing"
OR "data wrangling" OR "data scrubbing" OR "data harmonization"
OR "data standardization")
AND
("large language model" OR "large language models"
OR "LLM" OR "LLMs" OR "generative AI")
```

Vale ressaltar que a formatação dessa *string* foi adaptada às regras de cada base de dados.

3.4 Bases de Dados

As buscas foram realizadas em bases amplamente utilizadas na área de Ciência da Computação, que concentram grande parte da produção científica relacionada à engenharia de dados, à engenharia de software, à ciência de dados e à inteligência artificial.

- **Scopus**
- **IEEE Xplore**
- **ACM Digital Library**
- **Web of Science**
- **Science Direct**

3.4.1 Critérios de Seleção de Estudos

Para que um estudo seja considerado elegível para este MSL, é necessário que apresente relação direta com o objetivo da pesquisa, isto é, que aborde o uso de LLMs em tarefas de validação, pré-processamento ou limpeza de dados. Os critérios de seleção foram definidos para garantir a aderência às QPs e a consistência no processo de triagem dos estudos recuperados. Considerando que os estudos sobre o uso de LLMs em tarefas de limpeza de dados são recentes e se concentram majoritariamente nos últimos anos, não foi estabelecido um recorte temporal específico para a seleção dos estudos.

Critérios de Inclusão

Os estudos devem atender aos seguintes critérios:

- CI1: O estudo deve considerar tarefas de limpeza de dados, tais como detecção de erros, imputação de valores ausentes, deduplicação, correção de inconsistências ou geração de regras;
- CI2: O estudo deve utilizar LLMs como componente central da abordagem proposta;
- CI3: O estudo deve abordar dados estruturados, semiestruturados ou heterogêneos, em contextos relacionados à qualidade de dados;
- CI4: O estudo deve estar escrito em português ou inglês;
- CI5: O estudo deve estar disponível em texto completo.

Critérios de Exclusão

Serão excluídos os estudos que se enquadrarem em pelo menos um dos critérios abaixo:

- CE1: Estudos duplicados em diferentes bases de dados;
- CE2: Estudos não disponíveis em texto completo;
- CE3: Estudos que não apresentem descrição metodológica suficiente para compreensão da abordagem proposta;
- CE4: Estudos que mencionem LLMs apenas de forma periférica, sem que esses modelos desempenhem papel central na solução apresentada;
- CE5: Estudos voltados exclusivamente a tarefas tradicionais de Processamento de Linguagem Natural, como classificação de texto, sumarização ou análise de sentimento, sem relação direta com validação ou limpeza de dados;
- CE6: Estudos não revisados por pares.

3.4.2 Avaliação de Qualidade de Estudos

Após a aplicação dos critérios de inclusão e exclusão, os estudos selecionados foram submetidos a uma avaliação de qualidade, com o objetivo de apoiar a interpretação crítica dos resultados e verificar o grau de consistência metodológica dos trabalhos analisados. Diferentemente dos critérios de elegibilidade, esta etapa não tem como finalidade excluir automaticamente estudos, mas sim qualificar a análise do conjunto final de estudos.

Para isso, os estudos foram avaliados nos seguintes aspectos:

- O estudo aborda de forma clara uma tarefa de limpeza de dados voltada à melhoria da qualidade dos dados?
- O estudo utiliza LLMs como componente central da abordagem proposta?
- O estudo descreve adequadamente o modelo utilizado, a estratégia adotada e a integração do LLM ao sistema ou ao fluxo de dados?
- O estudo apresenta descrição do tipo de dado, do domínio de aplicação e do contexto experimental?
- O estudo inclui uma avaliação empírica da abordagem proposta?
- O estudo reporta métricas quantitativas, avaliação qualitativa, estudo de caso ou comparação com *baselines*?
- O estudo discute limitações, *trade-offs*, escalabilidade ou ameaças à validade?
- O estudo disponibiliza código, artefatos ou informações que favoreçam a replicação ou a reprodutibilidade?

3.5 Formulário de Extração

Considerando as QPs definidas no planejamento do MSL, utilizou-se o formulário de extração de dados mostrado na Tabela 3.1. A planilha completa, com os dados extraídos de todos os estudos incluídos, está disponível publicamente.[1]

Tabela 3.1: *Formulário de Extração de Dados*

Campo	Descrição	QP
DOI	Identificador digital do estudo.	-
Título	Título do estudo.	-
Nome da Técnica	Nome da técnica, sistema, método ou *framework* proposto no estudo (ex.: ZeroDC).	QP1
Autores	Nome dos autores.	-
Ano	Ano de publicação.	-

Continua na próxima página

[1] https://docs.google.com/spreadsheets/u/2/d/e/2PACX-1vRuYlqKYzmIIx2O99qc70_YVZ4EB2KUftrZWIzAhpLgumRzE9qvhux_YbRjre9m-K-Dz6KtfmvAT4cm/pubhtml

Continuação da Tabela 3.1

Campo	Descrição	QP
Fonte	Base de dados ou veículo de publicação (periódico ou conferência).	-
Link do Artigo	Link para acesso ao estudo avaliado.	-
Link do Código Fonte	Link para o código ou repositório associado ao estudo (quando disponível).	-
Objetivo do Estudo	Propósito principal da pesquisa apresentada no artigo.	QP1
Abordagem / Técnica Proposta	Metodologia, técnica ou ferramenta baseada em LLM utilizada para limpeza de dados.	QP1
Domínio de Aplicação	Área ou contexto de aplicação do estudo (ex.: saúde, governo, finanças, ciência aberta, etc.).	QP2
Tipo de Dados	Tipo de dados tratados no estudo (ex.: tabular, texto, dados da web, registros administrativos, dados semiestruturados, etc.).	QP3
Tarefa de Limpeza com LLM	Tipo de tarefa realizada com LLM (ex.: detecção de erros, imputação, deduplicação, correção de inconsistências, geração de regras, etc.).	QP4
LLM Utilizada	Modelo ou família de modelos empregada na abordagem (ex.: GPT, Claude, Gemini, Llama, Mistral, etc.).	QP4
Estratégia de Uso da LLM	Estratégia adotada para empregar a LLM na tarefa proposta (ex.: *zero-shot*, *few-shot*, *chain-of-thought*, *fine-tuning*, *agent-based*, RAG, etc.).	QP4
Implementação da LLM no Sistema	Detalhes de como a LLM é integrada ao sistema ou ao fluxo de dados, incluindo arquitetura, pipeline, etapas do processo e interação com outros componentes.	QP4
Nível de Automação	Grau de automação da abordagem, indicando se o processo é totalmente automatizado ou híbrido, com participação humana no ciclo.	QP4, QP5
Considerações sobre Escalabilidade	Discussão sobre a escalabilidade ou aplicabilidade da abordagem em diferentes domínios, conjuntos de dados, tipos de dados ou volumes de dados.	QP5
Desafios e Limitações	Dificuldades, limitações ou *trade-offs* relatados no uso de LLMs para limpeza de dados.	QP5
Métricas de Avaliação	Métricas utilizadas para avaliar o desempenho da técnica (ex.: precisão, *recall*, acurácia, F1-score, etc.).	QP5
Resultados Principais	Principais conclusões e evidências reportadas sobre o impacto das técnicas na qualidade, confiabilidade, transparência e rastreabilidade dos dados.	QP5

3.6 Seleção de Estudos

O MSL foi conduzido conforme o protocolo PRISMA 2020 (Page *et al.*, 2021), que define um fluxo padronizado para a identificação, triagem e inclusão de estudos em MSLs. A Figura 3.1 apresenta o fluxograma PRISMA adotado neste trabalho, incluindo o número de registros em cada etapa, os principais motivos de exclusão e o conjunto final de estudos.

A busca inicial nas bases de dados retornou 573 registros, distribuídos em cinco bases:

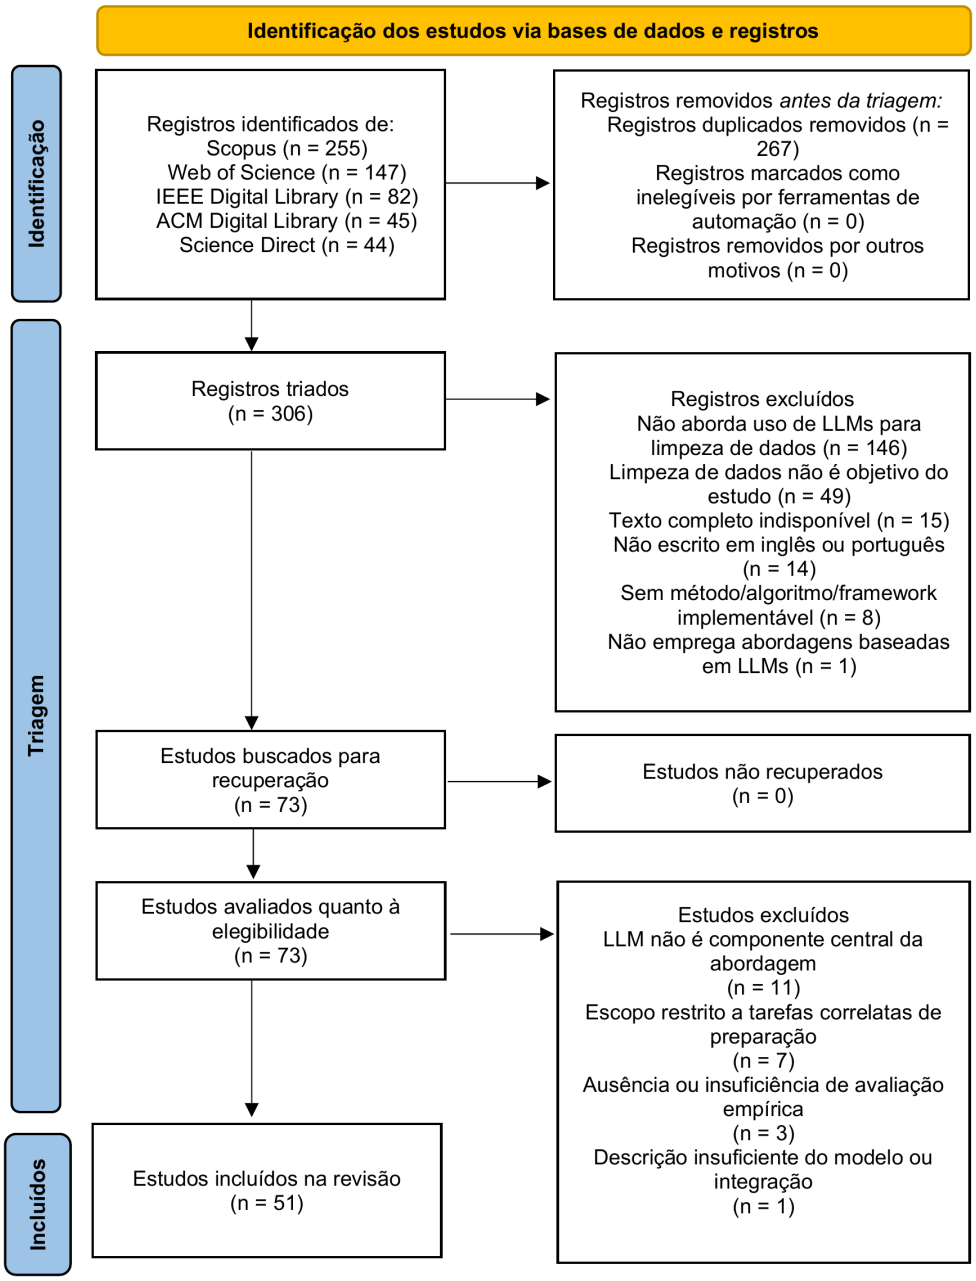


Figura 3.1: *Fluxograma PRISMA 2020 do processo de seleção de estudos.*

Scopus (255), ISI Web of Science (147), IEEE Digital Library (82), ACM Digital Library (45) e Science@Direct (44). A Figura 3.2 ilustra essa distribuição.

Após a remoção de 267 estudos duplicados, os 306 restantes passaram pela etapa de triagem, na qual títulos e resumos foram analisados conforme critérios de inclusão e exclusão. Nessa fase, 233 estudos foram descartados. O motivo mais comum foi a ausência do uso de LLMs na limpeza de dados (146 estudos), o que indica que a estratégia de busca retornou muitos resultados fora do escopo. Em seguida, 49 estudos foram excluídos por não terem a limpeza de dados como objetivo principal, focando apenas em atividades

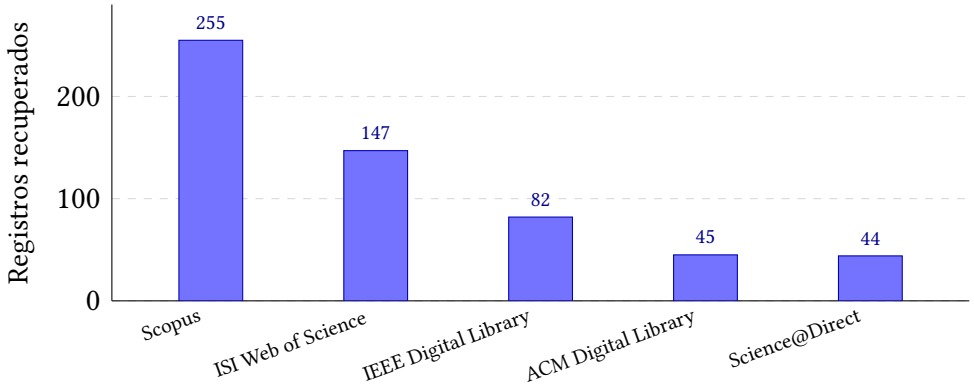


Figura 3.2: *Distribuição dos 573 registros identificados após a execução da string de busca nas bases de dados.*

relacionadas, como padronização, transformação, integração ou anotação de dados. Outros motivos incluíram: indisponibilidade do texto completo (15 estudos), idioma diferente de inglês ou de português (14), ausência de um método ou de um *framework* aplicável na prática (8) e não utilização de abordagens baseadas em LLMs (1). Ao final dessa etapa, 73 estudos foram encaminhados para leitura completa.

Na fase de elegibilidade, esses 73 estudos foram lidos na íntegra e avaliados conforme os critérios de qualidade obrigatórios definidos no protocolo (ver Seção 3.4.2). Como resultado, 22 estudos foram rejeitados. Entre os principais motivos estão: (i) a LLM não era parte central da solução, sendo utilizada apenas como apoio, enquanto a limpeza de dados era realizada por métodos tradicionais; (ii) descrição pouco clara do modelo, da estratégia adotada ou da forma como o LLM era integrado ao processo, dificultando o entendimento e a reprodução da abordagem; (iii) foco em tarefas relacionadas, como integração de esquemas, harmonização semântica ou orquestração de *pipelines*, sem contribuição direta para atividades centrais de limpeza de dados, como detecção e correção de erros, imputação, deduplicação ou geração de regras; e (iv) ausência de uma avaliação empírica alinhada às contribuições propostas. Ao final dessa fase, 51 estudos foram aprovados para responder às QPs do MSL.

A Tabela 3.2 apresenta a lista completa dos estudos analisados, incluindo seus respectivos IDs, títulos e referências.

Tabela 3.2: *Estudos primários incluídos no MSL.*

ID	Título	Referência
S1	A Task-Driven Interpretable Data Cleaning Framework Based on LLM	(Fan *et al.*, 2026)
S2	A Zero-Training Data Cleaning System With Large Language Models	(Yang *et al.*, 2026)
S3	A Zero-Training Error Correction System with Large Language Models	(Yangyang Wu *et al.*, 2025)
S4	Are Large Language Models Good Data Preprocessors?	(Meguellati *et al.*, 2025)

Continua na próxima página

Continuação da Tabela 3.2

ID	Título	Ref.
S5	Are We There Yet? Notes Towards Benchmarking an Experimental AI-Assisted Workflow for Humanities Data Cleaning and Reconciliation	(McCarthy, 2026)
S6	Ask Language Model to Clean Your Noisy Translation Data	(Bolding *et al.*, 2023)
S7	AutoClean: LLMs Can Prepare Their Training Corpus	(Shen *et al.*, 2025)
S8	AutoDCWorkflow: LLM-based Data Cleaning Workflow Auto-Generation and Benchmark	(L. Li *et al.*, 2025)
S9	AutoDW-TS: Automated Data Wrangling for Time-Series Data	(L. Liu, Hasegawa, Sampat, Bahrami *et al.*, 2025)
S10	AutoDW: Automatic Data Wrangling Leveraging Large Language Models	(L. Liu, Hasegawa, Sampat, Xenochristou *et al.*, 2024)
S11	BClean+: A Bayesian Data Cleaning System With Automated Prior Generation	(Han *et al.*, 2026)
S12	Can an LLM Find Its Way Around a Spreadsheet?	(C.-T. Lee *et al.*, 2025)
S13	CatDB: Data-catalog-guided, LLM-based Generation of Data-centric ML Pipelines	(Fathollahzadeh *et al.*, 2025a)
S14	CitySTI 2024 System: Tabular Data to KG Matching using LLMs	(Yue e Jimenez-Ruiz, 2024)
S15	CleanMAP: Distilling Multimodal LLMs for Confidence-Driven Crowdsourced HD Map Updates	(Shaw *et al.*, 2025)
S16	Cleaning Semi-Structured Errors in Open Data Using Large Language Models	(Mondal *et al.*, 2024)
S17	CodeGenWrangler: Data Wrangling task automation using Code-Generating Models	(Akella e Narayanam, 2025a)
S18	Dango: A Mixed-Initiative Data Wrangling System using Large Language Model	(Chen *et al.*, 2025)
S19	Data Cleaning Using Large Language Models	(S. Zhang *et al.*, 2025)
S20	Data Wrangling Task Automation Using Code-Generating Language Models	(Akella e Narayanam, 2025b)
S21	Demonstrating CatDB: LLM-based Generation of Data-centric ML Pipelines	(Fathollahzadeh *et al.*, 2025b)
S22	Directions Towards Efficient and Automated Data Wrangling with Large Language Models	(Z. Zhang *et al.*, 2024)
S23	GARF+: self-supervised and interpretable data cleaning with sequence generative adversarial networks	(Peng *et al.*, 2025)
S24	GIDCL: A Graph-Enhanced Interpretable Data Cleaning Framework with Large Language Models	(Yan *et al.*, 2024)
S25	Improving Dietary Supplement Information Retrieval: Development of a Retrieval-Augmented Generation System With Large Language Models	(Hou *et al.*, 2025)
S26	Improving the Quality of Diabetic Data with Large Language Model-driven Cleaning Techniques	(Biradar *et al.*, 2024)
S27	Integration of Machine Learning and Large Language Models for Scalable Data Cleaning	(Dawale *et al.*, 2025)

Continua na próxima página

Continuação da Tabela 3.2

ID	Título	Ref.
S28	IterClean: An Iterative Data Cleaning Framework with Large Language Models	(Ni, K. Zhang, Miao, X. Zhao, Yangyang Wu e Yin, 2024)
S29	KnowTrans: Boosting Transferability of Data Preparation LLMs via Knowledge Augmentation	(Ge *et al.*, 2025)
S30	LLM-Assisted Code Cleaning for Training Accurate Code Generators	(Jain *et al.*, 2024)
S31	LLMClean: Context-Aware Tabular Data Cleaning via LLM-Generated OFDs	(Biester *et al.*, 2025)
S32	Leveraging Generative Artificial Intelligence for Enhancing the Quality of Product Data	(Niemir *et al.*, 2025)
S33	Leveraging Structured and Unstructured Data for Tabular Data Cleaning	(Mehra e Rezig, 2024)
S34	LinkTransformer: A Unified Package for Record Linkage with Transformer Language Models	(Arora e Dell, 2024)
S35	MULTI-NEWS+: Cost-efficient Dataset Cleansing via LLM-based Data Annotation	(Choi *et al.*, 2024)
S36	Metadata Generation and Evaluation using LLMs - Case Study on Canonical Titles	(Zhu *et al.*, 2025)
S37	Multi-Agent Data Cleaning Framework of Solid-State Batteries using Large Language Models	(Z. Wang *et al.*, 2026)
S38	POI Extraction From Digital City: An Engineering Exploration With Large-Language Models	(Sun *et al.*, 2025)
S39	RetClean: Retrieval-Based Data Cleaning Using LLMs and Data Lakes	(Naeem *et al.*, 2024)
S40	Smartphone Usage Data Cleaning Using LLM-Based Processing	(Zaeifi e Lin, 2024)
S41	Sure! Here's a Short and Concise Title for Your Paper: Contamination in Generated Text Detection Benchmarks	(Dingfelder e Riess, 2026)
S42	Tailoring the Shapley Value for In-context Example Selection towards Data Wrangling	(Liang *et al.*, 2025)
S43	Token Cleaning: Fine-Grained Data Selection for LLM Supervised Fine-Tuning	(Pang *et al.*, 2025)
S44	Towards Efficient Data Wrangling with LLMs using Code Generation	(X. Li e Döhmen, 2024)
S45	Using Brand Knowledge Bases and LLM Agents to Enhance E-commerce Retailers' Catalog Quality	(Ceker *et al.*, 2026)
S46	Using Large Language Models for Data Cleaning: An Evaluation of ChatGPT-4o's Performance	(Ilhanli *et al.*, 2025)
S47	Using Large Language Models to Improve Product Information in E-commerce Catalogs	(Luo *et al.*, 2025)
S48	Using social media listening to identify the real-world challenges faced by dog owners globally when administering oral medications	(Tarrant *et al.*, 2025)
S49	VDSAgents: A PCS-Guided Multi-Agent System for Veridical Data Science Automation	(Y. Jiang *et al.*, 2026)

Continua na próxima página

Continuação da Tabela 3.2

ID	Título	Ref.
S50	Zero-Shot Error Detection via Performance-Guided Rule Generation with LLMs	(W. Wu e F. Liu, 2025)
S51	ZeroED: Hybrid Zero-shot Error Detection through Large Language Model Reasoning	(Ni, K. Zhang, Miao, X. Zhao, Yangyang Wu, Y. Wang *et al.*, 2025)

3.7 Resultados e Discussão

Os 51 estudos primários selecionados no MSL estão concentrados em um período bastante recente. Embora a busca não tenha aplicado restrição de ano, todos os trabalhos encontrados foram publicados entre 2023 e 2026, com maior concentração em 2024 e 2025, conforme ilustrado na Figura 3.3.

Esse comportamento indica que o uso de LLMs na limpeza de dados é uma linha de pesquisa emergente, que ganhou força principalmente nos últimos dois anos. Esse avanço está relacionado à evolução e à maior disponibilidade de modelos de linguagem, como GPT-4, Claude, Llama e Gemma, além da difusão de técnicas mais acessíveis, como *prompting* e *fine-tuning* com menor custo e maior facilidade de uso.

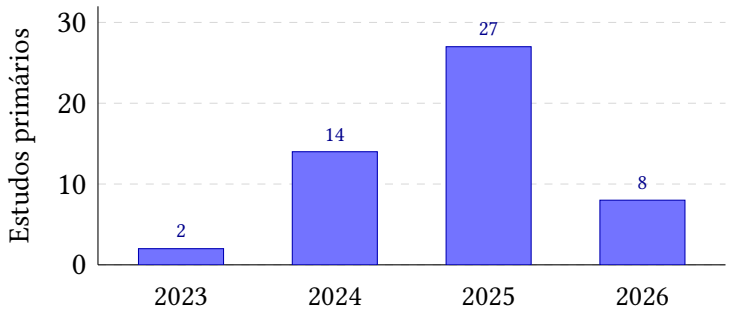


Figura 3.3: *Distribuição temporal dos 51 estudos primários incluídos no mapeamento.*

3.7.1 QP1: Quais metodologias, técnicas, ferramentas e abordagens baseadas em LLMs são utilizadas na literatura para limpeza de dados?

A análise das estratégias de uso de LLMs nos 51 estudos, apresentada na Figura 3.4, mostra uma preferência clara por abordagens que não exigem treinamento adicional dos modelos. As estratégias mais comuns são o *few-shot* ou *in-context learning* (30 estudos), o *zero-shot* (23 estudos) e a geração de código ou de regras executáveis (21 estudos). Por outro lado, o *fine-tuning* aparece em apenas 13 dos 51 estudos, o que indica que a maioria dos trabalhos opta por utilizar diretamente modelos já pré-treinados. O treinamento adicional é adotado principalmente em situações em que a tarefa demanda conhecimento de domínio

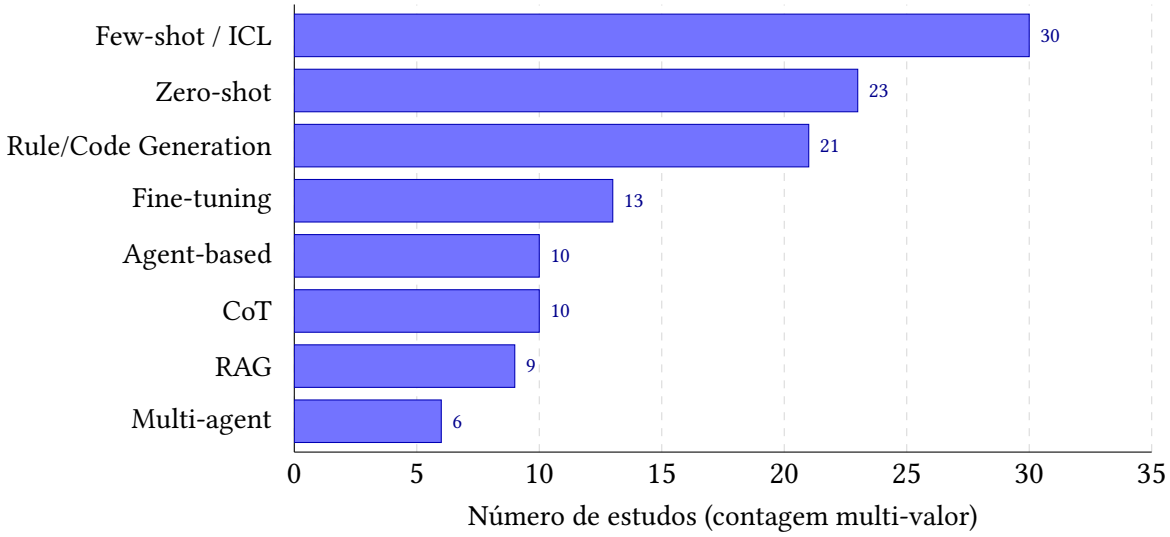


Figura 3.4: *Frequência das estratégias de uso das LLMs nos 51 estudos primários. Um mesmo estudo pode combinar múltiplas estratégias, por isso o somatório ultrapassa o total de estudos.*

mais específico, que não pode ser obtido apenas por meio de instruções ou exemplos fornecidos no momento da execução.

O ***few-shot***, ou *in-context learning*, consiste em fornecer à LLM alguns exemplos de dados rotulados diretamente no *prompt*. Trata-se da estratégia mais adotada, pois combina baixo custo com flexibilidade, permitindo adaptar o comportamento do modelo a um *dataset* ou a um tipo específico de erro apenas por meio do ajuste dos exemplos. Entre as técnicas que utilizam essa abordagem estão ZeroEC (S3) (Yangyang Wu *et al.*, 2025), AutoDCWorkflow (S8) (L. Li *et al.*, 2025), IterClean (S28) (Ni, K. Zhang, Miao, X. Zhao, Yangyang Wu e Yin, 2024) e o estudo (S42) (Liang *et al.*, 2025), que aborda a seleção ótima de exemplos para *prompts* por meio de um algoritmo denominado CSV (*Constrained Shapley Value*). Este último se destaca por tratar explicitamente da escolha dos exemplos mais adequados, considerando o problema de otimização do *prompt*, e por endereçar uma lacuna comum aos demais estudos.

O ***zero-shot*** corresponde à execução da tarefa exclusivamente a partir da instrução fornecida no *prompt*, sem o uso de exemplos. Essa abordagem é comum em estudos que lidam com erros de formatação, tipos de dados e valores categóricos semanticamente equivalentes, nos quais o conhecimento geral do LLM é suficiente. Cocoon (S19) (S. Zhang *et al.*, 2025), CatDB (S13) (Fathollahzadeh *et al.*, 2025a), LEAD (S50) (W. Wu e F. Liu, 2025) e ZeroED (S51) (Ni, K. Zhang, Miao, X. Zhao, Yangyang Wu, Y. Wang *et al.*, 2025) ilustram o uso de *zero-shot* em cenários de detecção e correção de células em tabelas. Os dois últimos destacam-se por utilizar explicitamente essa técnica como diferencial, oferecendo pipelines que não requerem qualquer esforço prévio de anotação.

A **geração de código ou regras** é uma técnica em que o LLM produz código executável como saída, em vez de atuar diretamente sobre as células dos dados. Essa estratégia é frequentemente combinada com *zero-shot* ou *few-shot* e consta em 21 estudos. Cocoon (S19) (S. Zhang *et al.*, 2025), por exemplo, gera consultas SQL comentadas que podem ser reexecutadas. Já CodeGenWrangler (S17) (Akella e Narayanam, 2025a) e TradeSweep

(S12) (C.-T. Lee *et al.*, 2025) produzem código em Python, enquanto BClean+ (S11) (Han *et al.*, 2026) e GARF+ (S23) (Peng *et al.*, 2025) geram regras de reparo no formato de dependências funcionais ou padrões de dados. Essa combinação é particularmente interessante, pois resulta em *pipelines* auditáveis e reutilizáveis, em contraste com abordagens em que o LLM corrige diretamente as células na memória da sessão de inferência.

O ***fine-tuning*** aparece em 13 estudos. Diferentemente das estratégias anteriores, que utilizam o modelo pré-treinado sem modificações, aqui o próprio modelo é ajustado com dados específicos da tarefa. Essa abordagem é comum quando o conhecimento necessário para a limpeza é específico demais para ser transmitido apenas por meio de um *prompt*. CleanMAP (S15) (Shaw *et al.*, 2025) adapta um modelo multimodal a partir de imagens de mapas rotuladas manualmente; ZEROMATCH (S22) (Z. Zhang *et al.*, 2024) utiliza o T5, um modelo de linguagem aberto e mais leve que os empregados nos demais estudos, para identificar registros equivalentes entre tabelas; GARF+ (S23) (Peng *et al.*, 2025) ajusta o modelo para diferentes *datasets* tabulares; e KnowTrans (S29) (Ge *et al.*, 2025) associa um ajuste específico a cada *dataset* de interesse. O número relativamente reduzido de estudos nessa categoria sugere que o *fine-tuning* tem sido reservado para cenários em que as estratégias sem treinamento adicional apresentam desempenho insuficiente.

As abordagens **baseadas em agentes** e **multiagentes** aparecem em 10 e 6 estudos, respectivamente. Um agente LLM é configurado para operar em ciclos: em vez de produzir uma única resposta, ele decide uma ação, executa uma ferramenta externa (como executar código ou consultar uma base de dados), observa o resultado e ajusta seu próximo passo com base nesse *feedback*. Essa capacidade permite lidar com tarefas que exigem múltiplas etapas ou validação intermediária. TR-Agent (S1) (Fan *et al.*, 2026), AutoDCWorkflow (S8) (L. Li *et al.*, 2025), IterClean (S28) (Ni, K. Zhang, Miao, X. Zhao, Yangyang Wu e Yin, 2024) e VDSAgents (S49) (Y. Jiang *et al.*, 2026) exemplificam essa abordagem. Na variação multiagente, diferentes agentes especializam-se em subtarefas, como detecção, correção e validação, como observado em VDSAgents (S49) (Y. Jiang *et al.*, 2026), MULTI-NEWS+ (S35) (Choi *et al.*, 2024) e AutoClean (S7) (Shen *et al.*, 2025). Essas abordagens apresentam forte sinergia com a geração de código ou de regras, já que os agentes frequentemente produzem e executam essas saídas como parte de seu ciclo de raciocínio. AutoClean (S7) (Shen *et al.*, 2025), Dango (S18) (Chen *et al.*, 2025), TETL (S37) (Z. Wang *et al.*, 2026) e VDSAgents (S49) (Y. Jiang *et al.*, 2026) ilustram essa combinação.

O ***chain-of-thought*** e o ***retrieval-augmented generation*** (RAG) aparecem em 10 e 9 estudos, respectivamente, geralmente combinados com outras estratégias. O *chain-of-thought* estrutura o raciocínio do LLM em etapas intermediárias antes da resposta final, sendo útil em tarefas que envolvem múltiplas decisões encadeadas, como em ZeroDC (S2) (Yang *et al.*, 2026), ZeroEC (S3) (Yangyang Wu *et al.*, 2025) e MULTI-NEWS+ (S35) (Choi *et al.*, 2024). Já o RAG recupera contextos externos — como tabelas de referência, documentos ou bases de conhecimento — antes de consultar o LLM, sendo empregado em abordagens como RetClean (S39) (Naeem *et al.*, 2024), iDISK2.0-RAG (S25) (Hou *et al.*, 2025) e BEAVER (S33) (Mehra e Rezig, 2024). Essa estratégia é especialmente útil quando o conhecimento necessário não está presente no treinamento do modelo.

Um padrão recorrente no MSL é a combinação de múltiplas estratégias em um mesmo sistema. RetClean (S39) (Naeem *et al.*, 2024), por exemplo, utiliza *zero-shot*, *few-shot*, RAG

e *fine-tuning* em diferentes situações. VDSAgents (S49) (Y. Jiang *et al.*, 2026) adota uma arquitetura multiagente com geração de código, enquanto ZeroDC (S2) (Yang *et al.*, 2026) combina *zero-shot*, *few-shot*, *chain-of-thought* e geração de regras em um único *pipeline*. Na prática, isso evidencia que nenhuma estratégia isolada é suficiente para cobrir todos os tipos de problemas presentes em um *dataset*, e que a literatura tem evoluído em direção a soluções híbridas que integram múltiplas abordagens.

3.7.2 QP2: Em quais domínios ou contextos de aplicação as abordagens de limpeza de dados têm sido utilizadas?

A distribuição dos estudos por domínio, apresentada na Figura 3.5, indica que a maior parte dos trabalhos foi avaliada em cenários genéricos, sem foco em um setor específico. Dos 51 estudos analisados, 32 (aproximadamente 63%) foram classificados como multi-domínio, ou seja, validados em três ou mais conjuntos de dados de áreas distintas. Os demais estudos estão distribuídos de forma bastante dispersa entre diferentes domínios, como *e-commerce* e varejo (5 estudos), saúde (4), academia e ciência (4), transportes (2), jurídico (1), redes sociais (1), energia (1) e outros (1). Um ponto importante é a ausência de estudos voltados ao contexto de governo e estatísticas públicas, que é justamente o foco desta pesquisa, evidenciando uma lacuna relevante na literatura.

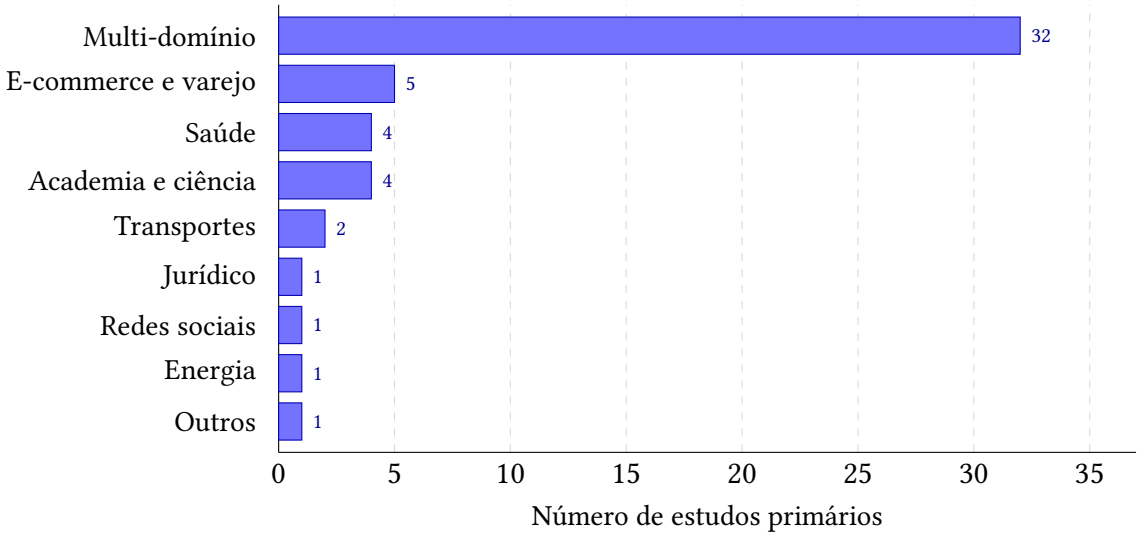


Figura 3.5: *Distribuição dos 51 estudos primários por domínio de aplicação.*

A categoria **multi-domínio** reúne os estudos que avaliam suas abordagens em diferentes *benchmarks*, ou seja, conjuntos de dados amplamente utilizados como referência para comparar técnicas de limpeza. Entre os mais recorrentes estão Hospital, Flights, Beers, Rayyan e Movies, além de outros como Tax e IMDB. Esses conjuntos são herdados de trabalhos clássicos da área e permitem uma comparação mais padronizada entre diferentes abordagens.

Entre os estudos multi-domínio, destacam-se Cocoon (S19) (S. Zhang *et al.*, 2025), ZeroEC (S3) (Yangyang Wu *et al.*, 2025), BClean+ (S11) (Han *et al.*, 2026), IterClean (S28) (Ni, K. Zhang, Miao, X. Zhao, Yangyang Wu e Yin, 2024), ZeroED (S51) (Ni, K. Zhang,

Miao, X. Zhao, Yangyang Wu, Y. Wang *et al.*, 2025) e RetClean (S39) (Naeem *et al.*, 2024). Esses trabalhos foram avaliados em cinco ou mais *benchmarks* e apresentam métricas comparáveis, o que facilita a identificação de soluções mais promissoras para novos cenários. Além disso, estudos como AutoDCWorkflow (S8) (L. Li *et al.*, 2025) e AutoDW (S10) (L. Liu, Hasegawa, Sampat, Xenochristou *et al.*, 2024) ampliam essa análise ao construírem seus próprios conjuntos de dados, permitindo avaliar, de forma mais direta, a capacidade de generalização entre domínios.

As categorias de ***e-commerce*** e **saúde** concentram a maior parte dos estudos fora do grupo multi-domínio. No contexto de *e-commerce*, o foco recorrente é a padronização de informações de produtos, como nomes, categorias e especificações, abordagem presente em S32 (Niemir *et al.*, 2025), S45 (Ceker *et al.*, 2026) e S47 (Luo *et al.*, 2025). Além disso, o TradeSweep (S12) (C.-T. Lee *et al.*, 2025) trata dados financeiros ligados a cadeias de suprimento, enquanto S36 (Zhu *et al.*, 2025) aplica técnicas semelhantes à padronização de títulos de vagas de emprego. Na área da saúde, o iDISK2.0-RAG (S25) (Hou *et al.*, 2025) constrói um grafo de conhecimento sobre suplementos alimentares; S26 (Biradar *et al.*, 2024) e S46 (Ilhanli *et al.*, 2025) tratam, respectivamente, registros de pacientes diabéticos e a avaliação do ChatGPT-4o sobre prontuários médicos; e S48 (Tarrant *et al.*, 2025) analisa dados de redes sociais relacionados à administração de medicamentos veterinários.

Os estudos no domínio de **academia e ciência** apresentam características mais específicas. Entre eles, o PRISM (S5) (McCarthy, 2026) trata da unificação de registros bibliográficos históricos; o C-MTNT (S6) (Bolding *et al.*, 2023) limpa dados utilizados no treinamento de sistemas de tradução automática; o S30 (Jain *et al.*, 2024) se concentra em bases de código-fonte usadas em tarefas de geração de código; e o MULTI-NEWS+ (S35) (Choi *et al.*, 2024) atua na filtragem de dados em tarefas de sumarização multi-documento. O domínio jurídico, por sua vez, é bastante limitado, com apenas um estudo, o LLMFixer (S16) (Mondal *et al.*, 2024), voltado à correção de erros estruturais em documentos jurídicos. De modo geral, esses trabalhos tendem a propor soluções mais especializadas, com menor potencial de reutilização em outros contextos.

Por fim, os domínios de **transportes, redes sociais e energia** apresentam baixa representatividade. Nesses casos, as aplicações envolvem tarefas bastante específicas: o CleanMAP (S15) (Shaw *et al.*, 2025) realiza a seleção de imagens confiáveis para mapas de alta definição; o DCPE (S38) (Sun *et al.*, 2025) atua na identificação de pontos de interesse a partir de dados urbanos; o S4 (Meguellati *et al.*, 2025) trata da limpeza de textos em redes sociais para detecção de persuasão em memes; e o TETL (S37) (Z. Wang *et al.*, 2026) aplica detecção de anomalias em séries temporais de baterias de veículos elétricos. Devido à natureza dos dados envolvidos, essas soluções geralmente exigem adaptações significativas para serem aplicadas em outros domínios. Ainda assim, muitas delas compartilham padrões arquiteturais, como o uso de agentes e geração de código, que podem ser aproveitados no desenvolvimento do framework proposto.

3.7.3 QP3: Quais tipos de dados são abordados pelas técnicas de limpeza de dados descritas na literatura?

A distribuição dos tipos de dados tratados pelos estudos primários, apresentada na Figura 3.6, evidencia o predomínio de dados tabulares, presentes em 33 dos 51 estudos

(aproximadamente 65%). Os demais tipos aparecem em menor quantidade, incluindo texto (7 estudos), dados semi-estruturados (3), multimodais (3), séries temporais (2), além de ocorrências isoladas em imagem, grafos e código. Esse cenário acompanha a tradição da área de qualidade de dados, historicamente voltada a tabelas, e também reflete o formato mais comum em bases de dados estatísticas públicas e em sistemas de geração de indicadores.

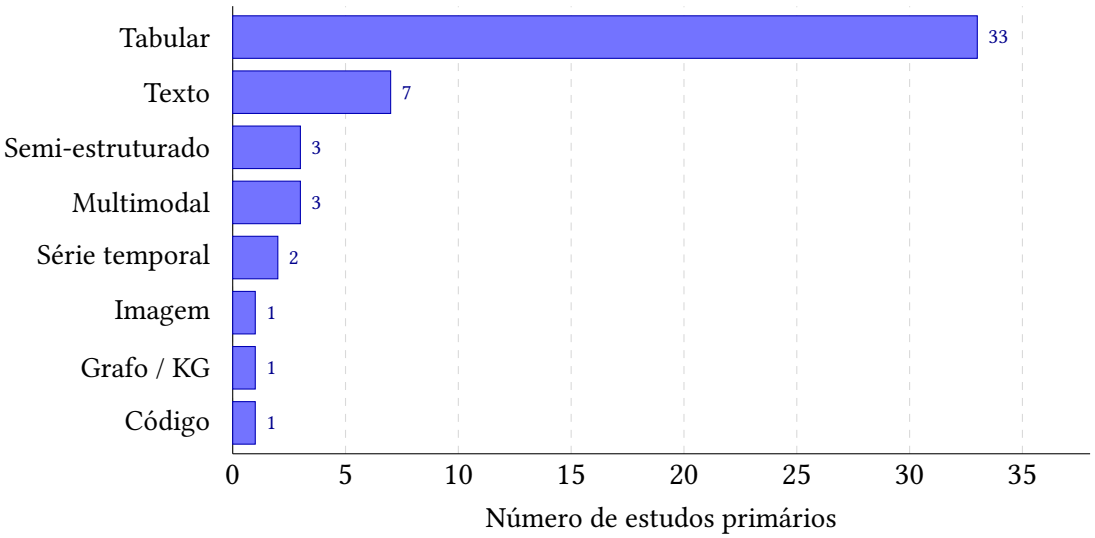


Figura 3.6: *Distribuição dos 51 estudos primários por tipo de dado tratado.*

Os estudos que tratam de **dados tabulares** constituem o núcleo da literatura analisada. Essa categoria inclui tabelas organizadas em linhas e colunas, provenientes tanto de *benchmarks* amplamente utilizados quanto de bases de dados reais, como Hospital, Flights, Beers, PPP, Tax e IMDB. Os trabalhos mais relevantes para a proposta de mestrado combinam bons resultados empíricos com propostas reutilizáveis, destacando-se Cocoon (S19) (S. Zhang *et al.*, 2025), ZeroEC (S3) (Yangyang Wu *et al.*, 2025), BClean+ (S11) (Han *et al.*, 2026), ZeroDC (S2) (Yang *et al.*, 2026) e ZeroED (S51) (Ni, K. Zhang, Miao, X. Zhao, Yangyang Wu, Y. Wang *et al.*, 2025), todos avaliados em múltiplos conjuntos de dados e com código aberto disponível.

Um subgrupo especialmente relevante é o dos estudos que complementam as tabelas com informações adicionais. BEAVER (S33) (Mehra e Rezig, 2024), por exemplo, utiliza documentos textuais externos por meio de RAG, enquanto CatDB (S13) (Fathollahzadeh *et al.*, 2025a) explora catálogos de dados para fornecer contexto semântico. Esse tipo de integração é particularmente importante no cenário das estatísticas públicas, em que os dados dependem fortemente de metadados e de regras de negócio. IterClean (S28) (Ni, K. Zhang, Miao, X. Zhao, Yangyang Wu e Yin, 2024) também se destaca por operar com um número reduzido de exemplos rotulados, o que reduz o esforço de adaptação a novos conjuntos de dados.

Os estudos voltados a **dados textuais** constituem um segundo grupo relevante, embora menor. Eles incluem aplicações como a limpeza de pares de tradução (C-MTNT (S6) (Bolding *et al.*, 2023)), a filtragem de documentos em bases de notícias (MULTI-NEWS+ (S35) (Choi *et al.*, 2024)) e o processamento em nível de *tokens* (Token Cleaning (S43) (Pang *et al.*, 2025)). Além disso, há trabalhos que tratam dados de redes sociais, removendo

ruídos e duplicações em textos pouco estruturados.

A categoria de **dados semi-estruturados** reúne estudos que lidam com formatos como XML, JSON e HTML. Exemplos incluem o LLMFixer (S16) (Mondal *et al.*, 2024), que corrige erros estruturais em documentos XML, o AutoClean (S7) (Shen *et al.*, 2025), que atua em páginas HTML, e estudos voltados à limpeza de descrições de produtos em *e-commerce*. Esses trabalhos são especialmente relevantes para o contexto do projeto, já que muitos dados institucionais são disponibilizados nesses formatos.

As **demais categorias** apresentam baixa representatividade e abrangem tipos de dados mais específicos. Entre elas estão séries temporais (AutoDW-TS (S9) (L. Liu, Hasegawa, Sampat, Bahrami *et al.*, 2025) e TETL (S37) (Z. Wang *et al.*, 2026)), imagens (CleanMAP (S15) (Shaw *et al.*, 2025)), dados multimodais (DCPE (S38) (Sun *et al.*, 2025), Brand KB (S45) (Ceker *et al.*, 2026)), grafos de conhecimento (iDISK2.0-RAG (S25) (Hou *et al.*, 2025)) e código-fonte (S30 (Jain *et al.*, 2024)). Embora não sejam o foco principal deste trabalho, essas abordagens oferecem contribuições relevantes, especialmente em cenários que envolvem dados heterogêneos.

De forma geral, os resultados mostram uma forte concentração em dados tabulares, como observado no Cocoon (S19) (S. Zhang *et al.*, 2025), no ZeroEC (S3) (Yangyang Wu *et al.*, 2025) e no BClean+ (S11) (Han *et al.*, 2026). Os demais tipos de dados aparecem de forma pontual, como os formatos semi-estruturados tratados pelo LLMFixer (S16) (Mondal *et al.*, 2024) e as séries temporais exploradas pelo AutoDW-TS (S9) (L. Liu, Hasegawa, Sampat, Bahrami *et al.*, 2025) e pelo TETL (S37) (Z. Wang *et al.*, 2026). Essa distribuição reflete a tendência histórica da área de qualidade de dados, centrada em tabelas, com os demais tipos sendo abordados de forma esparsa e, em geral, em contextos específicos (Côté *et al.*, 2024).

3.7.4 QP4: Como LLMs têm sido utilizados no processo de limpeza de dados (por exemplo, detecção de erros, imputação, normalização, deduplicação ou geração de regras)?

A distribuição das atividades de limpeza realizadas com LLMs, apresentada na Figura 3.7, mostra uma forte concentração em quatro tarefas: *Feature Cleaning* (43 estudos), *Imputation* (27), *Entity Matching* e *Deduplication* (18) e *Holistic Data Cleaning* (14). Um aspecto adicional relevante é o escopo das operações: 62% dos estudos cobrem simultaneamente a detecção e a correção dos erros, 30% realizam apenas a correção (partindo de erros já detectados por outro componente) e apenas 8% se limitam à detecção. Além disso, é importante distinguir as atividades centrais de limpeza de dados de outras atividades correlatas de preparação de dados, que aparecem com frequência nos *pipelines*, mas não constituem, em si, tarefas de limpeza no sentido estrito. As atividades centrais são discutidas a seguir, e as correlatas são tratadas em bloco separado ao final da seção.

O ***Feature Cleaning*** é a atividade mais frequente, presente em 43 dos 51 estudos. A tarefa consiste em detectar ou corrigir erros nos valores das colunas de um registro, como erros de digitação, inconsistências de formato (datas escritas de diferentes maneiras), violações de dependências funcionais (quando o CEP de um registro não corresponde à cidade informada na mesma linha) e valores fora do padrão esperado. A predominância

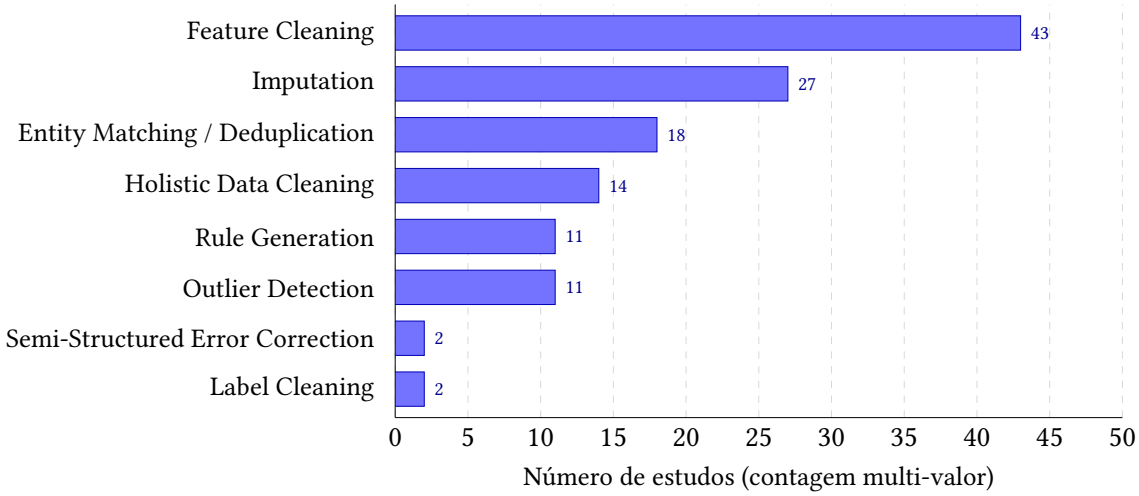


Figura 3.7: *Frequência das atividades centrais de limpeza de dados nos 51 estudos primários. Um mesmo estudo pode endereçar múltiplas atividades, por isso o somatório ultrapassa o total de estudos.*

dessa categoria é esperada, já que é a forma mais direta de limpeza em dados tabulares. Cocoon (S19) (S. Zhang *et al.*, 2025), ZeroEC (S3) (Yangyang Wu *et al.*, 2025) e BClean+ (S11) (Han *et al.*, 2026) são exemplos representativos que combinam detecção e correção em um mesmo pipeline.

A ***Imputation*** é utilizada em 27 estudos e consiste no preenchimento de valores ausentes. Quando realizada por LLMs, a tarefa se beneficia do conhecimento que o modelo adquiriu durante o pré-treinamento para inferir valores plausíveis a partir do contexto da linha e das demais colunas. RetClean (S39) (Naeem *et al.*, 2024) explora explicitamente essa capacidade ao combinar três fontes: o conhecimento geral do mundo contido nas LLMs, o conhecimento de domínio obtido por RAG sobre *Data Lakes* (repositórios que reúnem dados brutos de várias fontes) e o conhecimento privado de um modelo local ajustado aos dados do próprio usuário. AutoDW (S10) (L. Liu, Hasegawa, Sampat, Xenochristou *et al.*, 2024) e AutoDW-TS (S9) (L. Liu, Hasegawa, Sampat, Bahrami *et al.*, 2025) também tratam imputação dentro de *pipelines* mais amplos de preparação de dados.

O ***Entity Matching*** e a ***Deduplication*** aparecem em 18 estudos e tratam do problema de identificar registros que se referem à mesma entidade do mundo real, seja para fundir duplicatas em uma mesma base, seja para ligar registros entre bases distintas. LinkTransformer (S34) (Arora e Dell, 2024) oferece um pacote pronto para casamento em grande escala, em que cada registro é convertido em um vetor que representa seu significado e, em seguida, pares de registros com vetores próximos são confrontados. CitySTI (S14) (Yue e Jimenez-Ruiz, 2024) alinha dados tabulares ao Wikidata, uma base colaborativa com milhões de entidades descritas de forma padronizada, que funciona como referência externa para harmonizar os registros. PRISM (S5) (McCarthy, 2026) aplica ideias semelhantes às descrições de manuscritos históricos. O padrão recorrente é combinar uma primeira etapa rápida, que seleciona candidatos por similaridade, com uma segunda etapa em que o LLM atua como juíza nos casos duvidosos.

O ***Holistic Data Cleaning*** reúne os 14 estudos que tratam de vários tipos de erro ao mesmo tempo em um único *pipeline*, em vez de dedicar módulos distintos a cada tipo.

Cocoon (S19) (S. Zhang *et al.*, 2025), BClean+ (S11) (Han *et al.*, 2026), GIDCL (S24) (Yan *et al.*, 2024) e IterClean (S28) (Ni, K. Zhang, Miao, X. Zhao, Yangyang Wu e Yin, 2024) representam essa linha. O valor dessa categoria reside em oferecer ao usuário um único ponto de entrada, delegando ao LLM a tarefa de diagnosticar quais tipos de erro estão presentes e como tratá-los.

A ***Outlier Detection*** aparece em 11 estudos. Nela, o LLM costuma ser usado para diferenciar valores que são estatisticamente raros, mas semanticamente válidos (como um nome próprio pouco comum), de valores que de fato estão errados. Cocoon (S19) (S. Zhang *et al.*, 2025), CatDB (S13) (Fathollahzadeh *et al.*, 2025a) e VDSAgents (S49) (Y. Jiang *et al.*, 2026) combinam estatísticas clássicas com a validação semântica realizada pelo LLM, enquanto TETL (S37) (Z. Wang *et al.*, 2026) aplica essa lógica a séries temporais de sensores.

A ***Rule Generation*** também aparece em 11 estudos e tem caráter complementar: em vez de corrigir os dados diretamente, o LLM produz regras que descrevem como detectar ou corrigir erros, como dependências funcionais, padrões esperados de formato ou restrições lógicas entre colunas. As regras geradas são, depois, validadas e aplicadas sobre os dados por um componente tradicional. ZeroEC (S3) (Yangyang Wu *et al.*, 2025), LLMClean (S31) (Biester *et al.*, 2025), BClean+ (S11) (Han *et al.*, 2026) e GARF+ (S23) (Peng *et al.*, 2025) representam essa linha. A vantagem é que as regras são legíveis por humanos e podem ser reutilizadas, reduzindo a necessidade de múltiplas chamadas ao modelo durante a operação.

As atividades de ***Semi-Structured Error Correction*** e ***Label Cleaning*** aparecem em apenas 2 estudos cada. A primeira é representada por LLMFixer (S16) (Mondal *et al.*, 2024), já discutido na QP3, e por AutoClean (S7) (Shen *et al.*, 2025), que remove ruído HTML de bases de treinamento. A segunda categoria inclui MULTI-NEWS+ (S35) (Choi *et al.*, 2024) e Token Cleaning (S43) (Pang *et al.*, 2025), que atuam sobre os dados usados para treinar modelos, removendo rótulos ou trechos pouco informativos.

Além das atividades centrais, muitos estudos executam tarefas de preparação que não são estritamente de limpeza, mas complementam o pipeline de qualidade. A distribuição dessas atividades correlatas é apresentada na Figura 3.8.

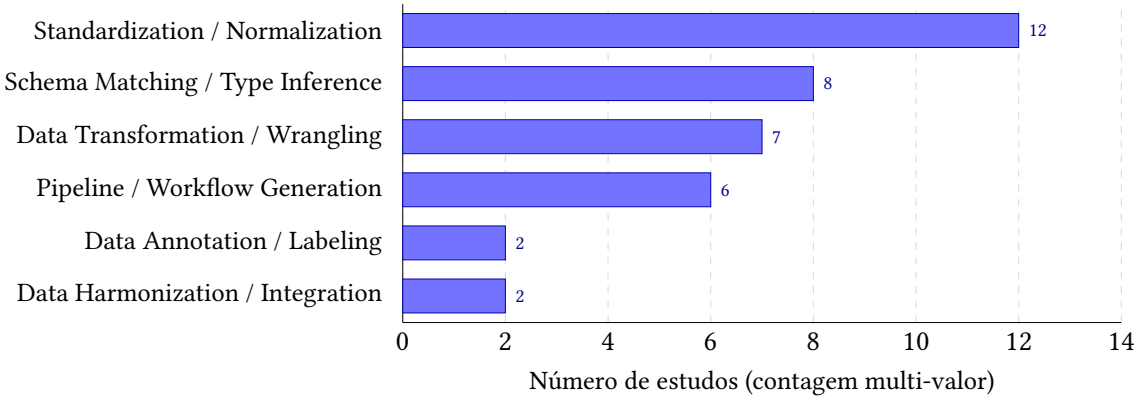


Figura 3.8: *Frequência das atividades correlatas de preparação de dados nos 51 estudos primários, realizadas em conjunto com as atividades centrais de limpeza.*

Entre as correlatas, a ***Standardization* ou *Normalization*** é a mais frequente (12 estudos) e trata da padronização de formatos de data, do uso de letras maiúsculas e

minúsculas, dos separadores decimais e de outras convenções de representação. ***Schema Matching* e *Type Inference*** aparecem em 8 estudos e tratam da inferência e correção dos tipos de colunas (como distinguir uma coluna de datas de uma coluna de texto livre), especialmente em CatDB (S13) (Fathollahzadeh *et al.*, 2025a) e AutoDW (S10) (L. Liu, Hasegawa, Sampat, Xenochristou *et al.*, 2024). ***Data Transformation* e *Wrangling*** aparecem em 7 estudos e cobrem transformações estruturais dos dados, como juntar tabelas, girar colunas em linhas ou combinar campos, presente em Dango (S18) (Chen *et al.*, 2025) e no sistema de limpeza em três níveis (S40) (Zaeifi e Lin, 2024). ***Pipeline* e *Workflow Generation*** (6 estudos) é a atividade de gerar automaticamente o fluxo completo de limpeza, como apresentado em AutoDCWorkflow (S8) (L. Li *et al.*, 2025) e CatDB (S13) (Fathollahzadeh *et al.*, 2025a). Por fim, ***Data Harmonization*** e ***Data Annotation*** aparecem em 2 estudos cada, com menor frequência. Essas atividades correlatas indicam que os LLMs têm sido usados não apenas para a limpeza em si, mas também para amarrar as etapas do *pipeline*, o que é relevante em arquiteturas como *Data Mesh*, que demandam produtos de dados reprodutíveis.

3.7.5 QP5: Quais evidências são apresentadas sobre o impacto dessas técnicas na qualidade, confiabilidade, transparência e rastreabilidade dos dados?

Os 51 estudos mapeados oferecem evidências consistentes de que os LLMs, quando bem integrados a *pipelines* de limpeza, superam as abordagens tradicionais. O MSL aponta três pontos que sustentam essa conclusão: a convergência em torno de métricas padrão, os ganhos expressivos em relação aos métodos anteriores e a importância da reprodutibilidade como critério de avaliação.

As métricas mais utilizadas são *Precision*, *Recall* e *F1-score*, presentes em praticamente todos os estudos com avaliação empírica. Algumas abordagens acrescentam medidas de eficiência, como tempo de execução, uso de CPU e de memória e custo monetário. Métricas adicionais aparecem em contextos específicos. AUROC e PR-AUC, utilizadas em estudos de detecção de *outliers*, medem a qualidade da separação entre valores normais e anômalos, considerando diferentes limiares de decisão. BERTScore e a distância de Levenshtein aparecem em tarefas de edição textual, medindo, respectivamente, a similaridade semântica entre duas frases (usando vetores gerados por um modelo de linguagem) e o número mínimo de alterações de caracteres entre uma cadeia e outra. Já as métricas de tarefa subsequente, como a acurácia de classificação e o MSE de regressão, avaliam o impacto indireto da limpeza, medindo o desempenho de um modelo de aprendizado de máquina treinado com base em dados já corrigidos.

Os ganhos em relação aos métodos anteriores são consistentemente expressivos. ZeroEC (S3) (Yangyang Wu *et al.*, 2025) reporta aumento médio de 66,82% em F1 sobre o Baran (Mahdavi *et al.*, 2019), com pico de 313,64% em *recall* no IMDB, e tempo de execução 6,87 vezes menor. Cocoon (S19) (S. Zhang *et al.*, 2025) supera HoloClean (Rekatsinas *et al.*, 2017), a combinação Raha+Baran (Mahdavi *et al.*, 2019), CleanAgent e RetClean em quatro dos cinco conjuntos avaliados, com F1 de 0,90 no Hospital, contra 0,63 do HoloClean. BClean+ (S11) (Han *et al.*, 2026), ZeroED (S51) (Ni, K. Zhang, Miao, X. Zhao, Yangyang Wu, Y. Wang *et al.*, 2025) e GIDCL (S24) (Yan *et al.*, 2024) apresentam resultados

semelhantes aos dos métodos anteriores aos LLMs.

Um ponto central da proposta de mestrado, decorrente da análise do QP1, é a distinção entre abordagens que garantem reprodutibilidade e as que não a garantem. Cerca de 21 dos 51 estudos empregam a estratégia de **geração de código ou de regras executáveis** por LLM. Nessa categoria, a LLM produz saídas persistentes, como consultas SQL em Cocoon (S19) (S. Zhang *et al.*, 2025), regras de dependência funcional e padrões de dados em BClean+ (S11) (Han *et al.*, 2026) e ZeroEC (S3) (Yangyang Wu *et al.*, 2025), ou *pipelines* em Python em CatDB (S13) (Fathollahzadeh *et al.*, 2025a) e CodeGenWrangler (S17) (Akella e Narayanam, 2025a). Essas saídas podem ser inspecionadas, versionadas e reexecutadas sem depender de uma nova chamada ao LLM, o que garante rastreabilidade das correções.

As demais abordagens operam com o LLM diretamente sobre as células, fornecendo as correções no momento em que são solicitadas, sem gerar uma saída persistente. Embora costumem ser mais simples de implementar e possam servir para tarefas pontuais, apresentam três desvantagens. Primeiro, a reexecução depende da estabilidade da API do LLM e do *prompt* original; basta que o provedor atualize o modelo para que os resultados mudem. Segundo, a auditoria das correções exige preservar o registro completo de todas as interações com o modelo, o que acarreta um ônus operacional significativo. Terceiro, como o LLM não é determinístico, o mesmo *prompt* pode gerar respostas distintas em execuções distintas. Essa distinção é especialmente relevante para esta tese, na qual o *framework* proposto deve atender a requisitos de reprodutibilidade, rastreabilidade e confiabilidade típicos de instituições produtoras de estatísticas oficiais. A escolha por técnicas que materializam as correções em código ou em regras executáveis mostra-se, portanto, uma diretriz metodológica central.

3.8 Desafios e Limitações

Com base nos resultados discutidos nas subseções anteriores, o MSL permitiu identificar cinco gargalos recorrentes na aplicação de LLMs à limpeza de dados. Esses gargalos sintetizam as principais limitações reportadas na literatura e orientam as diretrizes de evolução do *framework* a ser proposto. Cada um deles é apresentado a seguir, acompanhado das evidências extraídas dos estudos e das diretrizes de mitigação propostas pelos autores.

1. **Custo das APIs privadas.** Estudos que utilizam GPT-4, GPT-4o, Claude 3.5 ou Gemini reportam que a execução em larga escala pode ser proibitiva, sobretudo quando o LLM é chamado uma vez por célula ou por linha da tabela. ZeroEC (S3) (Yangyang Wu *et al.*, 2025) quantifica esse custo ao reportar até US$288 em uma única execução sobre o IMDB. O mesmo problema é apontado em Cocoon (S19) (S. Zhang *et al.*, 2025), AutoDCWorkflow (S8) (L. Li *et al.*, 2025) e VDSAgents (S49) (Y. Jiang *et al.*, 2026). A mitigação mais comum é materializar o conhecimento do LLM em regras ou código executável, reduzindo o número de chamadas à API durante a operação.

2. **Dependência da qualidade do *prompt* e comportamento não determinístico.** Pequenas mudanças na escrita do *prompt* podem produzir variações significativas no resultado, e rodar o mesmo *prompt* duas vezes pode gerar respostas diferentes, o que ameaça a reprodutibilidade. ZeroEC (S3) (Yangyang Wu *et al.*, 2025) acopla ao

pipeline um mecanismo que valida as regras geradas antes de aplicá-las, absorvendo parte dessa variação. BClean+ (S11) (Han *et al.*, 2026) e GIDCL (S24) (Yan *et al.*, 2024) adotam *templates* fixos de *prompt*, reduzindo a margem de variações acidentais. Em AutoDCWorkflow (S8) (L. Li *et al.*, 2025), os autores apontam para o *self-evolving prompting* como uma direção futura, em que o próprio sistema reescreve e testa automaticamente variações do *prompt*, mantendo as que funcionam melhor.

3. **Alucinação em erros atípicos.** Quando o LLM encontra padrões de erro raros ou muito específicos de um domínio, pode propor correções que parecem plausíveis, mas estão erradas. LLMFixer (S16) (Mondal *et al.*, 2024) observa isso em arquivos jurídicos, em que o LLM, por vezes, introduz novos erros estruturais ao tentar corrigir outros. ZeroEC (S3) (Yangyang Wu *et al.*, 2025) e IterClean (S28) (Ni, K. Zhang, Miao, X. Zhao, Yangyang Wu e Yin, 2024) mitigam o problema expondo o LLM a uma variedade maior de casos: os dados são primeiro divididos em grupos de padrões semelhantes, e exemplos de cada grupo são apresentados ao modelo, garantindo maior diversidade.

4. **Limitação da janela de contexto e escalabilidade de memória.** Mesmo com modelos que aceitam entradas longas, o custo computacional cresce com o tamanho da base, e vários estudos adotam estratégias de amostragem para contornar essa limitação. Cocoon (S19) (S. Zhang *et al.*, 2025) processa lotes de até 1000 valores frequentes por coluna. ZeroEC (S3) (Yangyang Wu *et al.*, 2025), em vez de enviar a tabela inteira ao LLM, seleciona, a cada decisão, apenas um pequeno conjunto de linhas semelhantes ao caso em análise, o que reduz o custo total em várias ordens de magnitude. BEAVER (S33) (Mehra e Rezig, 2024) agrupa atributos com base na diversidade de valores para controlar o tamanho do *prompt*. Apesar dessas otimizações, esses estudos raramente validam suas abordagens em bases de escala industrial.

5. **Automação completa ou supervisão humana.** Alguns estudos defendem *pipelines* totalmente automatizados, como AutoDCWorkflow (S8) (L. Li *et al.*, 2025) e CatDB (S13) (Fathollahzadeh *et al.*, 2025a). Outros reconhecem que o acompanhamento humano continua necessário em etapas críticas. Cocoon (S19) (S. Zhang *et al.*, 2025) foi desenhado com *human-in-the-loop*, uma arquitetura em que o usuário é consultado em pontos decisivos, o que permite verificar o raciocínio do LLM. IterClean (S28) (Ni, K. Zhang, Miao, X. Zhao, Yangyang Wu e Yin, 2024) e ZeroEC (S3) (Yangyang Wu *et al.*, 2025) reduzem essa supervisão a apenas 5 ou 10 linhas revisadas manualmente, buscando um equilíbrio. Essa discussão é particularmente relevante em estatísticas públicas, nas quais a auditabilidade das correções é um requisito institucional.

Em síntese, os cinco gargalos apontam diretrizes claras para a evolução do *framework* proposto. O custo das APIs e a limitação da janela de contexto indicam que, sempre que possível, o LLM deve gerar regras ou código reutilizáveis, em vez de ser chamado repetidamente para cada nova correção. A dependência do *prompt* e o comportamento não determinístico demandam *prompts* fixos, validação automática das saídas do LLM e registro das interações, para garantir que os resultados possam ser auditados e reproduzidos. O risco de alucinação indica que o *framework* precisa apresentar ao modelo uma variedade maior de

exemplos e confirmar suas respostas diante de fontes externas, especialmente em domínios pouco representados na literatura. Por fim, a decisão entre automação e supervisão humana sugere um desenho híbrido, em que o LLM assume o trabalho repetitivo e o analista é consultado nos pontos de decisão mais sensíveis. Essas direções são fundamentais para adaptar o estado da arte ao contexto das estatísticas públicas, em que a confiabilidade e a rastreabilidade das correções são requisitos essenciais.

3.9 Ameaças à Validade do MSL

Seguindo a orientação de Wohlin *et al.* (2012), as ameaças à validade deste MSL são discutidas em quatro dimensões: construção, interna, externa e de conclusão. Em cada dimensão, são apresentadas a ameaça identificada e as mitigações adotadas ao longo da condução do estudo.

Validade de construção. A principal ameaça nesta dimensão refere-se à cobertura da *string* de busca em relação ao objeto de estudo. A *string* final, detalhada na Seção 3.3, reúne seis variações terminológicas para limpeza de dados (*data cleaning*, *data cleansing*, *data wrangling*, *data scrubbing*, *data harmonization* e *data standardization*) e cinco variações terminológicas para modelos de linguagem (*large language model*, *large language models*, *LLM*, *LLMs* e *generative AI*). Termos de escopo mais amplos, como *data preparation* e *foundation models*, foram excluídos porque resultariam em um número alto de falsos positivos sem acréscimo proporcional de cobertura sobre o objeto específico desta pesquisa. Essa decisão implica que estudos que empreguem exclusivamente esses termos podem não ter sido recuperados. Como mitigação, a *string* foi aplicada a cinco bases indexadoras (Scopus, IEEE Xplore, ACM Digital Library, Web of Science e ScienceDirect), o que aumenta a probabilidade de captar trabalhos relevantes, mesmo diante da escolha de um vocabulário mais restrito.

Validade interna. Como o MSL foi conduzido por um único pesquisador, há risco de subjetividade na seleção dos estudos e na classificação das abordagens em categorias como estratégia de uso do LLM, atividade de limpeza ou tipo de dados. Para reduzir esse risco, foram adotados critérios de inclusão e exclusão explícitos, um formulário de extração padronizado (Tabela 3.1) e um processo de avaliação de qualidade com questões objetivas. Todas as decisões de triagem e extração foram registradas na plataforma Parsifal, o que permite auditoria posterior do protocolo.

Validade externa. A seleção limitou-se a estudos revisados por pares, publicados até o início de 2026 e indexados nas bases consultadas. Isso pode restringir a generalização dos achados, especialmente no que se refere à literatura cinza, aos pré-prints recentes e aos estudos em línguas distintas das contempladas. A mitigação adotada foi a cobertura de múltiplas bases, que reúnem os principais veículos da área, e a inclusão dos estudos mais recentes disponíveis durante a condução do MSL. Ainda assim, recomenda-se cautela ao extrapolar os achados para cenários fora do escopo desta revisão.

Validade de conclusão. A classificação das abordagens em taxonomias envolve interpretação e pode produzir variações entre revisores distintos. Além disso, algumas categorias, como *holistic data cleaning* e *rule generation*, apresentam sobreposição parcial de significado na literatura. Para mitigar esse risco, cada categoria foi definida operaci-

onalmente no texto do capítulo; os critérios de classificação foram aplicados de forma sistemática, e o protocolo completo, incluindo a *string* de busca, os critérios e o formulário, foi documentado para permitir a replicação por outros pesquisadores.

3.10 Considerações Finais

Este MSL investigou como LLMs têm sido utilizados em tarefas de limpeza de dados, com base em 51 estudos primários publicados entre 2023 e 2026. Os achados convergem em cinco pontos principais. Primeiro, a literatura organiza-se em torno de oito estratégias de uso de LLMs, com predomínio de *few-shot*/ICL, *zero-shot* e geração de regras e de código. Segundo, a maior parte dos estudos avalia suas abordagens em cenários genéricos multi-domínio, com ausência completa de aplicações em estatísticas públicas. Terceiro, os dados tabulares dominam o corpus (aproximadamente 65% dos estudos), formato que coincide com o predominante nas bases de produção de indicadores oficiais. Quarto, as atividades mais frequentes são *feature cleaning*, imputação, deduplicação e limpeza holística, com forte tendência à unificação da detecção e da correção em um único *pipeline*. Quinto, os LLMs superam os métodos anteriores nas métricas padronizadas da área, e os estudos que materializam as correções em código ou em regras executáveis oferecem o caminho mais consistente para a reprodutibilidade e a rastreabilidade.

Esses resultados, somados às lacunas discutidas na Seção 3.8, delimitam as bases do *framework* de limpeza de dados para estatísticas públicas proposto nesta proposta de mestrado. A proposta precisará combinar, de forma explícita, a materialização do conhecimento do LLM em artefatos executáveis (regras, consultas SQL, código em Python), *templates* de *prompts* estáveis, mecanismos de validação das saídas do modelo e pontos de supervisão humana nas decisões sensíveis. Além disso, o *framework* deverá abordar características importantes do domínio de estatísticas públicas, como metadados institucionais, regras de consistência entre indicadores e a geração de relatórios para auditabilidade.

Como próximos passos, o trabalho avançará em três frentes. Primeiro, o projeto do *framework* será detalhado com base nos padrões identificados e adaptado ao contexto da Fundação SEADE. Em seguida, será formalizado um instrumento de validação que permita avaliar, em termos de qualidade, confiabilidade e rastreabilidade, a contribuição do *framework* em relação às práticas correntes da instituição. Terceiro, um estudo de caso com base real na produção de estatísticas públicas será conduzido para refinar o *framework* e demonstrar sua aplicabilidade em condições operacionais.

Capítulo 4

Proposta de Mestrado

4.1 Considerações Iniciais

Este capítulo apresenta a proposta de mestrado construída a partir dos fundamentos teóricos apresentados. A proposta consiste em um *framework* para limpeza de dados baseado em LLMs, pensado para institutos produtores de estatísticas públicas, como a Fundação SEADE, que têm como prioridade atender a requisitos de reprodutibilidade, rastreabilidade e auditabilidade. As próximas seções estão organizadas da seguinte forma. A Seção 4.2 apresenta a questão de pesquisa e suas decomposições. A Seção 4.3 descreve o *framework* proposto, apresenta o fluxograma funcional e detalha os componentes e os princípios arquiteturais. A Seção 4.4 apresenta a metodologia de pesquisa adotada. A Seção 4.5 apresenta o cronograma previsto para o restante da pesquisa. A Seção 4.6 descreve a estratégia de avaliação, incluindo *benchmarks* e conjuntos de dados. A Seção 4.7 sintetiza as contribuições esperadas.

4.2 Questão de Pesquisa

A proposta de mestrado é orientada pela seguinte questão de pesquisa (QP):

> *QP - Como estruturar um framework baseado em LLMs para apoiar a limpeza de dados em estatísticas públicas, garantindo reprodutibilidade, auditabilidade e integração com arquiteturas Data Mesh?*

A questão principal é decomposta em três sub-questões, cada uma associada a uma dimensão da pesquisa:

- **SQP1 (Alinhamento à Arquitetura *Data Mesh*)** - Como estruturar um *pipeline* de limpeza de dados que combine geração de código por LLMs, supervisão humana e persistência de metadados, alinhado aos princípios da arquitetura *Data Mesh*? **SQP2 (Desempenho da Metodologia de Limpeza de Dados)** - Em que medida o *framework* realiza a limpeza de dados de forma efetiva quando aplicado em institutos produtores de estatísticas públicas?

- **SQP3 (Aplicabilidade ao Contexto de Estatísticas Públicas)** - De que forma o *framework* atende aos requisitos de reprodutibilidade, rastreabilidade e integração a fluxos de trabalho característicos de um instituto produtor de estatísticas oficiais?

4.3 Descrição do Framework

4.3.1 Visão Geral

O framework proposto foi projetado com base nos padrões arquiteturais recorrentes identificados no MSL e, como princípio, nos requisitos institucionais para a produção de estatísticas públicas discutidos no Capítulo 2. A Figura 4.1 apresenta o fluxograma funcional do *framework*, organizado em quatro raias: *Front-End*, Entrada de Dados, Integrador e Banco de Dados.

O fluxograma contempla dois caminhos principais. O **caminho de reúso** é disparado quando já existe, na base de metadados, um modelo de limpeza aplicável aos dados ingeridos; nesse caso, o código previamente aprovado é executado diretamente e o resultado é encaminhado à avaliação do responsável pelo produto de dados. O **caminho de geração** é acionado quando não há modelo aplicável; nele, dois agentes LLM atuam em sequência, o primeiro para produzir um *prompt* estruturado com base nas instruções do responsável, em uma amostra dos dados e na consulta a modelos anteriormente aprovados, e o segundo para gerar o código de limpeza correspondente. O código gerado é executado, auditado e documentado, e o resultado é submetido à mesma etapa de avaliação humana. Quando aprovado, o código passa a integrar a base de metadados institucionais, permanecendo disponível para reúso em futuras execuções.

Esse projeto aplica a principal recomendação extraída do MSL: priorizar abordagens que geram correções de código ou regras executáveis reutilizáveis, em vez de depender de chamadas repetidas ao LLM a cada execução (S. Zhang *et al.*, 2025; Yangyang Wu *et al.*, 2025; Han *et al.*, 2026; Akella e Narayanam, 2025a).

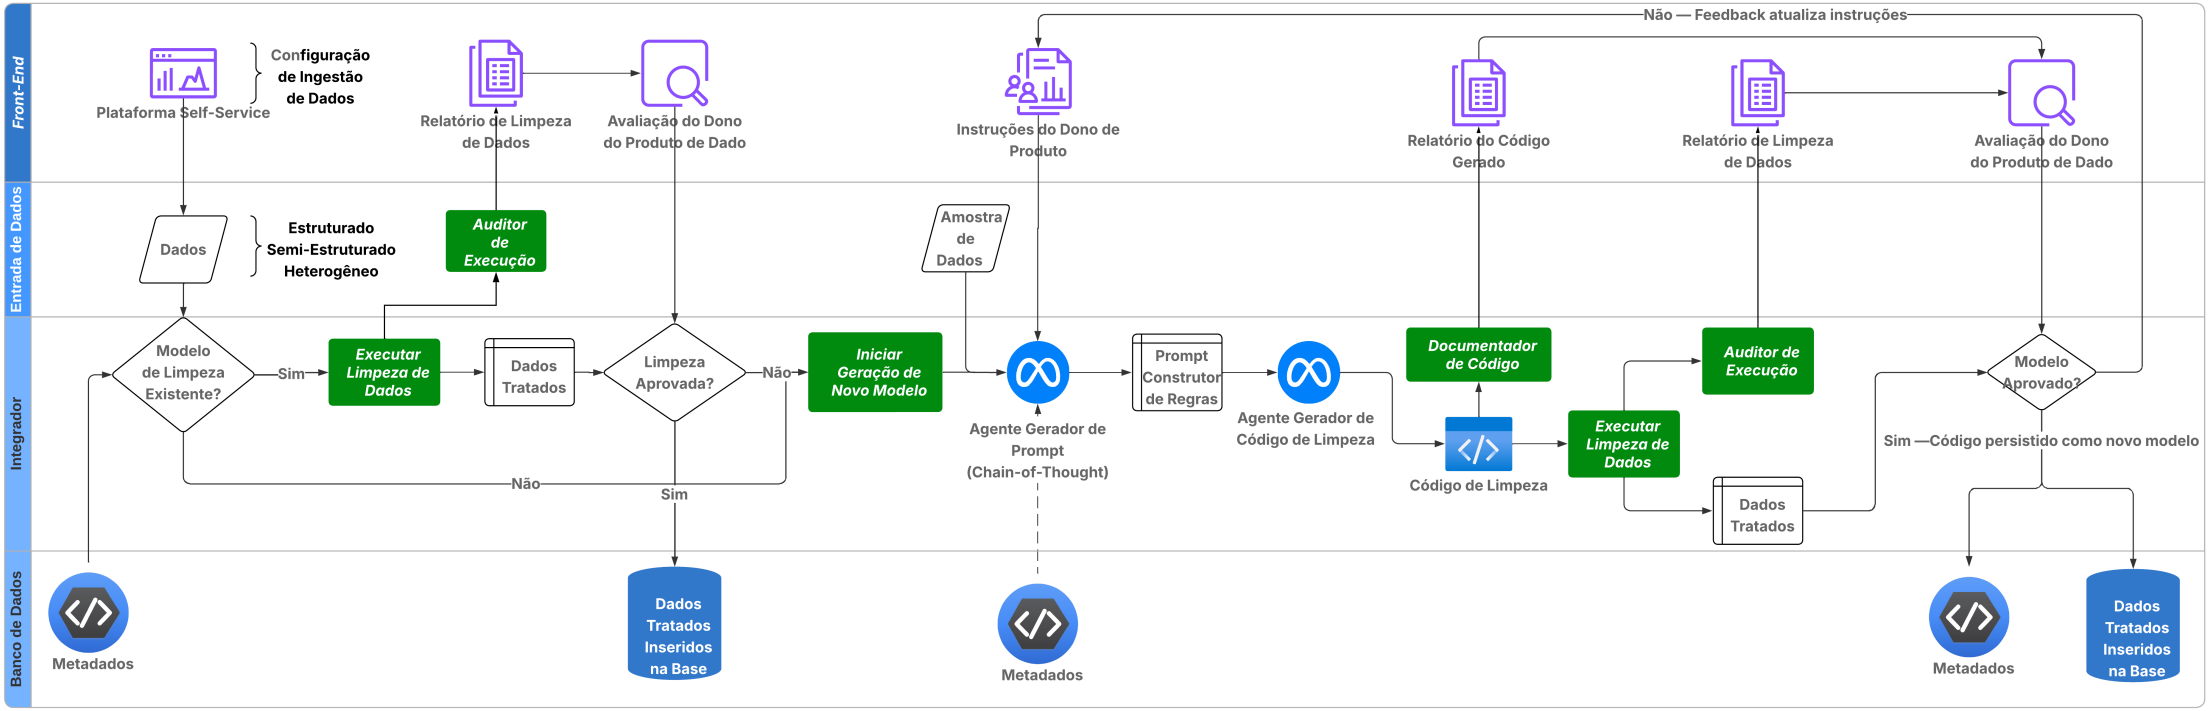


Figura 4.1: *Fluxograma do framework proposto.*

4.3.2 Componentes

O *framework* é composto por um conjunto de componentes que combinam agentes LLM, processos determinísticos e saídas armazenadas. Cada componente é descrito a seguir, com indicação do padrão da literatura que o sustenta.

Plataforma *Self-Service*. Interface pela qual o analista responsável pelo produto de dados configura a ingestão e acompanha o ciclo de limpeza. Recebe os dados de entrada (estruturados, semiestruturados ou não estruturados), coleta as instruções do responsável e disponibiliza os relatórios produzidos ao longo do fluxo. Alinha-se ao princípio da plataforma de autoatendimento discutido nas arquiteturas do *Data Mesh*.

Agente Gerador de *Prompt* (*Chain-of-Thought*). Agente LLM responsável por consolidar as entradas disponíveis, as instruções do responsável, uma amostra de dados e a consulta a modelos anteriormente aprovados em um *prompt* estruturado para o próximo agente. O uso de *Chain-of-Thought* segue os estudos do MSL que aplicam raciocínio encadeado para decompor decisões complexas, como ZeroEC (S3) (Yangyang Wu *et al.*, 2025), ZeroDC (S2) (Yang *et al.*, 2026) e MULTI-NEWS+ (S35) (Choi *et al.*, 2024).

Agente Gerador de Código de Limpeza. Agente LLM que recebe o *prompt* construído pelo agente anterior e gera o código de limpeza correspondente, em uma linguagem executável (por exemplo, consultas SQL ou *pipelines* em Python). Esse padrão é observado em estudos como Cocoon (S19) (S. Zhang *et al.*, 2025), CatDB (S13) (Fathollahzadeh *et al.*, 2025a), CodeGenWrangler (S17) (Akella e Narayanam, 2025a) e BClean+ (S11) (Han *et al.*, 2026).

Código de Limpeza. Artefato persistente produzido pelo agente gerador de código. Por ser inspecionável, versionado e reexecutável, sem necessidade de novas chamadas ao LLM, cumpre o papel central de rastreabilidade destacado na Seção 3.7.5 do MSL.

Executar Limpeza de Dados. Processo determinístico que aplica o código de limpeza (recém-gerado ou reaproveitado) sobre os dados de entrada, produzindo os dados tratados.

Auditor de Execução. Processo determinístico que instrumenta a execução do código, captura estatísticas (linhas alteradas, distribuição das alterações por coluna, valores antes e depois) e gera o Relatório de Limpeza de Dados. Cumpre uma função análoga à do mecanismo de validação de regras descrito em ZeroEC (S3) (Yangyang Wu *et al.*, 2025). Por ser determinístico, garante que a auditoria das correções seja reprodutível.

Documentador de Código. Processo determinístico que analisa o código gerado, extrai as operações aplicadas, as regras inferidas e os atributos afetados e produz o Relatório do Código Gerado. Esse relatório é apresentado ao responsável pelo produto de dados para apoiar a avaliação.

Avaliação do Dono do Produto de Dado. Etapa humana em que o responsável pelo produto analisa os relatórios produzidos e decide pela aprovação ou rejeição da limpeza. Quando rejeitada, o *framework* retorna às instruções do responsável, incorporando o *feedback* no próximo ciclo de geração. Esse ponto de supervisão humana segue o padrão de *human-in-the-loop* adotado em estudos como Cocoon (S19) (S. Zhang *et al.*, 2025), IterClean (S28) (Ni, K. Zhang, Miao, X. Zhao, Yangyang Wu e Yin, 2024) e ZeroEC (S3) (Yangyang Wu *et al.*, 2025).

Metadados Institucionais. Repositório que armazena os códigos aprovados, as instruções que os geraram, os relatórios associados e metadados específicos do contexto institucional (por exemplo, regras de consistência entre indicadores). Atua como fonte de consulta para o agente de *prompt* e como base para o mecanismo de reúso de modelos na decisão *Modelo de Limpeza Existente?*.

Dados Tratados Inseridos na Base. Destino final dos dados após aprovação, disponibilizados para os processos analíticos e de geração de indicadores.

4.3.3 Princípios do Framework

O desenho do *framework* é orientado por cinco princípios extraídos dos achados do MSL e das características do domínio de estatísticas públicas.

Conversão em código ou em regras executáveis. Sempre que possível, o conhecimento da LLM é convertido em saídas persistentes e reexecutáveis. Essa escolha responde ao gargalo de custos de APIs e à exigência de reprodutibilidade, conforme discutido na Seção 3.8 do MSL (S. Zhang *et al.*, 2025; Yangyang Wu *et al.*, 2025; Han *et al.*, 2026; Akella e Narayanam, 2025a).

Separação entre componentes generativos e determinísticos. Agentes LLM são utilizados apenas nas etapas criativas de geração de *prompt* e código. As etapas de execução, auditoria e documentação são processos determinísticos que não dependem de LLM durante sua operação. Essa separação preserva a rastreabilidade e reduz a variância entre as execuções (Yangyang Wu *et al.*, 2025; Han *et al.*, 2026).

Supervisão humana em pontos de decisão institucional. A aprovação do responsável pelo produto de dado funciona como ponto de controle antes da persistência dos dados tratados ou do código. O *feedback* do responsável, em caso de rejeição, alimenta a próxima iteração por meio da atualização das instruções, com abordagem alinhada à direção de *self-evolving prompting* sugerida por AutoDCWorkflow (S8) (L. Li *et al.*, 2025; S. Zhang *et al.*, 2025; Ni, K. Zhang, Miao, X. Zhao, Yangyang Wu e Yin, 2024; Yangyang Wu *et al.*, 2025).

Reúso de modelos via metadados persistentes. À medida que modelos são aprovados, o repositório de metadados cresce e passa a alimentar tanto o caminho de reúso quanto o contexto do agente de *prompt*. O *framework* se beneficia, portanto, do uso acumulado, sem depender de *fine-tuning* do modelo base (Naeem *et al.*, 2024; Ni, K. Zhang, Miao, X. Zhao, Yangyang Wu e Yin, 2024).

Especialização ao contexto de estatísticas públicas. A especialização ao domínio é atingida por três mecanismos complementares: (i) *templates* de *prompt* específicos, que incorporam padrões típicos de indicadores oficiais e regras de consistência conhecidas; (ii) RAG (*Retrieval-Augmented Generation*) sobre conhecimento institucional, como documentação metodológica dos produtos estatísticos e metadados de execuções anteriores; e (iii) validações específicas no Auditor de Execução, como verificações de plausibilidade dos valores e de integridade entre indicadores relacionados (Mehra e Rezig, 2024; Naeem *et al.*, 2024).

4.4 Metodologia

A pesquisa foi estruturada para propor e validar um *framework* aplicável a problemas reais em contextos institucionais. O *framework*, descrito na Seção 4.3, é o principal resultado desta proposta e será acompanhado de um protótipo funcional que permitirá sua avaliação empírica. A condução da pesquisa é organizada em seis etapas descritas a seguir.

Etapa 1 – Fundamentação teórica. Consiste na consolidação dos conceitos de estatísticas públicas, *Data Mesh* e limpeza de dados (Apresentado no Capítulo 2).

Etapa 2 – Mapeamento sistemático da literatura (MSL). Consiste na condução do MSL sobre o uso de LLMs na limpeza de dados, com 51 estudos primários analisados (Apresentado no Capítulo 3).

Etapa 3 – Projeto do *framework*.. Consiste na formalização do fluxograma funcional, dos componentes e das diretrizes arquiteturais (Apresentado na Seção 4.3). O desenho será refinado ao longo das etapas seguintes, à medida que o protótipo for desenvolvido e avaliado.

Etapa 4 – Implementação do protótipo. Esta etapa consiste no desenvolvimento de uma versão funcional do *framework*, priorizando inicialmente o tratamento de dados tabulares, tipo de dado predominante tanto no MSL quanto nas bases de produção de indicadores oficiais. O protótipo será construído com ferramentas de código aberto integradas ao ecossistema Python. A orquestração dos agentes LLM será feita com um *framework* voltado a agentes, como LangGraph. A execução dos modelos ocorrerá prioritariamente em ambiente local, por meio de modelos abertos especializados na geração de código, executados por ferramentas como Ollama; APIs externas poderão ser utilizadas pontualmente durante a prototipação inicial. A validação das saídas será realizada com bibliotecas de validação de dados em Python, como Pandera. A interface *self-service* será desenvolvida com uma ferramenta de prototipação leve, como o Streamlit. O repositório de metadados será implementado em um banco de dados relacional, como PostgreSQL.

Etapa 5 – Avalidação do *framework*. Avaliação do protótipo em dois cenários complementares. No primeiro, o *framework* será aplicado a conjuntos de dados amplamente utilizados pela literatura mapeada, como Hospital, Flights, Beers e Rayyan, e seus resultados são comparados a *baselines* clássicos (HoloClean e Raha+Baran) e a abordagens recentes baseadas em LLMs (Cocoon, ZeroEC e BClean+). No segundo, o *framework* é aplicado a pelo menos um conjunto de dados reais de produção de estatísticas públicas, a ser definido em conjunto com o Centro de Ciências de Dados para Estatísticas Públicas (CCDEP) da Fundação SEADE. O detalhamento dos *baselines*, dos conjuntos de dados e das métricas é apresentado na Seção 4.6.

Etapa 6 – Análise, refinamento e redação. Análise dos resultados da avaliação, refinamento iterativo do *framework* e do protótipo com base nos achados empíricos e redação da dissertação. As evidências coletadas também servirão de base para a preparação de artigos científicos associados à pesquisa.

4.5 Cronograma

O cronograma previsto para a pesquisa, entre janeiro de 2025 e julho de 2027, é apresentado na Tabela 4.1. A estimativa assume trabalho em regime de dedicação parcial, compatível com a rotina do mestrado, e distribui 31 meses entre fundamentação teórica, mapeamento da literatura, desenho da proposta, implementação, avaliação, redação e defesa, com cada atividade associada à etapa da metodologia descrita na Seção 4.4.

Período	**Etapa**	**Atividade**
Jan–Set/2025	Etapa 1	Fundamentação Teórica. (Concluída)
Out/2025–Fev/2026	Etapa 2	Mapeamento sistemático da literatura (Concluída)
Mar–Abr/2026	Etapa 3	Projeto do *framework* (Concluída)
Mai–Jun/2026	Etapa 4	Configuração do ambiente e definição do *dataset*-piloto
Jul–Ago/2026	Etapa 4	Implementação do caminho de geração de novo modelo
Set/2026	Etapa 4	Implementação do Auditor de Execução e do Documentador de Código
Out/2026	Etapa 4	Implementação da interface *self-service* e da persistência de metadados
Nov–Dez/2026	Etapa 4	Implementação do caminho de reúso de modelos e do *loop* de *feedback*
Jan/2027	Etapa 5	Avaliação em *benchmarks* da literatura
Fev–Mar/2027	Etapa 5	Estudo de caso na Fundação SEADE
Abr–Jun/2027	Etapa 6	Redação da dissertação e preparação de artigos
Jul/2027	Etapa 6	Defesa

Tabela 4.1: *Cronograma previsto para a pesquisa após a qualificação.*

4.6 Avaliação dos Resultados

A avaliação do *framework* é organizada em três aspectos complementares: técnico, metodológico e institucional. Cada aspecto responde a uma das subquestões definidas na Seção 4.2.

- **Aspecto técnico.** O *framework* é avaliado por meio de métricas objetivas, alinhadas às práticas predominantes na literatura mapeada. As métricas principais são *Precision*, *Recall* e *F1-score* calculadas em nível de célula, conforme o padrão da área e de estudos como ZeroEC (S3) (Yangyang Wu *et al.*, 2025), Cocoon (S19) (S. Zhang *et al.*, 2025), BClean+ (S11) (Han *et al.*, 2026) e ZeroED (S51) (Ni, K. Zhang, Miao, X. Zhao, Yangyang Wu, Y. Wang *et al.*, 2025). A essas métricas são acrescentadas medidas de eficiência (tempo de execução e uso de memória).
- **Aspecto metodológico.** Três propriedades são examinadas nessa análise. A rastreabilidade é verificada por meio da auditoria do código aprovado: um código é considerado rastreável se puder ser lido, versionado e reexecutado sem depender

de uma nova chamada ao LLM. A reusabilidade é medida pela taxa de sucesso do caminho de reúso em conjuntos de dados similares aos que geraram o modelo original. A adaptabilidade é medida pelo número médio de iterações do ciclo de *feedback* necessárias para obter a aprovação do responsável pelo produto de dado, em cenários controlados.

- **Aspecto institucional.** O *framework* é avaliado em um estudo de caso conduzido em colaboração com o Centro de Ciências de Dados para Estatísticas Públicas (CCDEP) da Fundação SEADE. Além das métricas técnicas da primeira vertente aplicadas a um conjunto de dados real, a avaliação considera uma lista de verificação derivada dos requisitos institucionais: rastreabilidade (código aprovado, versionado e auditável), reprodutibilidade (reexecução do *pipeline* com resultados equivalentes) e aderência ao fluxo de trabalho do analista responsável pelo produto de dados. A comparação é feita em relação ao fluxo de limpeza atualmente adotado, considerando-se o tempo de execução, o número de correções realizadas e o esforço do analista.

Para permitir comparação direta com a literatura, são adotados dois grupos de *baselines*: o primeiro, composto por métodos clássicos anteriores aos LLMs, como HoloClean (Rekatsinas *et al.*, 2017) e a combinação Raha+Baran (Mahdavi *et al.*, 2019); o segundo, composto por abordagens recentes baseadas em LLMs que se destacaram no MSL por seus resultados empíricos e pela disponibilidade de código aberto, como Cocoon (S19) (S. Zhang *et al.*, 2025), ZeroEC (S3) (Yangyang Wu *et al.*, 2025) e BClean+ (S11) (Han *et al.*, 2026). Os conjuntos de dados utilizados na validação combinam *benchmarks* clássicos da literatura (Hospital, Flights, Beers e Rayyan), presentes em grande parte dos estudos mapeados, e ao menos um conjunto real de produção de estatísticas públicas, a ser definido em colaboração com o CCDEP. O uso conjunto desses dois grupos permite, respectivamente, comparar o *framework* à literatura em condições padronizadas e avaliar sua aplicabilidade em um cenário operacional representativo do problema que motiva a pesquisa.

4.7 Contribuições Esperadas

Espera-se que essa proposta de mestrado apresente as seguintes contribuições:

- Proposição e validação de um *framework* que integra a geração de código por LLMs, a supervisão humana estruturada e a persistência de metadados institucionais, em um *pipeline* voltado ao contexto das estatísticas públicas, identificado como uma lacuna explícita na análise dos domínios da Seção 3.7.2 do MSL.
- Consolidação de um padrão arquitetural que prioriza reprodutibilidade e auditabilidade, ao gerar as correções como código executável e ao separar as etapas generativas (agentes LLM) das etapas determinísticas (execução, auditoria, documentação). Esse padrão é apresentado como alternativa explícita à abordagem de inferência direta em nível de célula, predominante em parte da literatura e apontada como frágil sob o ponto de vista institucional na Seção 3.7.5 do MSL.
- Desenvolvimento de um protótipo funcional de código aberto, documentado e auditável, aplicável a institutos de estatística e com potencial de adoção pelo CCDEP da Fundação SEADE. O protótipo serve como prova de conceito do *framework* e como

ponto de partida reutilizável em outras instituições com requisitos semelhantes.

- Ampliação da base empírica do MSL por meio da aplicação do *framework* em dados reais de produção de estatísticas públicas, um domínio hoje ausente da literatura mapeada, que se concentra em *benchmarks* genéricos, *e-commerce* e academia. Os achados dessa aplicação também fundamentarão os artigos científicos a serem elaborados na Etapa 6 da pesquisa.

Anexo A

Catálogo de Ferramentas Clássicas de Limpeza de Dados

Este anexo consolida o levantamento de ferramentas e bibliotecas de código aberto para limpeza de dados a partir dos três mapeamentos sistemáticos discutidos na Seção 2.3, bem como as métricas de validação adotadas por cada uma dessas soluções. O material é apresentado em três tabelas: o Catálogo de Ferramentas e Bibliotecas, construído a partir das revisões de Côté *et al.* (2024) e Hosseinzadeh *et al.* (2023); a lista complementar de ferramentas citadas por Abedjan *et al.* (2016); e o compilado das métricas de validação utilizadas pelos autores de cada ferramenta.

A.1 Catálogo de Ferramentas e Bibliotecas

Após varredura de todas as soluções apresentadas nas revisões 1 e 2, verificou-se que nem todas as técnicas, frameworks ou bibliotecas apresentadas possuíam código aberto. Com relação a revisão 1, foi possível encontrar o código da implementação disponível para 41 das soluções apresentadas no artigo. Já no caso da revisão 2 foi possível encontrar o código da implementação disponível em 4 dos artigos listados. Todas as soluções com códigos disponíveis estão listadas na Tabela A.1.

Tabela A.1: *Catálogo de ferramentas e bibliotecas de Data Cleaning*

Referência	Nome da Solução	Atividade de Data Cleaning	Ano	Link Solução
Rekatsinas *et al.*, 2017	HoloClean	Feature Cleaning (model based)	2017	https://github.com/HoloClean/holoclean
Visengeriyeva e Abedjan, 2018	DetectEr	Feature Cleaning (model based)	2018	https://github.com/visenger/DetectEr
Mahdavi *et al.*, 2019	RAHA	Feature Cleaning (model based)	2019	https://github.com/BigDaMa/raha

Referência	Nome da Solução	Atividade de Data Cleaning	Ano	Link Solução
Mahdavi *et al.*, 2019	BARAN	Feature Cleaning (model based)	2019	https://github.com/BigDaMa/raha
Mahdavi *et al.*, 2019	RAHA	Feature Cleaning (model based)	2019	https://github.com/BigDaMa/raha
Neutatz *et al.*, 2019	ED2	Feature Cleaning (model based)	2019	https://github.com/BigDaMa/ExampleDrivenErrorDetection
Visengeriyeva, Akbik *et al.*, 2016	DataGuards	Feature Cleaning (ensemble based)	2016	https://github.com/visenger/DataGuards
R. Wang *et al.*, 2023	Sudowoodo	Feature Cleaning (ensemble based) Feature Cleaning (transformer based) Entity Matching (Latent Space Comparison)	2022	https://github.com/megagonlabs/sudowoodo
Narayan *et al.*, 2022	-	Feature Cleaning (transformer based)	2022	https://github.com/HazyResearch/fm_data_tasks
Nashaat *et al.*, 2021	TabReformer	Feature Cleaning (transformer based)	2021	https://github.com/MonaNashaat/TabReformer
Mauritz *et al.*, 2021	autoencoder-pdb-cleaning	Feature Cleaning (auto-encoder based)	2021	https://github.com/fpjnijweide/autoencoder-pdb-cleaning
Z. Liu *et al.*, 2022		Feature Cleaning (auto-encoder based)	2022	https://github.com/sis-ethz/Picket
Karlaš *et al.*, 2020	CPClean	Feature Cleaning (Error prioritization)	2021	https://github.com/chu-data-lab/CPClean
Krishnan *et al.*, 2016	ActiveClean	Feature Cleaning (Error prioritization)	2016	https://activeclean.github.io/
Rottmann e 2023, 2023	Automatic-Label-Error-Detection	Label Cleaning (Uncertaint based)	2023	https://github.com/mrcoee/Automatic-Label-Error-Detection
Teso *et al.*, 2021	Cincer	Label Cleaning (Uncertaint based)	2021	https://github.com/abonte/cincer
Atkinson e Metsis, 2021	Tsar	Label Cleaning (Uncertaint based)	2021	https://github.com/imics-lab/TSAR
Bernhardt *et al.*, 2022	InnerEye-DataQuality	Label Cleaning (Uncertaint based)	2022	https://github.com/microsoft/InnerEye-DeepLearning/tree/1606729c7a16e1bfeb269694314212b6e2737939/InnerEye-DataQuality

Referência	Nome da Solução	Atividade de Data Cleaning	Ano	Link Solução
Northcutt *et al.*, 2021	Cleanlab	Label Cleaning (Uncertaint based)	2019	https://github.com/cleanlab/cleanlab
Hendrycks e Gimpel, 2017	-	Label Cleaning (Uncertaint based)	2016	https://github.com/hendrycks/error-detection
Yu e Aizawa, 2020	-	Label Cleaning (Loss based)	2020	https://github.com/YU1ut/Unknown-Class-Label-Cleaning
Jinchi Huang *et al.*, 2019	O2U-Net	Label Cleaning (Loss based)	2019	https://github.com/hjimce/O2U-Net
Smyth *et al.*, 2019	Training-ValueNet	Label Cleaning (Counterfactual)	2020	https://github.com/lukasmyth96/Training-ValueNet
Suzuki *et al.*, 2021		Label Cleaning (Counterfactual)	2021	https://github.com/sony/ai-research-code/tree/master/data-cleansing
Yinjun Wu *et al.*, 2021	Chef	Label Cleaning (Counterfactual)	2021	https://github.com/wuyinjun-1993/Chef
Hara *et al.*, 2019	-	Label Cleaning (Counterfactual)	2019	https://github.com/sato9hara/sgd-influence
X. Zhang *et al.*, 2018	DUTI	Label Cleaning (Counterfactual)	2018	http://pages.cs.wisc.edu/~jerryzhu/DUTI
K.-H. Lee *et al.*, 2018	CleanNet	Label Cleaning (Outlier based)	2018	https://kuanghuei.github.io/CleanNetProject/
Y. Li *et al.*, 2020	Ditto	Entity Matching (Blocking)	2020	https://github.com/megagonlabs/ditto
Jiacheng Huang *et al.*, 2023	DAEM	Entity Matching (Blocking)	2021	https://github.com/nju-websoft/DAEM
Jin *et al.*, 2021	AdaMEL	Entity Matching (Token Comparison)	2021	https://github.com/DerekDiJin/AdaMEL-supplementary
Fu *et al.*, 2020	EntityMatcher	Entity Matching (Latent Space Comparison)	2021	https://github.com/icip-cas/EntityMatcher
Mudgal *et al.*, 2018	DeepMatcher	Entity Matching (Latent Space Comparison/Learned Comparison)	2018	https://github.com/anhaidgroup/deepmatcher
Kasai *et al.*, 2019	DeepMatcher	Entity Matching (Latent Space Comparison/Learned Comparison)	2018	https://github.com/anhaidgroup/deepmatcher

Referência	Nome da Solução	Atividade de Data Cleaning	Ano	Link Solução
C. Zhao e He, 2019	AutoEM	Entity Matching (Learned Comparison)	2019	https://github.com/henryzhao5852/AutoEM
Brunner e Stockinger, 2020	Entity Matching Transformer	Entity Matching (Learned Comparison)	2020	https://github.com/brunnurs/entity-matching-transformer
Pit-Claudel *et al.*, 2016	dBOOST	Outlier Detection (Statistic Based)	2016	https://github.com/cpitclaudel/dBoost
Y. Liu *et al.*, 2020	MO-GAAL	Outlier Detection (Model Based)	2019	https://github.com/leibinghe/GAAL-based-outlier-detection
W. Jiang *et al.*, 2023	READ	Outlier Detection (Model Based)	2023	https://github.com/lygjwy/READ
Berti-Equille, 2019	Learn2Clean	Outlier Detection / Imputation / Entity Matching	2019	https://github.com/LaureBerti/Learn2Clean
Kolb *et al.*, 2012	Dedoop	Entity Matching	2012	https://dbs.uni-leipzig.de/research/projects/object-matching-entity-resolution/howto-dedoop
García-Gil *et al.*, 2019	HME-BD	Label Cleaning	2018	https://github.com/djgarcia/NoiseFramework
De *et al.*, 2014	Bayeswipe	Label Cleaning	2014	https://bayeswipe.sushovan.de/
J. Wang *et al.*, 2014	SampleClean	Feature Cleaning / Outlier Detection / Entity Matching	2014	https://github.com/sjyk/sampleclean

A.2 Ferramentas Complementares de Abedjan *et al.* (2016)

A revisão 1 também faz referência a outros estudos secundários, como o artigo Abedjan *et al.*, 2016 que cita algumas ferramentas conhecidas na área de dados para o processo de data cleaning. Essas ferramentas estão listadas na Tabela A.2.

Ferramenta	Descrição	Atividade de Data Cleaning	Site Oficial
dBoost	Detecta outliers com base em histogramas, distribuições Gaussianas e GMM	Outlier Detection	https://github.com/cpitclaudel/dBoost
OpenRefine	Detecta e corrige padrões sintáticos via faceting, clustering e GREL	Feature Cleaning (Model Based)	https://openrefine.org/
Trifacta	Aplica transformações sintáticas, análise de frequência e verificação de tipo	Feature Cleaning (Model Based)	https://www.alteryx.com/products/designer-cloud
Pentaho	Aplica regras e transformações manuais via workflows ETL	Feature Cleaning (Rule Based)	https://pentaho.com/products/pentaho-data-integration
Knime	Constrói workflows de transformação e validação manual	Feature Cleaning (Rule Based)	https://www.knime.com/
Tamr	Identifica duplicatas com aprendizado de máquina e realiza resolução de entidades	Entity Matching	https://www.tamr.com/

Tabela A.2: *Ferramentas de Data Cleaning citadas no artigo Abedjan et al., 2016*

A.3 Métricas de Validação por Solução

A Tabela A.3 compila, para cada ferramenta catalogada, as métricas de avaliação utilizadas pelos respectivos autores. Observa-se o predomínio de Precision, Recall e F1-Score em feature cleaning, Accuracy em label cleaning, e métricas específicas como AUROC, PRAUC e Runtime em contextos pontuais. As descrições didáticas dessas métricas estão reunidas no Anexo B.

Tabela A.3: *Métricas de Validação utilizadas nas soluções de Data Cleaning*

Artigo	Solução / Framework	Métricas de Avaliação
Rekatsinas *et al.*, 2017	HoloClean	Precision, Recall, F1-Score, Runtime
Visengeriyeva e Abedjan, 2018	DetectEr	Precision, Recall, F1-Score

Artigo	Solução / Framework	Métricas de Avaliação
Mahdavi *et al.*, 2019	RAHA	Precision, Recall, F1-Score, Runtime
Mahdavi *et al.*, 2019	BARAN	Precision, Recall, F1-Score, Runtime
Mahdavi *et al.*, 2019	RAHA	Precision, Recall, F1-Score, Runtime
Neutatz *et al.*, 2019	ED2	Precision, Recall, F1-Score
Visengeriyeva, Akbik *et al.*, 2016	DataGuards	Precision, Recall, F1-Score
R. Wang *et al.*, 2023	Sudowoodo	Precision, Recall, F1-Score
Narayan *et al.*, 2022	-	F1-Score, Accuracy
Nashaat *et al.*, 2021	TabReformer	Precision, Recall, F1-Score
Mauritz *et al.*, 2021	autoencoder-pdb-cleaning	Accuracy, F1-Score
Z. Liu *et al.*, 2022	-	AUROC, Accuracy, F1-Score
Karlaš *et al.*, 2020	CPClean	Accuracy
Krishnan *et al.*, 2016	ActiveClean	Accuracy
Rottmann e 2023, 2023	Automatic-Label-Error-Detection	Precision, Recall, F1-Score
Teso *et al.*, 2021	Cincer	Precision, F1-Score
Atkinson e Metsis, 2021	Tsar	Accuracy, Precision
Bernhardt *et al.*, 2022	InnerEye-DataQuality	Accuracy
Northcutt *et al.*, 2021	Cleanlab	Accuracy, Precision, Recall, F1-Score
Hendrycks e Gimpel, 2017	-	AUROC, AUPR
Yu e Aizawa, 2020	-	Accuracy
Jinchi Huang *et al.*, 2019	O2U-Net	Precision
Smyth *et al.*, 2019	Training-ValueNet	Accuracy, Precision, Recall
Suzuki *et al.*, 2021		Accuracy

Artigo	**Solução / Framework**	**Métricas de Avaliação**
Yinjun Wu *et al.*, 2021	Chef	F1-Score, Runtime
Hara *et al.*, 2019	-	Kendall's tau, Jaccard index
K.-H. Lee *et al.*, 2018	CleanNet	Accuracy
Y. Li *et al.*, 2020	Ditto	F1 Score, Training Time
Jiacheng Huang *et al.*, 2023	DAEM	Precision, Recall, F1-Score
Jin *et al.*, 2021	AdaMEL	PRAUC
Fu *et al.*, 2020	EntityMatcher	Precision, Recall, F1-Score
Mudgal *et al.*, 2018	DeepMatcher	Precision, Recall, F1-Score
Kasai *et al.*, 2019	DeepMatcher	Precision, Recall, F1-Score
C. Zhao e He, 2019	AutoEM	Mean Reciprocal Rank (MRR), Precision, Recall
Brunner e Stockinger, 2020	Entity Matching Transformer	F1-Score
Pit-Claudel *et al.*, 2016	dBOOST	Accuracy, Runtime
Y. Liu *et al.*, 2020	MO-GAAL	ROC curve, AUC
W. Jiang *et al.*, 2023	READ	AUROC
Berti-Equille, 2019	Learn2Clean	MSE, Accuracy, Silhouette
García-Gil *et al.*, 2019	HME-BD	Accuracy
De *et al.*, 2014	Bayeswipe	Precision, Recall

Anexo B

Métricas de Avaliação

Este anexo apresenta, em caráter didático, as principais métricas utilizadas para avaliar técnicas de limpeza de dados e de aprendizado de máquina referenciadas ao longo da tese. A referência a qualquer uma delas no texto principal pode ser consultada aqui em busca de detalhe adicional.

B.1 Accuracy

A acurácia é uma das métricas mais simples e intuitivas para avaliação de modelos de classificação. Ela mede a proporção de previsões corretas em relação ao total de exemplos avaliados. Ela é calculada pela razão entre os verdadeiros positivos e verdadeiros negativos somados, e o total de exemplos, conforme a Equação B.1:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \tag{B.1}$$

Embora seja uma métrica amplamente utilizada por sua simplicidade, a acurácia pode ser enganosa em cenários com classes desbalanceadas, como é comum em tarefas de data cleaning, em que a maioria dos registros é correta e apenas uma pequena fração contém erros.

B.2 Precision, Recall e F1-Score

Em modelos de machine learning métricas como *Precision*, *Recall* e *F1-Score* são utilizadas por sua capacidade de capturar diferentes aspectos da qualidade das predições. Essas métricas são especialmente importantes em tarefas de classificação binária, como a distinção entre registros corretos e registros com erro em um processo de *data cleaning*.

A métrica **Precision** (precisão) é definida como a razão entre os verdadeiros positivos (*True Positives* — TP) e o total de instâncias classificadas como positivas (TP + FP) Géron, 2019, conforme a Equação B.2:

$$\text{Precision} = \frac{TP}{TP + FP} \tag{B.2}$$

A precisão então nos indica do total de registros classificados como erros quantos de fato são erros reais.

A métrica **Recall** (sensibilidade) mede a proporção de instâncias realmente positivas que foram corretamente identificadas Géron, 2019, como expressa na Equação B.3:

$$\text{Recall} = \frac{TP}{TP + FN} \tag{B.3}$$

O Recall, por entanto, nos indica do horizonte de erros que ocorreram de fato, quantos foram corretamente identificados pelo nosso modelo.

A **F1-Score** é a média harmônica entre precision e recall Géron, 2019, e busca capturar um balanço entre essas duas dimensões. Essa métrica é importante em cenários com dados desbalanceados, como é comum em processos de detecção de erros, onde a maioria dos dados está correta e apenas uma fração contém inconsistências. Sua fórmula está apresentada na Equação B.4:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \tag{B.4}$$

B.3 Curva ROC e AUROC

A curva ROC é outra ferramenta comum utilizada com classificadores binários. A curva ROC plota a taxa de verdadeiros positivos (true positive rate, outro nome para recall) em relação à taxa de falsos positivos (false positive rate – FPR). A FPR é a razão entre as instâncias negativas que foram classificadas incorretamente como positivas. Ela é igual a 1 menos a taxa de verdadeiros negativos (true negative rate – TNR), que corresponde à razão de instâncias negativas que foram corretamente classificadas como negativas. A TNR também é chamada de especificidade (specificity). Assim, a curva ROC plota a sensibilidade (recall) contra 1 – especificidade.

Uma forma de comparar classificadores é medir a área sob a curva (AUROC). Um classificador perfeito terá uma AUROC igual a 1, enquanto um classificador puramente aleatório terá uma ROC AUC igual a 0,5.

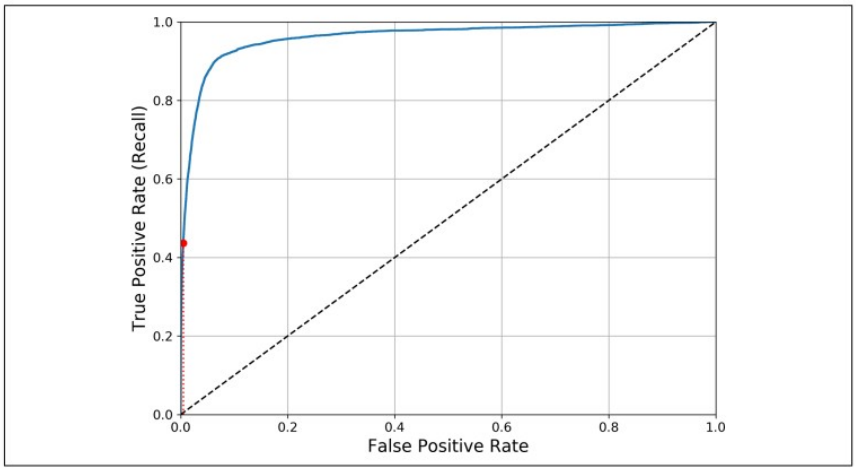


Figura B.1: *Exemplo de Curva ROC Géron, 2019.*

B.4 PRAUC

A PRAUC é a Área sob a Curva Precision-Recall (Precision-Recall Area Under the Curve), uma métrica que resume o desempenho de um modelo classificatório ao longo de diferentes limiares de decisão, considerando duas dimensões: Precision e Recall. A curva Precision-Recall (PR) plota a precision (precisão) no eixo Y contra o recall (revocação/-sensibilidade) no eixo X, para vários limiares de classificação.

A PRAUC representa uma média ponderada do desempenho do modelo ao longo de todos os possíveis limiares. Quanto mais próxima de 1, melhor é o desempenho do modelo (alta precision e alta recall em vários pontos). Uma PRAUC baixa indica que o modelo erra muito ou perde muitos exemplos positivos.

Referências

[Abedjan *et al.* 2016] Ziawasch Abedjan *et al.* "Detecting data errors: where are we and what needs to be done?" *Proceedings of the VLDB Endowment* 9.12 (2016), pp. 993–1004 (citado nas pgs. viii, 53, 56, 57).

[Akella e Narayanam 2025a] Ashlesha Akella e Krishnasuri Narayanam. "Codegenwrangler: data wrangling task automation using code-generating models". In: *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL) — Industry Track*. Vol. 39. Association for the Advancement of Artificial Intelligence, 2025, pp. 29616–29618. DOI: 10.1609/aaai.v39i28.35344. URL: https://www.scopus.com/pages/publications/105003908496?origin=resultslist (citado nas pgs. 26, 29, 38, 44, 46, 47).

[Akella e Narayanam 2025b] Ashlesha Akella e Krishnasuri Narayanam. "Data wrangling task automation using code-generating language models". In: *The Thirty-Ninth AAAI Conference on Artificial Intelligence (AAAI-25)*. Vol. 39. Association for the Advancement of Artificial Intelligence, 2025, pp. 29616–29618. DOI: 10.1609/aaai.v39i28.35344. URL: https://www.scopus.com/pages/publications/105003908496?origin=resultslist (citado na pg. 26).

[Arora e Dell 2024] Abhishek Arora e Melissa Dell. "Linktransformer: a unified package for record linkage with transformer language models". In: *arXiv preprint arXiv:2309.00789 (v2)*. ASSOC COMPUTATIONAL LINGUISTICS-ACL, 2024, pp. 221–231 (citado nas pgs. 27, 35).

[Atkinson e Metsis 2021] Gentry Atkinson e Vangelis Metsis. "TSAR: a time series assisted relabeling tool for reducing label noise". In: *Proceedings of the 14th PErvasive Technologies Related to Assistive Environments Conference (PETRA '21)*. New York, NY, USA: Association for Computing Machinery, 2021, pp. 203–209. DOI: 10.1145/3453892.3461321. URL: https://github.com/imics-lab/TSAR (citado nas pgs. 54, 58).

[Bernhardt *et al.* 2022] Mélanie Bernhardt *et al.* "Active label cleaning for improved dataset quality under resource constraints". *Nature Communications* 13.1 (2022), p. 1161. doi: 10.1038/s41467-022-28818-3. url: https://github.com/microsoft/InnerEye-DeepLearning/tree/1606729c7a16e1bfeb269694314212b6e2737939/InnerEye-DataQuality (citado nas pgs. 54, 58).

[Berti-Equille 2019] Laure Berti-Equille. "Learn2Clean: optimizing the sequence of tasks for web data preparation". In: *The World Wide Web Conference (WWW '19)*. New York, NY, USA: Association for Computing Machinery, 2019, pp. 2580–2586. doi: 10.1145/3308558.3313602. url: https://github.com/LaureBerti/Learn2Clean (citado nas pgs. 56, 59).

[Biester *et al.* 2025] Fabian Biester, Mohamed Abdelaal e Daniel Del Gaudio. "Llm-clean: context-aware tabular data cleaning via llm-generated ofds". In: *ADBIS 2024 (Communications in Computer and Information Science, vol. 2186, Springer)*. Vol. 2186. SPRINGER INTERNATIONAL PUBLISHING AG, 2025, pp. 68–78. doi: 10.1007/978-3-031-70421-5_7 (citado nas pgs. 27, 36).

[Biradar *et al.* 2024] Divya Biradar, Rahul Dattangire, Ruchika Vaidya e Naga-SuryaShivani Inti. "Improving the quality of diabetic data with large language model-driven cleaning techniques". In: *2024 IEEE International Conference on Intelligent Systems and Advanced Applications (ICISAA)*. IEEE, 2024, pp. 1–6. doi: 10.1109/ICISAA62385.2024.10828925 (citado nas pgs. 26, 32).

[Bolding *et al.* 2023] Quinten Bolding, Baohao Liao, Brandon James Denis e Christof Luo Junand Monz. "Ask language model to clean your noisy translation data". In: *Findings of the Association for Computational Linguistics: EMNLP 2023*. ASSOC COMPUTATIONAL LINGUISTICS-ACL, 2023, pp. 3215–3236 (citado nas pgs. 26, 32, 33).

[Brunner e Stockinger 2020] Ursin Brunner e Kurt Stockinger. "Entity matching with transformer architectures – a step forward in data integration". In: *Proceedings of the 23rd International Conference on Extending Database Technology (EDBT 2020)*. OpenProceedings.org, 2020, pp. 463–473. doi: 10.5441/002/edbt.2020.58. url: https://github.com/brunnurs/entity-matching-transformer (citado nas pgs. 56, 59).

[Ceker *et al.* 2026] Hayreddin Ceker *et al.* "Using brand knowledge bases and llm agents to enhance e-commerce retailers' catalog quality". In: *Proceedings of the Nineteenth ACM International Conference on Web Search and Data Mining (WSDM '26)*. New York, NY, USA: Association for Computing Machinery, 2026, pp. 1343–1344. doi: 10.1145/3773966.3784969. url: https://doi.org/10.1145/3773966.3784969 (citado nas pgs. 27, 32, 34).

[Chen *et al.* 2025] Wei-Hao Chen, Weixi Tong, Amanda Case e Tianyi Zhang. "Dango: a mixed-initiative data wrangling system using large language model". In: *CHI '25: CHI Conference on Human Factors in Computing Systems*. ASSOC COMPUTING MACHINERY, 2025. DOI: 10.1145/3706598.3714135 (citado nas pgs. 26, 30, 37).

[Chessa e Griffioen 2019] Antonio G. Chessa e Robert Griffioen. "Comparing price indices of clothing and footwear for scanner data and web scraped data". *Economie et Statistique / Economics and Statistics* 509 (2019), pp. 49–68. DOI: 10.24187/ecostat.2019.509.1984 (citado na pg. 1).

[Choi *et al.* 2024] Juhwan Choi, Jungmin Yun, Kyohoon Jin e YoungBin Kim. "Multi-news+: cost-efficient dataset cleansing via llm-based data annotation". In: *arXiv preprint (2409.06924v3)*. ASSOC COMPUTATIONAL LINGUISTICS-ACL, 2024, pp. 15–29 (citado nas pgs. 27, 30, 32, 33, 36, 46).

[Côté *et al.* 2024] Pierre-Olivier Côté, Amin Nikanjam, Nafisa Ahmed, Dmytro Humeniuk e Foutse Khomh. "Data cleaning and machine learning: a systematic literature review". *Automated Software Engineering* 31.2 (2024), p. 54 (citado nas pgs. v, 12, 13, 16, 17, 34, 53).

[Daas *et al.* 2015] Piet J. H. Daas, Marco J. H. Puts, Bart Buelens e Paul A. M. van den Hurk. "Big data as a source for official statistics". *Journal of Official Statistics* 31.2 (2015), pp. 249–262. DOI: 10.1515/jos-2015-0016 (citado nas pgs. 1, 7–9).

[Dawale *et al.* 2025] Shreya Dawale *et al.* "Integration of machine learning and large language models for scalable data cleaning". In: *Proceedings of the 8th International Conference on Computing Methodologies and Communication (ICCMC-2025)*. Institute of Electrical e Electronics Engineers Inc., 2025, pp. 1295–1301. DOI: 10.1109/ICCMC65190.2025.11140947. URL: https://www.scopus.com/pages/publications/105016904055?origin=resultslist (citado na pg. 26).

[De *et al.* 2014] Sushovan De, Yuheng Hu, Yi Chen e Subbarao Kambhampati. "BayesWipe: a multimodal system for data cleaning and consistent query answering on structured bigdata". In: *2014 IEEE International Conference on Big Data (Big Data)*. IEEE, 2014, pp. 15–24. DOI: 10.1109/BigData.2014.7004207. URL: https://bayeswipe.sushovan.de/ (citado nas pgs. 56, 59).

[Dingfelder e Riess 2026] Philipp Dingfelder e Christian Riess. "Sure! here's a short and concise title for your paper: contamination in generated text detection benchmarks". In: *CSCML 2025 (LNCS vol. 16244, Springer)*. Vol. 16244. SPRINGER INTERNATIONAL PUBLISHING AG, 2026, pp. 250–262. DOI: 10.1007/978-3-032-10759-6_16 (citado na pg. 27).

[Fan *et al.* 2026] Shuhuan Fan, Jingcong Liu, Zhenyuan Luo, Sidun Zhou e Yuanfeng Song. "A task-driven interpretable data cleaning framework based on llm". In: *Artificial Intelligence and Human-Computer Interaction (AIHCI), IOS Press / Frontiers in AI and Applications (FAIA vol. 251753)*. Vol. 419. IOS Press BV, 2026, pp. 96–102. doi: 10.3233/FAIA251753. url: https://www.scopus.com/pages/publications/105032087146?origin=resultslist (citado nas pgs. 25, 30).

[Fathollahzadeh *et al.* 2025a] Saeed Fathollahzadeh, Essam Mansour e Matthias Boehm. "Catdb: data-catalog-guided, llm-based generation of data-centric ml pipelines". *Proc. VLDB Endow.* 18 (2025), pp. 2639–2652. doi: 10.14778/3742728.3742754. url: https://doi.org/10.14778/3742728.3742754 (citado nas pgs. 26, 29, 33, 36–39, 46).

[Fathollahzadeh *et al.* 2025b] Saeed Fathollahzadeh, Essam Mansour e Matthias Boehm. "Demonstrating catdb: llm-based generation of data-centric ml pipelines". In: *Companion of the 2025 International Conference on Management of Data (SIGMOD-Companion'25)*. Association for Computing Machinery, 2025, pp. 87–90. doi: 10.1145/3722212.3725097. url: https://www.scopus.com/pages/publications/105010222256?origin=resultslist (citado na pg. 26).

[Fu *et al.* 2020] Cheng Fu, Xianpei Han, Jiaming He e Le Sun. "Hierarchical matching network for heterogeneous entity resolution". In: *Proceedings of the 29th International Joint Conference on Artificial Intelligence (IJCAI 2020)*. International Joint Conferences on Artificial Intelligence Organization, 2020, pp. 3665–3671. doi: 10.24963/ijcai.2020/507. url: https://github.com/icip-cas/EntityMatcher (citado nas pgs. 55, 59).

[Fundação Seade 2026a] Fundação Seade. *Fundação Sistema Estadual de Análise de Dados - Seade*. https://www.seade.gov.br/institucional/fundacao-seade/. Acesso em: 25 jan. 2026. Fundação Seade, 2026 (citado nas pgs. 1, 6, 7).

[Fundação Seade 2026b] Fundação Seade. *Produtos*. https://www.seade.gov.br/produtos/. Acesso em: 25 jan. 2026. Fundação Sistema Estadual de Análise de Dados, 2026 (citado nas pgs. 1, 7).

[García-Gil *et al.* 2019] Diego García-Gil, Julián Luengo, Salvador García e Francisco Herrera. "Enabling smart data: noise filtering in big data classification". *Information Sciences* 479 (2019), pp. 135–152. doi: 10.1016/j.ins.2018.12.002. url: https://github.com/djgarcia/NoiseFramework (citado nas pgs. 56, 59).

[Ge *et al.* 2025] Yuhang Ge *et al.* "Knowtrans: boosting transferability of data preparation llms via knowledge augmentation". In: *2025 IEEE 41st International Conference on Data Engineering (ICDE)*. IEEE Computer Society, 2025, pp. 2852–2866. doi: 10.1109/ICDE65448.2025.00214. url: https://www.scopus.com/pages/publications/105015418240?origin=resultslist (citado nas pgs. 27, 30).

[Géron 2019] Aurélien Géron. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*. 2nd. O'Reilly Media, Inc., 2019 (citado nas pgs. 61–63).

[Goedegebuure *et al.* 2025] Abel Goedegebuure *et al.* "Data mesh: a systematic gray literature review". *ACM Computing Surveys* 57.1 (2025), Article 11. DOI: 10.1145/3687301 (citado nas pgs. v, 9–11).

[Han *et al.* 2026] Ziyan Han *et al.* "Bclean+: a bayesian data cleaning system with automated prior generation". *IEEE TRANSACTIONS ON KNOWLEDGE AND DATA ENGINEERING* 38 (2026), pp. 2165–2182. DOI: 10.1109/TKDE.2026.3656941 (citado nas pgs. 26, 30, 31, 33–39, 44, 46, 47, 49, 50).

[Hara *et al.* 2019] Satoshi Hara, Atsushi Nitanda e Takanori Maehara. "Data cleansing for models trained with SGD". In: *Advances in Neural Information Processing Systems 32 (NeurIPS 2019)*. Curran Associates, Inc., 2019, pp. 4215–4224. URL: https://github.com/sato9hara/sgd-influence (citado nas pgs. 55, 59).

[Hendrycks e Gimpel 2017] Dan Hendrycks e Kevin Gimpel. "A baseline for detecting misclassified and out-of-distribution examples in neural networks". In: *5th International Conference on Learning Representations (ICLR 2017)*. 2017. URL: https://github.com/hendrycks/error-detection (citado nas pgs. 55, 58).

[Hosseinzadeh *et al.* 2023] Mehdi Hosseinzadeh *et al.* "Data cleansing mechanisms and approaches for big data analytics: a systematic study". *Journal of Ambient Intelligence and Humanized Computing* (2023), pp. 1–13 (citado nas pgs. v, 12, 13, 16, 53).

[Hou *et al.* 2025] Yu Hou, Jeffrey R. Bishop, Hongfang Liu e Rui Zhang. "Improving dietary supplement information retrieval: development of a retrieval-augmented generation system with large language models". *Journal of Medical Internet Research* 27 (2025). DOI: 10.2196/67677. URL: https://www.scopus.com/pages/publications/105000553374?origin=resultslist (citado nas pgs. 26, 30, 32, 34).

[Jiacheng Huang *et al.* 2023] Jiacheng Huang, Wei Hu, Zhifeng Bao, Qijin Chen e Yuzhong Qu. "Deep entity matching with adversarial active learning". *The VLDB Journal* 32.1 (2023), pp. 229–255. DOI: 10.1007/s00778-022-00745-1. URL: https://github.com/nju-websoft/DAEM (citado nas pgs. 55, 59).

[Jinchi Huang *et al.* 2019] Jinchi Huang, Lie Qu, Rongfei Jia e Binqiang Zhao. "O2U-Net: a simple noisy label detection approach for deep neural networks". In: *2019 IEEE/CVF International Conference on Computer Vision (ICCV)*. IEEE, 2019, pp. 3325–3333. DOI: 10.1109/ICCV.2019.00342. URL: https://github.com/hjimce/O2U-Net (citado nas pgs. 55, 58).

[IBGE, Coordenação de Cadastros e Classificações 2024] IBGE, Coordenação de Cadastros e Classificações. *Classificação de informações estatísticas: versão 1.0*. Acesso em: 25 jan. 2026. Rio de Janeiro: IBGE, 2024. ISBN: 9788524046100. URL: https://biblioteca.ibge.gov.br/visualizacao/livros/liv102082.pdf (citado nas pgs. 5, 6).

[Ilhanli *et al.* 2025] Nevruz Ilhanli, Esra Tokur Sonuvar e Kemal Hakan Gulkesen. "Using large language models for data cleaning: an evaluation of chatgpt-4o's performance". In: *Global Healthcare Transformation in the Era of Artificial Intelligence and Informatics (Studies in Health Technology and Informatics), IOS Press*. Vol. 328. IOS Press BV, 2025, pp. 121–125. DOI: 10.3233/SHTI250685. URL: https://www.scopus.com/pages/publications/105010177210?origin=resultslist (citado nas pgs. 27, 32).

[Jain *et al.* 2024] Naman Jain *et al.* "Llm-assisted code cleaning for training accurate code generators". In: *arXiv:2311.14904 (preprint)*. International Conference on Learning Representations, ICLR, 2024. URL: https://www.scopus.com/pages/publications/85200465118?origin=resultslist (citado nas pgs. 27, 32, 34).

[W. Jiang *et al.* 2023] Wenyu Jiang *et al.* "READ: aggregating reconstruction error into out-of-distribution detection". In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 37. 12. AAAI Press, 2023, pp. 14910–14918. DOI: 10.1609/aaai.v37i12.26741. URL: https://github.com/lygjwy/READ (citado nas pgs. 56, 59).

[Y. Jiang *et al.* 2026] Yunxuan Jiang, Silan Hu, Xiaoning Wang e Xiangyu Zhang Yuanyuan andChang. "Vdsagents: a pcs-guided multi-agent system for veridical data science automation". *STAT* 15 (2026). DOI: 10.1002/sta4.70126 (citado nas pgs. 27, 30, 31, 36, 38).

[Jin *et al.* 2021] Di Jin, Bunyamin Sisman, Hao Wei, Xin Luna Dong e Danai Koutra. "Deep transfer learning for multi-source entity linkage via domain adaptation". *Proceedings of the VLDB Endowment* 15.3 (2021), pp. 465–477. DOI: 10.14778/3494124.3494131. URL: https://github.com/DerekDiJin/AdaMEL-supplementary (citado nas pgs. 55, 59).

[Karlaš *et al.* 2020] Bojan Karlaš *et al.* "Nearest neighbor classifiers over incomplete information: from certain answers to certain predictions". *Proceedings of the VLDB Endowment* 14.3 (2020), pp. 255–267. DOI: 10.14778/3430915.3430917. URL: https://github.com/chu-data-lab/CPClean (citado nas pgs. 54, 58).

[Kasai *et al.* 2019] Jungo Kasai, Kun Qian, Sairam Gurajada, Yunyao Li e Lucian Popa. "Low-resource deep entity resolution with transfer and active learning". In: *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL 2019)*. Florence, Italy: Association for Computational Linguistics, 2019, pp. 5851–5861. DOI: 10.18653/v1/P19-1586. URL: https://github.com/anhaidgroup/deepmatcher (citado nas pgs. 55, 59).

[Kitchin 2015] Rob Kitchin. “The opportunities, challenges and risks of big data for official statistics”. *Statistical Journal of the IAOS* 31.3 (2015), pp. 471–481. doi: 10.3233/SJI-150906 (citado nas pgs. 1, 7, 8).

[Kolb *et al.* 2012] Lars Kolb, Andreas Thor e Erhard Rahm. “Dedoop: efficient deduplication with Hadoop”. *Proceedings of the VLDB Endowment* 5.12 (2012), pp. 1878–1881. doi: 10.14778/2367502.2367527. url: https://dbs.uni-leipzig.de/research/projects/object-matching-entity-resolution/howto-dedoop (citado na pg. 56).

[Krishnan *et al.* 2016] Sanjay Krishnan, Jiannan Wang, Eugene Wu, Michael J. Franklin e Ken Goldberg. “ActiveClean: interactive data cleaning for statistical modeling”. *Proceedings of the VLDB Endowment* 9.12 (2016), pp. 948–959. doi: 10.14778/2994509.2994514. url: https://activeclean.github.io/ (citado nas pgs. 54, 58).

[C.-T. Lee *et al.* 2025] Cho-Ting Lee *et al.* “Can an llm find its way around a spreadsheet?” In: *2025 IEEE/ACM 47th International Conference on Software Engineering (ICSE)*. IEEE, 2025, pp. 294–306. doi: 10.1109/ICSE55347.2025.00101 (citado nas pgs. 26, 30, 32).

[K.-H. Lee *et al.* 2018] Kuang-Huei Lee, Xiaodong He, Lei Zhang e Linjun Yang. “CleanNet: transfer learning for scalable image classifier training with label noise”. In: *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, 2018, pp. 5447–5456. doi: 10.1109/CVPR.2018.00571. url: https://kuanghuei.github.io/CleanNetProject/ (citado nas pgs. 55, 59).

[L. Li *et al.* 2025] Lan Li, Liri Fang, Bertram Ludäscher e Vetle I. Torvik. “Autodcworkflow: llm-based data cleaning workflow auto-generation and benchmark”. In: *Findings of the Association for Computational Linguistics: EMNLP 2025*. Association for Computational Linguistics (ACL), 2025, pp. 7766–7780. doi: 10.18653/v1/2025.findings-emnlp.410. url: https://www.scopus.com/pages/publications/105028973173?origin=resultslist (citado nas pgs. 26, 29, 30, 32, 37–39, 47).

[X. Li e Döhmen 2024] Xue Li e Till Döhmen. “Towards efficient data wrangling with llms using code generation”. In: *Proceedings of the Seventh International Workshop on Exploiting Artificial Intelligence Techniques for Data Management (aiDM ’24)*. New York, NY, USA: Association for Computing Machinery, 2024, pp. 62–66. doi: 10.1145/3650203.3663334. url: https://doi.org/10.1145/3650203.3663334 (citado na pg. 27).

[Y. Li *et al.* 2020] Yuliang Li, Jinfeng Li, Yoshihiko Suhara, AnHai Doan e Wang-Chiew Tan. “Deep entity matching with pre-trained language models”. *Proceedings of the VLDB Endowment* 14.1 (2020), pp. 50–60. doi: 10.14778/3421424.3421431. url: https://github.com/megagonlabs/ditto (citado nas pgs. 55, 59).

[Liang *et al.* 2025] Zheng Liang *et al.* "Tailoring the shapley value for in-context example selection towards data wrangling". In: *2025 IEEE 41st International Conference on Data Engineering (ICDE)*. IEEE Computer Society, 2025, pp. 2281–2294. doi: 10.1109/ICDE65448.2025.00173. url: https://www.scopus.com/pages/publications/105015496147?origin=resultslist (citado nas pgs. 27, 29).

[L. Liu, Hasegawa, Sampat, Bahrami *et al.* 2025] Lei Liu, So Hasegawa, Shailaja Keyur Sampat, Wei-Peng Bahrami Mehdiand Chen *et al.* "Autodw-ts: automated data wrangling for time-series data". In: *CIKM '25: Proceedings of the 34th ACM International Conference on Information and Knowledge Management*. ASSOC COMPUTING MACHINERY, 2025, pp. 5888–5897. doi: 10.1145/3746252.3761524 (citado nas pgs. 26, 34, 35).

[L. Liu, Hasegawa, Sampat, Xenochristou *et al.* 2024] Lei Liu, So Hasegawa, Shailaja Keyur Sampat, Maria Xenochristou *et al.* "Autodw: automatic data wrangling leveraging large language models". In: *ASE '24: 39th IEEE/ACM International Conference on Automated Software Engineering*. Association for Computing Machinery, Inc, 2024, pp. 2041–2052. doi: 10.1145/3691620.3695267. url: https://www.scopus.com/pages/publications/85212411533?origin=resultslist (citado nas pgs. 26, 32, 35, 37).

[Y. Liu *et al.* 2020] Yezheng Liu *et al.* "Generative adversarial active learning for unsupervised outlier detection". *IEEE Transactions on Knowledge and Data Engineering* 32.8 (2020), pp. 1517–1528. doi: 10.1109/TKDE.2019.2905606. url: https://github.com/leibinghe/GAAL-based-outlier-detection (citado nas pgs. 56, 59).

[Z. Liu *et al.* 2022] Zifan Liu, Zhechun Zhou e Theodoros Rekatsinas. "Picket: guarding against corrupted data in tabular data during learning and inference". *The VLDB Journal* 31.5 (2022), pp. 927–955. doi: 10.1007/s00778-021-00699-w. url: https://github.com/sis-ethz/Picket (citado nas pgs. 54, 58).

[Luo *et al.* 2025] Gang Luo, Julien Han, Hayreddin Ceker e Karim Bouyarmane. "Using large language models to improve product information in e-commerce catalogs". In: *CIKM '25: 34th ACM International Conference on Information and Knowledge Management*. ASSOC COMPUTING MACHINERY, 2025, pp. 6873–6874. doi: 10.1145/3746252.3761437 (citado nas pgs. 27, 32).

[MacFeely 2020] Steve MacFeely. "Measuring the Sustainable Development Goal Indicators: an unprecedented statistical challenge". *Journal of Official Statistics* 36.2 (2020), pp. 361–378. doi: 10.2478/jos-2020-0019 (citado nas pgs. 1, 5, 7, 8).

[Machado *et al.* 2022] Inês Araújo Machado, Carlos Costa e Maribel Yasmina Santos. "Data mesh: concepts and principles of a paradigm shift in data architectures". *Procedia Computer Science* 196 (2022), pp. 263–271. doi: 10.1016/j.procs.2021.12.013 (citado na pg. 9).

[Mahdavi *et al.* 2019] Mohammad Mahdavi *et al.* "Raha: a configuration-free error detection system". In: *Proceedings of the 2019 International Conference on Management of Data (SIGMOD '19)*. New York, NY, USA: Association for Computing Machinery, 2019, pp. 865–882. DOI: 10.1145/3299869.3324956. URL: https://github.com/BigDaMa/raha (citado nas pgs. 37, 50, 53, 54, 58).

[Mauritz *et al.* 2021] R. R. Mauritz, F. P. J. Nijweide, J. Goseling e M. van Keulen. *A Probabilistic Database Approach to Autoencoder-based Data Cleaning*. Preprint. 2021. arXiv: 2106.09764. URL: https://github.com/fpjnijweide/autoencoder-pdb-cleaning (citado nas pgs. 54, 58).

[McCarthy 2026] Erin A. McCarthy. "Are we there yet? notes towards benchmarking an experimental ai-assisted workflow for humanities data cleaning and reconciliation". *JOURNAL OF OPEN HUMANITIES DATA* 12 (2026). DOI: 10.5334/johd.490 (citado nas pgs. 26, 32, 35).

[Meguellati *et al.* 2025] Elyas Meguellati, Nardiena Pratama, Shazia Sadiq e Gianluca Demartini. "Are large language models good data preprocessors?" In: *WWW '25: Companion Proceedings of the ACM Web Conference 2025*. Association for Computing Machinery, Inc, 2025, pp. 2129–2132. DOI: 10.1145/3701716.3717568. URL: https://www.scopus.com/pages/publications/105009232010?origin=resultslist (citado nas pgs. 25, 32).

[Mehra e Rezig 2024] Pavitra Mehra e El Kindi Rezig. "Leveraging structured and unstructured data for tabular data cleaning". In: *2024 IEEE International Conference on Big Data (Big Data)*. Institute of Electrical e Electronics Engineers Inc., 2024, pp. 5765–5768. DOI: 10.1109/BigData62323.2024.10825257. URL: https://www.scopus.com/pages/publications/85218073057?origin=resultslist (citado nas pgs. 27, 30, 33, 39, 47).

[Mondal *et al.* 2024] Manuel Mondal, Julien Audiffren, Ljiljana Dolamic, Gérôme Bovet e Philippe Cudré-Mauroux. "Cleaning semi-structured errors in open data using large language models". In: *2024 11th IEEE Swiss Conference on Data Science (SDS)*. IEEE, 2024, pp. 258–261. DOI: 10.1109/SDS60720.2024.00047 (citado nas pgs. 26, 32, 34, 36, 39).

[Mudgal *et al.* 2018] Sidharth Mudgal *et al.* "Deep learning for entity matching: a design space exploration". In: *Proceedings of the 2018 International Conference on Management of Data (SIGMOD '18)*. New York, NY, USA: Association for Computing Machinery, 2018, pp. 19–34. DOI: 10.1145/3183713.3196926. URL: https://github.com/anhaidgroup/deepmatcher (citado nas pgs. 55, 59).

[Naeem *et al.* 2024] Zan Ahmad Naeem, Mohammad Shahmeer Ahmad, Mohamed Eltabakh, Mourad Ouzzani e Nan Tang. "Retclean: retrieval-based data cleaning using llms and data lakes". In: *Proceedings of the VLDB Endowment, Vol. 17, No. 12*. Vol. 17. VLDB Endowment, 2024, pp. 4421–4424. doi: 10.14778/3685800.3685890. url: https://www.scopus.com/pages/publications/85205304772?origin=resultslist (citado nas pgs. 27, 30, 32, 35, 47).

[Narayan *et al.* 2022] Avanika Narayan, Ines Chami, Laurel Orr e Christopher Ré. "Can foundation models wrangle your data?" *Proceedings of the VLDB Endowment* 16.4 (2022), pp. 738–746. doi: 10.14778/3574245.3574258. url: https://github.com/HazyResearch/fm_data_tasks (citado nas pgs. 54, 58).

[Nashaat *et al.* 2021] Mona Nashaat, Aindrila Ghosh, James Miller e Shaikh Quader. "TabReformer: unsupervised representation learning for erroneous data detection". *ACM/IMS Transactions on Data Science* 2.3 (2021), 18:1–18:29. doi: 10.1145/3447541. url: https://github.com/MonaNashaat/TabReformer (citado nas pgs. 54, 58).

[Neutatz *et al.* 2019] Felix Neutatz, Mohammad Mahdavi e Ziawasch Abedjan. *ED2: Two-stage Active Learning for Error Detection – Technical Report*. Preprint. 2019. arXiv: 1908 . 06309. url: https : / / github . com / BigDaMa / ExampleDrivenErrorDetection (citado nas pgs. 54, 58).

[Ni, K. Zhang, Miao, X. Zhao, Yangyang Wu, Y. Wang *et al.* 2025] Wei Ni, Kaihang Zhang, Xiaoye Miao, Xiangyu Zhao, Yangyang Wu, Yaoshu Wang *et al.* "Zeroed: hybrid zero-shot error detection through large language model reasoning". In: *2025 IEEE 41st International Conference on Data Engineering (ICDE)*. IEEE, 2025, pp. 3126–3139. doi: 10.1109/ICDE65448.2025.00234 (citado nas pgs. 28, 29, 31, 33, 37, 49).

[Ni, K. Zhang, Miao, X. Zhao, Yangyang Wu e Yin 2024] Wei Ni, Kaihang Zhang, Xiaoye Miao, Xiangyu Zhao, Yangyang Wu e Jianwei Yin. "Iterclean: an iterative data cleaning framework with large language models". In: *ACM Turing Award Celebration Conference 2024 (ACM-TURC '24)*. ASSOC COMPUTING MACHINERY, 2024, pp. 100–105. doi: 10.1145/3674399.3674436 (citado nas pgs. 27, 29–31, 33, 36, 39, 46, 47).

[Niemir *et al.* 2025] Maciej Niemir, Beata Mrugalska, Dominika Grajewska e Bartlomiej Niton. "Leveraging generative artificial intelligence for enhancing the quality of product data". *LOGFORUM* 21 (2025). doi: 10.17270/J.LOG.001164 (citado nas pgs. 27, 32).

[Northcutt *et al.* 2021] Curtis G. Northcutt, Lu Jiang e Isaac L. Chuang. "Confident learning: estimating uncertainty in dataset labels". *Journal of Artificial Intelligence Research* 70 (2021), pp. 1373–1411. doi: 10.1613/jair.1.12125. url: https://github.com/cleanlab/cleanlab (citado nas pgs. 55, 58).

[Page *et al.* 2021] Matthew J. Page *et al.* "The PRISMA 2020 statement: an updated guideline for reporting systematic reviews". *BMJ* 372 (2021), n71. DOI: 10.1136/bmj.n71 (citado na pg. 23).

[Pang *et al.* 2025] Jinlong Pang *et al.* "Token cleaning: fine-grained data selection for llm supervised fine-tuning". In: *Proceedings of the 42nd International Conference on Machine Learning (ICML), PMLR 267*. Vol. 267. JMLR-JOURNAL MACHINE LEARNING RESEARCH, 2025, pp. 47837–47858 (citado nas pgs. 27, 33, 36).

[Peng *et al.* 2025] Jinfeng Peng *et al.* "Garf+: self-supervised and interpretable data cleaning with sequence generative adversarial networks". *VLDB JOURNAL* 34 (2025). DOI: 10.1007/s00778-025-00941-9 (citado nas pgs. 26, 30, 36).

[Petersen *et al.* 2015] Kai Petersen, Sairam Vakkalanka e Ludwik Kuzniarz. "Guidelines for conducting systematic mapping studies in software engineering: an update". *Information and Software Technology* 64 (2015), pp. 1–18. DOI: 10.1016/j.infsof.2015.03.007 (citado na pg. 19).

[Pit-Claudel *et al.* 2016] Clément Pit-Claudel, Zelda Mariet, Rachael Harding e Sam Madden. *Outlier Detection in Heterogeneous Datasets using Automatic Tuple Expansion*. Rel. técn. MIT-CSAIL-TR-2016-002. Cambridge, MA, USA: MIT Computer Science e Artificial Intelligence Laboratory, 2016. URL: https://github.com/cpitclaudel/dBoost (citado nas pgs. 56, 59).

[Rekatsinas *et al.* 2017] Theodoros Rekatsinas, Xu Chu, Ihab F. Ilyas e Christopher Ré. "Holoclean: holistic data repairs with probabilistic inference". *Proceedings of the VLDB Endowment* 10.11 (2017), pp. 1190–1201. DOI: 10.14778/3137628.3137631. URL: https://github.com/HoloClean/holoclean (citado nas pgs. 37, 50, 53, 57).

[Riza e Suhardi 2022] Kemas Muhammad Irsan Riza e Suhardi. "Big data requirements for estimating official statistics indicator". In: *2022 International Conference on Information Technology Systems and Innovation (ICITSI)*. IEEE, 2022. DOI: 10.1109/ICITSI56531.2022.9971049 (citado nas pgs. 1, 7).

[Rottmann e 2023 2023] Rottmann e Reese 2023. *Automated Detection of Label Errors in Semantic Segmentation Datasets via Deep Learning and Uncertainty Quantification*. 2023. URL: https://github.com/mrcoee/Automatic-Label-Error-Detection (citado nas pgs. 54, 58).

[Saidani e Dumpert 2025] Younes Saidani e Florian Dumpert. "Quality dimensions and quality guidelines for machine learning in official statistics". In: *Foundations and Advances of Machine Learning in Official Statistics*. Ed. por Florian Dumpert. Society, Environment and Statistics. Cham: Springer, 2025, pp. 73–90. DOI: 10.1007/978-3-032-10004-7_4 (citado nas pgs. 2, 8).

[Shaw *et al.* 2025] Ankit Kumar Shaw *et al.* "Cleanmap: distilling multimodal llms for confidence-driven crowdsourced hd map updates". In: *2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*. IEEE, 2025, pp. 3798–3807. DOI: 10.1109/CVPRW67362.2025.00365 (citado nas pgs. 26, 30, 32, 34).

[Shen *et al.* 2025] Xingyu Shen *et al.* "Autoclean: llms can prepare their training corpus". In: *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL) — System Demonstrations*. Vol. 6. Association for Computational Linguistics (ACL), 2025, pp. 85–95. DOI: 10.18653/v1/2025.naacl-demo.9. URL: https://www.scopus.com/pages/publications/105027102410?origin=resultslist (citado nas pgs. 26, 30, 34, 36).

[Smyth *et al.* 2019] Luka Smyth, Dmitry Kangin e Nicolas Pugeault. "Training-ValueNet: data driven label noise cleaning on weakly-supervised web images". In: *2019 Joint IEEE 9th International Conference on Development and Learning and Epigenetic Robotics (ICDL-EpiRob)*. IEEE, 2019, pp. 17–22. DOI: 10.1109/DEVLRN.2019.8850689. URL: https://github.com/lukasmyth96/Training-ValueNet (citado nas pgs. 55, 58).

[Souibgui *et al.* 2019] Manel Souibgui, Faten Atigui, Saloua Zammali, Samira Cherfi e Sadok Ben Yahia. "Data quality in etl process: a preliminary study". *Procedia Computer Science* 159 (2019), pp. 676–687. DOI: 10.1016/j.procs.2019.09.223. URL: https://www.sciencedirect.com/science/article/pii/S1877050919314097 (citado nas pgs. 9, 12).

[Statista 2022] Statista. *Total Data Volume Worldwide (2010–2025) [Statistic No. 871513]*. Acessado em: 18 jan. 2026. Statista. Set. de 2022. URL: https://www.statista.com/statistics/871513/worldwide-data-created/ (citado na pg. 1).

[Struijs *et al.* 2014] Peter Struijs, Barteld Braaksma e Piet J. H. Daas. "Official statistics and big data". *Big Data & Society* 1.1 (2014), pp. 1–6. DOI: 10.1177/2053951714538417 (citado nas pgs. 1, 2, 7, 8).

[Sun *et al.* 2025] Mingzheng Sun *et al.* "Poi extraction from digital city: an engineering exploration with large-language models". *EXPERT SYSTEMS* 42 (2025). DOI: 10.1111/exsy.70001 (citado nas pgs. 27, 32, 34).

[Suzuki *et al.* 2021] Kenji Suzuki, Yoshiyuki Kobayashi e Takuya Narihira. *Data Cleansing for Deep Neural Networks with Storage-efficient Approximation of Influence Functions*. Preprint. 2021. arXiv: 2103.11807. URL: https://github.com/sony/ai-research-code/tree/master/data-cleansing (citado nas pgs. 55, 58).

[Tarrant *et al.* 2025] Georgina Tarrant, Taranpreet Rai, Andrea Wright, Travis Street e Kevin Wells. "Using social media listening to identify the real-world challenges faced by dog owners globally when administering oral medications". *FRONTIERS IN VETERINARY SCIENCE* 12 (2025). doi: 10.3389/fvets.2025.1502236 (citado nas pgs. 27, 32).

[Teso *et al.* 2021] Stefano Teso, Andrea Bontempelli, Fausto Giunchiglia e Andrea Passerini. "Interactive label cleaning with example-based explanations". In: *Advances in Neural Information Processing Systems 34 (NeurIPS 2021)*. Curran Associates, Inc., 2021. url: https://github.com/abonte/cincer (citado nas pgs. 54, 58).

[United Nations 2003] United Nations. *Handbook of Statistical Organization: The Operation and Organization of a Statistical Agency*. 3ª ed. Accessed: 25 Jan. 2026. New York: United Nations, 2003. url: https://unstats.un.org/unsd/dnss/hb/default.aspx (citado nas pgs. 5, 7, 9).

[Visengeriyeva e Abedjan 2018] Larysa Visengeriyeva e Ziawasch Abedjan. "Metadata-driven error detection". In: *Proceedings of the 30th International Conference on Scientific and Statistical Database Management (SSDBM '18)*. New York, NY, USA: Association for Computing Machinery, 2018. doi: 10.1145/3221269.3223028. url: https://doi.org/10.1145/3221269.3223028 (citado nas pgs. 53, 57).

[Visengeriyeva, Akbik *et al.* 2016] Larysa Visengeriyeva, Alan Akbik, Manohar Kaul e Volker Markl. "Improving data quality by leveraging statistical relational learning". In: *Proceedings of the 21st International Conference on Information Quality (ICIQ 2016)*. Ciudad Real, Spain, 2016. url: https://github.com/visenger/DataGuards (citado nas pgs. 54, 58).

[J. Wang *et al.* 2014] Jiannan Wang *et al.* "A sample-and-clean framework for fast and accurate query processing on dirty data". In: *Proceedings of the 2014 ACM SIGMOD International Conference on Management of Data (SIGMOD '14)*. New York, NY, USA: Association for Computing Machinery, 2014, pp. 469–480. doi: 10.1145/2588555.2610505. url: https://github.com/sjyk/sampleclean (citado na pg. 56).

[R. Wang *et al.* 2023] Runhui Wang, Yuliang Li e Jin Wang. "Sudowoodo: contrastive self-supervised learning for multi-purpose data integration and preparation". In: *2023 IEEE 39th International Conference on Data Engineering (ICDE)*. IEEE, 2023, pp. 1502–1515. doi: 10.1109/ICDE55515.2023.00391. url: https://github.com/megagonlabs/sudowoodo (citado nas pgs. 54, 58).

[Z. Wang *et al.* 2026] Zhenxi Wang *et al.* "Multi-agent data cleaning framework of solid-state batteries using large language models". *Green Energy and Intelligent Transportation* (2026), p. 100401. doi: https://doi.org/10.1016/j.geits.2026.100401. url: https://www.sciencedirect.com/science/article/pii/S2773153726000137 (citado nas pgs. 27, 30, 32, 34, 36).

[Wohlin *et al.* 2012] Claes Wohlin *et al. Experimentation in Software Engineering*. Berlin, Heidelberg: Springer, 2012. DOI: 10.1007/978-3-642-29044-2 (citado na pg. 40).

[W. Wu e F. Liu 2025] Wei Wu e Feng Liu. "Zero-shot error detection via performance-guided rule generation with llms". In: *2025 7th International Conference on Robotics, Intelligent Control and Artificial Intelligence (RICAI)*. Institute of Electrical e Electronics Engineers Inc., 2025, pp. 695–701. DOI: 10.1109/RICAI68060.2025.11384953. URL: https://www.scopus.com/pages/publications/105034462122?origin=resultslist (citado nas pgs. 28, 29).

[Yangyang Wu *et al.* 2025] Yangyang Wu *et al.* "A zero-training error correction system with large language models". In: *2025 IEEE 41st International Conference on Data Engineering (ICDE)*. IEEE, 2025, pp. 2949–2962. DOI: 10.1109/ICDE65448.2025.00221 (citado nas pgs. 25, 29–31, 33–39, 44, 46, 47, 49, 50).

[Yinjun Wu *et al.* 2021] Yinjun Wu, James Weimer e Susan B. Davidson. "CHEF: a cheap and fast pipeline for iteratively cleaning label uncertainties". *Proceedings of the VLDB Endowment* 14.11 (2021), pp. 2410–2418. DOI: 10.14778/3476249.3476290. URL: https://github.com/wuyinjun-1993/Chef (citado nas pgs. 55, 59).

[Yan *et al.* 2024] Mengyi Yan, Yaoshu Wang, Yue Wang, Xiaoye Miao e Jianxin Li. "Gidcl: a graph-enhanced interpretable data cleaning framework with large language models". *Proc. ACM Manag. Data* 2 (2024). DOI: 10.1145/3698811. URL: https://doi.org/10.1145/3698811 (citado nas pgs. 26, 36, 37, 39).

[Yang *et al.* 2026] Chen Yang *et al.* "A zero-training data cleaning system with large language models". *IEEE Transactions on Knowledge and Data Engineering* 38 (2026), pp. 2136–2149. DOI: 10.1109/TKDE.2026.3658627 (citado nas pgs. 25, 30, 31, 33, 46).

[Yu e Aizawa 2020] Qing Yu e Kiyoharu Aizawa. "Unknown class label cleaning for learning with open-set noisy labels". In: *2020 IEEE International Conference on Image Processing (ICIP)*. IEEE, 2020, pp. 1731–1735. DOI: 10.1109/ICIP40778.2020.9190652. URL: https://github.com/YU1ut/Unknown-Class-Label-Cleaning (citado nas pgs. 55, 58).

[Yue e Jimenez-Ruiz 2024] Dylan Li Tin Yue e Ernesto Jimenez-Ruiz. "Citysti 2024 system: tabular data to kg matching using llms". In: *SemTab'24: Semantic Web Challenge on Tabular Data to Knowledge Graph Matching 2024, co-located with ISWC 2024 (CEUR Workshop Proceedings)*. Vol. 3889. CEUR-WS, 2024, pp. 84–89. URL: https://www.scopus.com/pages/publications/85214919840?origin=resultslist (citado nas pgs. 26, 35).

[Zaeifi e Lin 2024] Mehdi Zaeifi e Beiyu Lin. "Smartphone usage data cleaning using llm-based processing". In: *2024 IEEE International Conference on Big Data (Big Data)*. Institute of Electrical e Electronics Engineers Inc., 2024, pp. 8871–8873. DOI: 10.1109/BigData62323.2024.10825647. URL: https://www.scopus.com/pages/publications/85218073378?origin=resultslist (citado nas pgs. 27, 37).

[S. Zhang *et al.* 2025] Shuo Zhang, Zezhou Huang e Eugene Wu. "Data cleaning using large language models". In: *2025 IEEE 41st International Conference on Data Engineering Workshops (ICDEW)*. IEEE, 2025, pp. 28–32. DOI: 10.1109/ICDEW67478.2025.00008 (citado nas pgs. 26, 29, 31, 33–39, 44, 46, 47, 49, 50).

[X. Zhang *et al.* 2018] Xuezhou Zhang, Xiaojin Zhu e Stephen Wright. "Training set debugging using trusted items". In: *Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence (AAAI-18)*. AAAI Press, 2018, pp. 4482–4489. DOI: 10.1609/aaai.v32i1.11610. URL: http://pages.cs.wisc.edu/~jerryzhu/DUTI (citado na pg. 55).

[Z. Zhang *et al.* 2024] Zeyu Zhang, Paul Groth, Iacer Calixto e Sebastian Schelter. "Directions towards efficient and automated data wrangling with large language models". In: *2024 IEEE 40th International Conference on Data Engineering Workshops (ICDEW)*. IEEE COMPUTER SOC, 2024, pp. 301–304. DOI: 10.1109/ICDEW61823.2024.00044 (citado nas pgs. 26, 30).

[C. Zhao e He 2019] Chen Zhao e Yeye He. "Auto-EM: end-to-end fuzzy entity-matching using pre-trained deep models and transfer learning". In: *The World Wide Web Conference (WWW '19)*. New York, NY, USA: Association for Computing Machinery, 2019, pp. 2413–2424. DOI: 10.1145/3308558.3313578. URL: https://github.com/henryzhao5852/AutoEM (citado nas pgs. 56, 59).

[Zhu *et al.* 2025] Sinan Zhu, Darren Edmonds, Sanja Simonovikj e Yang Sun. "Metadata generation and evaluation using llms - case study on canonical titles". In: *Proceedings of the Nineteenth ACM Conference on Recommender Systems (RecSys '25)*. ASSOC COMPUTING MACHINERY, 2025, pp. 1010–1013. DOI: 10.1145/3705328.3748100 (citado nas pgs. 27, 32).